均值-方差思想与有效前沿

肖亮海

信息科学技术学院

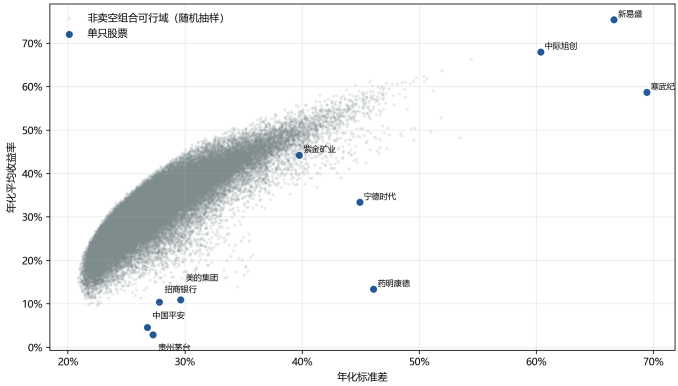
课程 GitHub：github.com/styluck/quant

本讲目标

学完本讲后，你应该能够：

1. 从均值向量与协方差矩阵写出组合的收益和风险。
2. 区分可行组合、有效组合、全局最小方差组合和最大 Sharpe 组合。
3. 解释 CAL、CML 与 SML，并将组合配置连接到第三讲的 CAPM 定价。
4. 使用真实股票数据和约束优化计算有效前沿，并识别估计误差风险。

第三讲留下的问题



第三讲已经完成：

- 十只股票的收益与风险估计；
- 5 万组非卖空随机权重；
- 组合可行域的数值近似。

本讲问题

可行组合很多，哪些组合值得持有？
如何找到它们？

本讲位置

1. 从可行域到有效前沿
2. 关键组合与无风险资产
3. 估计误差与稳健优化
4. 课堂实践：用真实数据计算前沿

Markowitz 的关键改变：从选证券到选组合

Harry Markowitz 在 1952 年的《Portfolio Selection》中把投资选择写成风险–收益权衡问题：

原文：`https://doi.org/10.1111/j.1540-6261.1952.tb01525.x`

- 投资对象是**一组资产权重**，而不只是某一只“好股票”。
- 组合风险取决于资产之间的协方差，不能逐只股票独立判断。
- 对风险厌恶投资者而言，只需保留不被其他组合支配的有效集合。

模型语言

用收益率均值描述收益，用方差描述风险，在约束下选择组合权重。

模型边界

均值与方差不能完整描述厚尾、偏度、流动性风险和最大回撤。

均值–方差模型需要哪些输入？

设 N 个资产的收益率向量为 $\boldsymbol{R}$，权重为 $\boldsymbol{w}$：

$$\boldsymbol{\mu} = \mathbb{E}[\boldsymbol{R}], \qquad \boldsymbol{\Sigma} = \mathrm{Cov}(\boldsymbol{R}), \qquad \mathbf{1}^\top \boldsymbol{w} = 1.$$

组合的两个核心统计量是

$$\mu_p = \boldsymbol{w}^\top \boldsymbol{\mu}, \qquad \sigma_p = \sqrt{\boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}}.$$

- $\boldsymbol{\mu}$ 决定每项资产对组合预期收益的贡献。
- $\boldsymbol{\Sigma}$ 同时包含单项资产波动和资产之间的共同波动。
- 第三讲解释了分散化；本讲研究如何在收益目标与投资约束下选择权重。

权重如何映射为均值–方差图上的点?

每一组满足约束的权重

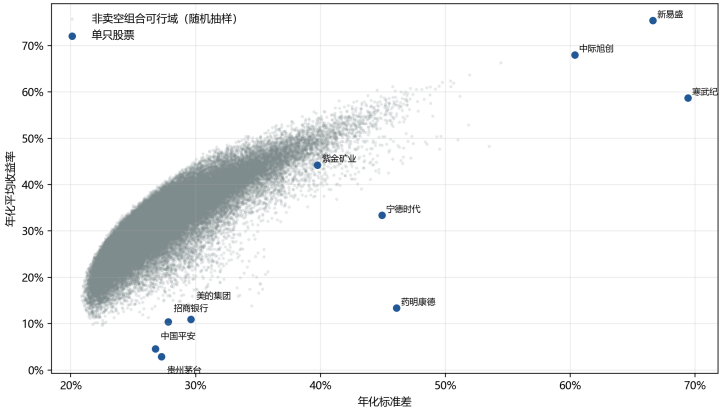
$$\mathbf{1}^\top \boldsymbol{w} = 1, \qquad w_i \geq 0,$$

都映射为风险–收益图上的一个点:

$$\boldsymbol{w} \longmapsto \begin{pmatrix} \sigma_p \\ \mu_p \end{pmatrix} = \begin{pmatrix} \sqrt{\boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}} \\ \boldsymbol{w}^\top \boldsymbol{\mu} \end{pmatrix}.$$

如何读图?

蓝点是单只股票；灰点是 5 万组随机非卖空权重对应的组合。



随机抽样回答不了的问题

散点近似展示了可行域，但不能精确识别边界；下一步要用优化寻找有效前沿。

可行不等于有效：什么是支配？

若组合 A 和 B 满足

$$\mu_A \geq \mu_B, \qquad \sigma_A \leq \sigma_B,$$

且至少一个不等式严格成立，则称 A 在均值–方差意义下**支配** B。

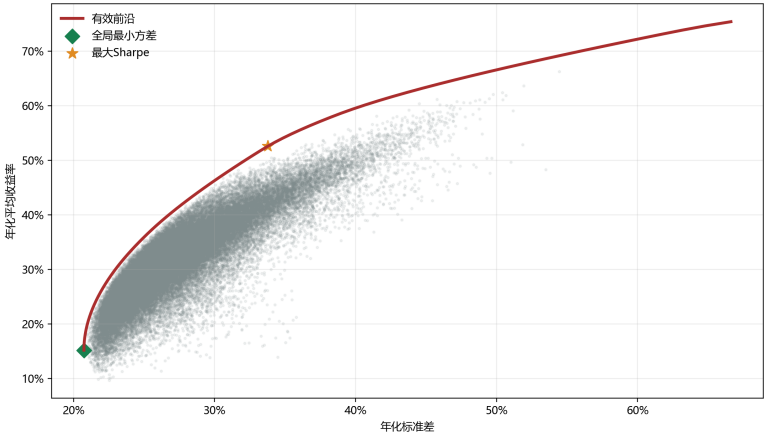
有效组合

不存在收益不低且风险更小，或风险不高且收益更大的可行替代组合。

低效组合

虽然权重满足约束，但存在更优的风险–收益替代方案。

有效前沿



灰点是可行组合，红线是有效前沿。全局最小方差组合在最左侧。
星号标出最大 Sharpe 组合，后面再解释它与无风险资产配置的关系；它通常不同于最左侧的 GMV 组合。

怎样精确计算一条有效前沿?

对每个目标收益率 μ_0，求解

$$\begin{aligned} \min_{\boldsymbol{w}} \quad & \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w} \\ \text{s.t.} \quad & \boldsymbol{w}^\top \boldsymbol{\mu} = \mu_0, \\ & \mathbf{1}^\top \boldsymbol{w} = 1, \\ & w_i \geq 0, \quad i = 1, \ldots, N. \end{aligned}$$

- 改变 μ_0，得到一系列“给定预期收益下风险最低”的组合。
- 从全局最小方差组合向上的边界才是有效前沿。
- 当协方差矩阵半正定时，这是凸二次规划；需检查求解状态和约束误差。

有效前沿不是数据的固定属性

前沿取决于**资产池、参数估计与约束**：

- 保持原参数与约束、且允许新资产权重为零时，新增资产会扩大或保持原可行域。
- 允许卖空时 w_i 可为负，前沿可能延伸，但杠杆和估计误差也会被放大。
- 最大权重、行业约束和交易限制会缩小可行域，却可能提高可实施性。
- 更换估计区间后，$\widehat{\mu}$ 与 $\widehat{\Sigma}$ 改变，样本前沿也会移动。

样本口径

我们画出的是“给定股票池、样本区间、估计方法和约束下的样本有效前沿”。

本讲位置

1. 从可行域到有效前沿
2. 关键组合与无风险资产
3. 估计误差与稳健优化
4. 课堂实践：用真实数据计算前沿

全局最小方差组合：只回答风险问题

全局最小方差（Global Minimum Variance, GMV）组合在给定可行域内使方差最低。先考虑仅有预算约束的情形：

$$\boldsymbol{w}_{\mathrm{GMV}} = \arg\min_{\mathbf{1}^\top \boldsymbol{w}=1} \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}.$$

允许卖空且 $\boldsymbol{\Sigma}$ 正定时，

$$\boldsymbol{w}_{\mathrm{GMV}} = \frac{\boldsymbol{\Sigma}^{-1}\mathbf{1}}{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1}\mathbf{1}}.$$

- GMV 不使用 $\boldsymbol{\mu}$，因此不回答“收益是否足够高”。
- 加入非卖空或权重上限后，一般使用数值优化而不是闭式解。
- 它是整个可行域最左侧的组合，也是有效前沿的起点。

GMV 的解析解：拉格朗日乘子推导

在允许卖空且 $\boldsymbol{\Sigma}$ 正定可逆时，考虑

$$\min_{\boldsymbol{w}} \ \frac{1}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w}, \qquad \text{s.t. } \mathbf{1}^{\top}\boldsymbol{w} = 1.$$

拉格朗日函数及一阶条件为

$$\mathcal{L}(\boldsymbol{w}, \lambda) = \frac{1}{2}\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w} - \lambda(\mathbf{1}^{\top}\boldsymbol{w} - 1), \qquad \nabla_{\boldsymbol{w}}\mathcal{L} = \boldsymbol{\Sigma}\boldsymbol{w} - \lambda\mathbf{1} = \mathbf{0}.$$

因此 $\boldsymbol{w} = \lambda\boldsymbol{\Sigma}^{-1}\mathbf{1}$。代入预算约束：

$$\lambda\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{1} = 1 \quad \Longrightarrow \quad \boxed{\boldsymbol{w}_{\mathrm{GMV}} = \frac{\boldsymbol{\Sigma}^{-1}\mathbf{1}}{\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{1}}}.$$

同时得到最小组合方差

$$\sigma^2_{\mathrm{GMV}} = \boldsymbol{w}_{\mathrm{GMV}}^{\top}\boldsymbol{\Sigma}\boldsymbol{w}_{\mathrm{GMV}} = \frac{1}{\mathbf{1}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{1}}.$$

若加入 $w_i \geq 0$、权重上限等不等式约束，闭式解通常不再成立，需要使用二次规划。

给定目标收益率：两个约束下的解析解

设 $\boldsymbol{\Sigma}$ 正定，$\boldsymbol{\mu}$ 中的元素不全相同。给定目标收益率 μ_0，允许卖空时求解

$$\min_{\boldsymbol{w}} \ \frac{1}{2}\boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}, \qquad \text{s.t. } \mathbf{1}^\top \boldsymbol{w} = 1, \quad \boldsymbol{\mu}^\top \boldsymbol{w} = \mu_0.$$

拉格朗日函数的一阶条件给出

$$\boldsymbol{\Sigma}\boldsymbol{w} - \lambda \mathbf{1} - \gamma \boldsymbol{\mu} = \mathbf{0} \quad \Longrightarrow \quad \boldsymbol{w} = \boldsymbol{\Sigma}^{-1}(\lambda \mathbf{1} + \gamma \boldsymbol{\mu}).$$

定义

$$A = \mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \mathbf{1}, \qquad B = \mathbf{1}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}, \qquad C = \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}, \qquad D = AC - B^2 > 0.$$

将两个约束代回，可得

$$\begin{pmatrix} A & B \\ B & C \end{pmatrix} \begin{pmatrix} \lambda \\ \gamma \end{pmatrix} = \begin{pmatrix} 1 \\ \mu_0 \end{pmatrix}, \qquad \lambda = \frac{C - B\mu_0}{D}, \quad \gamma = \frac{A\mu_0 - B}{D}.$$

目标收益率组合与解析有效前沿

因此，给定 μ_0 的最小方差权重为

$$\boxed{\boldsymbol{w}(\mu_0) = \boldsymbol{\Sigma}^{-1}\left(\frac{C - B\mu_0}{D}\mathbf{1} + \frac{A\mu_0 - B}{D}\boldsymbol{\mu}\right).}$$

对应的最小方差为

$$\sigma^2(\mu_0) = \frac{A\mu_0^2 - 2B\mu_0 + C}{D} = \frac{1}{A} + \frac{A}{D}\left(\mu_0 - \frac{B}{A}\right)^2.$$

GMV 是双曲线顶点

$$\mu_{\mathrm{GMV}} = \frac{B}{A}, \qquad \sigma^2_{\mathrm{GMV}} = \frac{1}{A}.$$

两条分支不要混淆

$\mu_0 \geq B/A$ 是有效上支；$\mu_0 < B/A$ 虽有最小方差解，但被上支组合支配。

加入 $w_i \geq 0$ 后，可行域缩小；前沿通常变为分段曲线，需要重新优化，不能简单截取原双曲线。

最大 Sharpe 组合：解析切点与约束解

延续 $\boldsymbol{\Sigma}$ 正定、$D>0$ 的假设，并设 $r_f<\mu_{\mathrm{GMV}}=B/A$。最大 Sharpe 组合求解：

$$\max_{\mu_0\ge\mu_{\mathrm{GMV}}}\frac{\mu_0-r_f}{\sigma(\mu_0)}\quad\Longleftrightarrow\quad\max_{\mathbf{1}^\top\boldsymbol{w}=1}\frac{\boldsymbol{w}^\top\boldsymbol{\mu}-r_f}{\sqrt{\boldsymbol{w}^\top\boldsymbol{\Sigma}\boldsymbol{w}}}.$$

允许卖空：切点组合有闭式解

令超额收益向量 $\boldsymbol{q}=\boldsymbol{\mu}-r_f\mathbf{1}$，则

$$\boxed{\boldsymbol{w}_T=\frac{\boldsymbol{\Sigma}^{-1}\boldsymbol{q}}{\mathbf{1}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{q}}}=\frac{\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}-r_f\mathbf{1})}{B-Ar_f}.$$

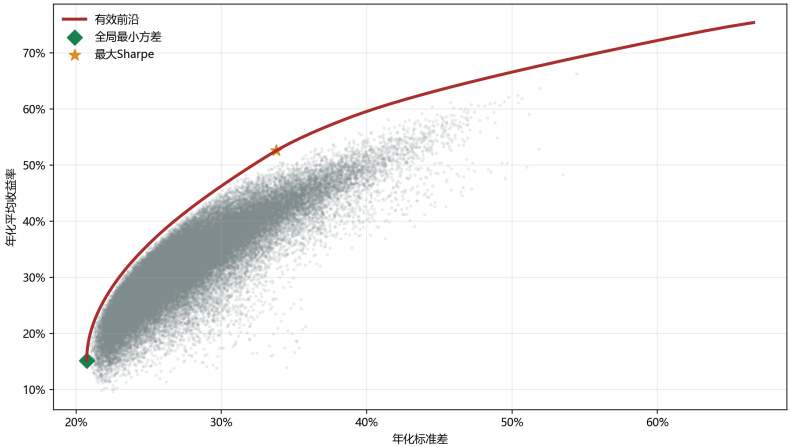
此时 $B-Ar_f>0$，得到有效上支的有限切点；随后用 CAL 解释它的几何含义。

加入非卖空约束后

若要求 $w_i\ge0$，上述闭式解可能不可行。本讲图中的最大 Sharpe 星号是直接在 $\mathbf{1}^\top\boldsymbol{w}=1,\ w_i\ge0$ 下用 SLSQP 数值优化得到的。

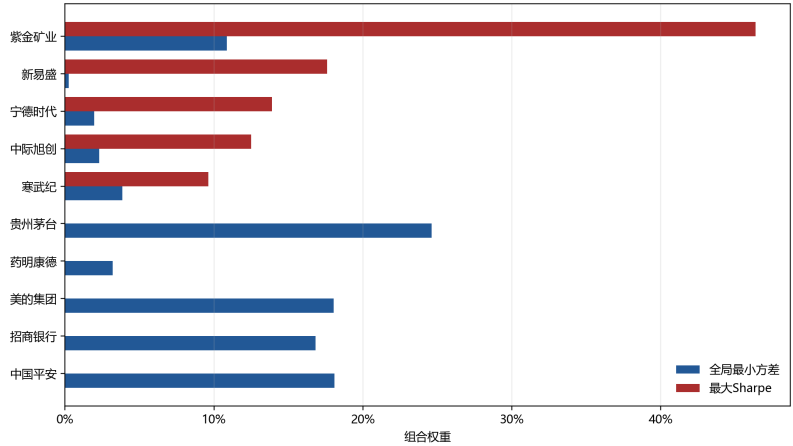
上述 3 个组合的解析解都依赖对协方差矩阵的估计，会有什么问题?

真实数据中的两个关键组合



样本结果：GMV 的年化均值约 15.2%、波动率约 20.7%；最大 Sharpe 组合分别约 52.6% 和 33.8%。

“最优”目标不同，权重也不同



GMV 偏向历史协方差结构下的低风险资产；最大 Sharpe 组合明显追逐样本期高收益资产，并出现更集中的权重。

CAL：无风险资产与任意风险组合的配置线

将比例 y 投入风险组合 P，其余投入无风险资产：

$$\mathbb{E}[R_c] = r_f + y\big(\mathbb{E}[R_P] - r_f\big), \qquad \sigma_c = |y|\sigma_P.$$

当 $y \geq 0$ 时可写为

$$\mathbb{E}[R_c] = r_f + \frac{\mathbb{E}[R_P] - r_f}{\sigma_P}\sigma_c.$$

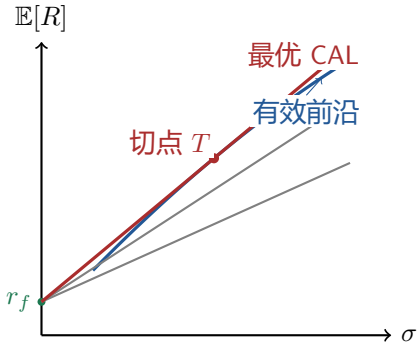
- 这条直线称为资本配置线（Capital Allocation Line, CAL）。
- CAL 的斜率就是风险组合 P 的 Sharpe 比率。
- $0 < y < 1$：部分资金持有无风险资产；$y = 1$：全部持有 P。
- $y > 1$：在允许借贷的理想模型中，借入无风险资产并加杠杆持有 P。

从很多条 CAL 中选择最优 CAL

每个风险组合 P 都对应一条 CAL：

$$\mathbb{E}[R_c] = r_f + SR(P)\sigma_c, \qquad SR(P) = \frac{\mathbb{E}[R_P] - r_f}{\sigma_P}.$$

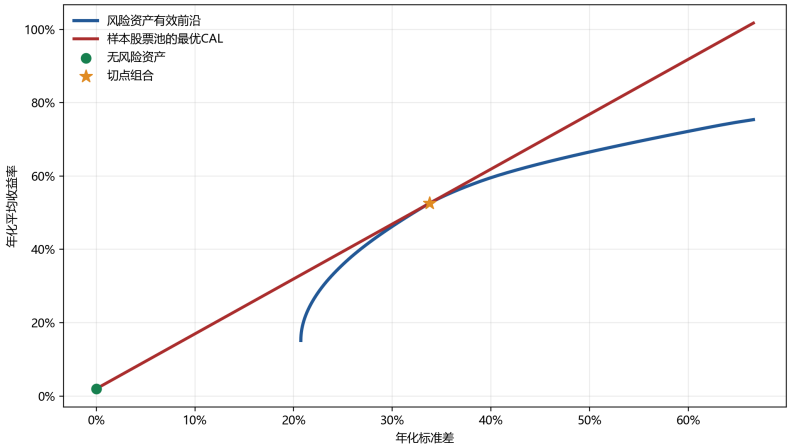
- 对相同的总风险，斜率更高的 CAL 提供更高预期收益。
- 因此应在风险资产有效前沿上最大化 Sharpe 比率。
- 从 $(0, r_f)$ 出发与有效前沿相切的直线，就是**最优 CAL**。



切点组合 T

在相同投资机会集与借贷利率下，最优 CAL 的斜率是最大 Sharpe；风险偏好通过无风险资产与 T 的配置比例体现。

真实股票池中的最优 CAL



红线通过 $r_f = 2\%$ 与样本最大 Sharpe 组合；它是该十股票样本的最优 CAL。

CML：市场组合对应的资本配置线

在 CAPM 均衡中，**市场组合** M 按市值比例持有全部风险资产，并位于有效前沿。无风险资产与 M 形成的有效配置线称为资本市场线（Capital Market Line, CML）：

$$\mathbb{E}[R_p] = r_f + \frac{\mathbb{E}[R_M] - r_f}{\sigma_M}\sigma_p$$

横轴与纵轴

横轴是组合总风险 σ_p，纵轴是组合预期收益 $\mathbb{E}[R_p]$。

斜率

斜率是市场组合的 Sharpe 比率 $\big(\mathbb{E}[R_M] - r_f\big)/\sigma_M$。

CAL 与 CML 的名称区别

CAL 对应任意风险组合；CML 对应 CAPM 均衡中的市场组合，并只描述无风险资产与市场组合形成的有效组合。

为什么最优 CAL 仍不一定是 CML?

组合优化中的最优 CAL

- 给定某个投资者的资产池;
- 使用其估计的 μ 与 Σ;
- 服从其卖空、杠杆和权重约束;
- 切点是一个**统计优化结果。**

CML 需要的 CAPM 均衡

- 投资者拥有相同预期和投资机会集;
- 均可按同一 r_f 借贷;
- 市场无摩擦，资产可分割;
- 所有人都进行均值–方差优化。

不能自动画等号

“十只股票的样本最大 Sharpe 组合”不是“全市场组合”，其最优 CAL 不能直接称为 CML。

为什么均衡中的切点组合是市场组合?

在上一页的 CAPM 假设下，所有投资者面对相同的有效前沿和借贷利率，因而选择同一个最优切点组合 T。风险偏好只影响投入 T 的资金比例。

市场出清

所有投资者对风险资产的持有量加总后，必须恰好等于市场中全部风险资产的供给。因此，共同持有的切点组合只能是市场组合：

$$\text{切点组合} T = \text{市场组合} M.$$

两基金分离

所有投资者通过无风险资产和同一个市场组合 M 配置财富；风险偏好决定比例：保守者选择 $0 < y < 1$，激进者可选择 $y > 1$。

CML 的适用范围

CML 描述无风险资产与市场组合形成的**均值–方差有效组合**，不用于评价任意单只股票。

为什么 CML 不能用来评价单只股票?

CML 描述的是无风险资产与市场组合形成的**有效组合**:

$$\mathbb{E}[R_p] = r_f + \frac{\mathbb{E}[R_M] - r_f}{\sigma_M}\sigma_p.$$

但单只股票通常不在 CML 上，因为其总风险可以分解为

$$\sigma_i^2 = \underbrace{\beta_i^2\sigma_M^2}_{\text{系统性风险}} + \underbrace{\sigma_{\varepsilon_i}^2}_{\text{特质风险}}.$$

- 在 CAPM 假设下，可分散的特质风险不获得额外的均衡风险溢价。
- 因此，单只股票的必要收益率应由不可分散的市场风险暴露决定。

从 σ 转向 β

评价有效组合使用总风险；评价任意资产的风险补偿使用 Beta。

SML：Beta 风险对应多少必要收益率？

证券市场线（Security Market Line, SML）是 CAPM 的图像表达：

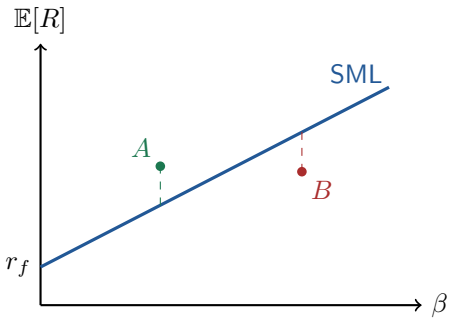
$$\boxed{\mathbb{E}[R_i] = r_f + \beta_i\big(\mathbb{E}[R_M] - r_f\big)}$$

其中

$$\beta_i = \frac{\mathrm{Cov}(R_i, R_M)}{\mathrm{Var}(R_M)}.$$

- 横轴是系统性风险 β，纵轴是必要收益率。
- 截距是无风险利率 r_f。
- 斜率是市场风险溢价 $\mathbb{E}[R_M] - r_f$。
- $\beta = 1$ 的资产应获得与市场组合相同的必要收益率。

SML 上方和下方意味着什么?



给定 Beta，将研究者估计的预期收益与 CAPM 必要收益率比较：

$$\alpha_i = \mathbb{E}[R_i] - [r_f + \beta_i(\mathbb{E}[R_M] - r_f)]\,.$$

- SML 上方：$\alpha_i > 0$;
- SML 下方：$\alpha_i < 0$;
- SML 上：$\alpha_i = 0$。

解释限制

CAPM 均衡要求 $\alpha_i = 0$；图中偏离表示估计或预测相对模型的差异，正 Alpha 仍需检验。

CML 和 SML 回答不同问题

	CML	SML
横轴	总风险 σ	系统性风险 β
适用对象	无风险资产与市场组合形成的有效组合	任意资产或组合
斜率	市场组合 Sharpe 比率	市场风险溢价 $\mathbb{E}[R_M] - r_f$
核心问题	有效组合的总风险如何补偿?	Beta 风险如何定价?

一句话

CML 讨论有效组合的总风险补偿；SML 讨论任意资产的 Beta 风险补偿。

本讲位置

1. 从可行域到有效前沿
2. 关键组合与无风险资产
3. 估计误差与稳健优化
4. 课堂实践：用真实数据计算前沿

历史均值不是未来预期收益

课堂中使用

$$\widehat{\boldsymbol{\mu}} = 252\,\overline{\boldsymbol{R}}, \qquad \widehat{\boldsymbol{\Sigma}} = 252\ \mathrm{Cov}(\boldsymbol{R}),$$

只是为了演示模型计算。

- 日收益噪声很大，历史均值的标准误下降得很慢。
- 协方差通常比均值更容易估计，但也会随市场状态改变。
- 高历史收益可能来自偶然样本、行业行情或前视选择，而不是稳定风险溢价。

解释边界

样本有效前沿描述历史统计量下的最优解，不代表未来真实前沿。

优化器会放大输入中的小误差

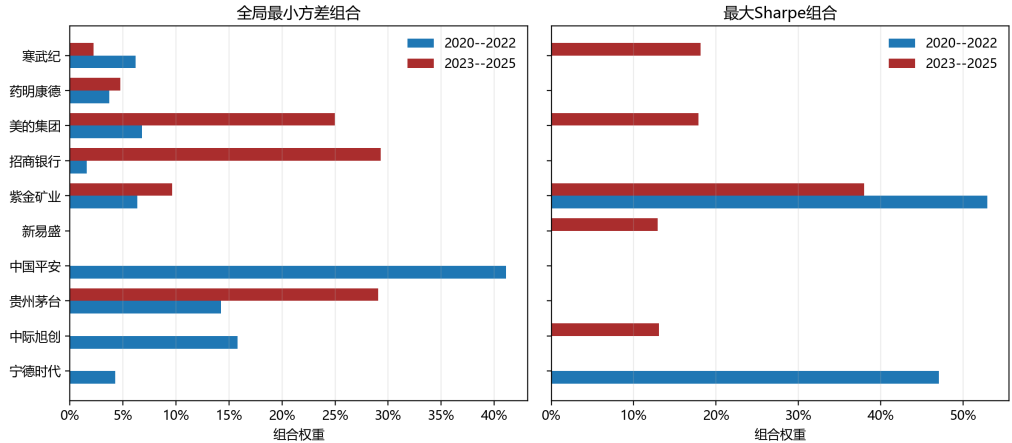
若两只股票的估计收益非常接近，$\widehat{\mu}_i$ 的微小变化可能使权重从 0 跳到上限。

- 最大 Sharpe 同时追逐高 $\widehat{\mu}$、低方差和有利协方差，容易形成角点解。
- 允许卖空时，正负大权重可能互相抵消，使名义净权重正常但总杠杆很高。
- “最优值”变化很小，不代表“最优权重”也稳定。

敏感性思想

不只问“最优权重是多少”，还要问“输入略微变化时，权重会变化多少”。

真实数据检验：更换估计区间会怎样？



同一股票池分别使用 2020–2022 和 2023–2025 估计。GMV 已明显变化，最大 Sharpe 权重的切换更加剧烈。

为什么最大 Sharpe 通常比 GMV 更不稳定?

GMV

- 主要依赖 $\widehat{\Sigma}$;
- 不直接估计预期收益;
- 通常较少追逐短期赢家。

最大 Sharpe

- 同时依赖 $\widehat{\mu}$ 与 $\widehat{\Sigma}$;
- 均值估计误差通常更大;
- 容易产生集中和频繁切换。

因此更高的样本 Sharpe 可能只是更严重地拟合了样本噪声。

实务中如何让优化结果更稳健?

方法	作用
权重上下限	避免单一资产和卖空杠杆主导组合
协方差收缩	将不稳定的样本协方差拉向更简单的结构
收益率收缩	将极端历史均值拉向总体均值或因子模型预测
换手惩罚	降低参数小幅变化导致的大规模交易
风险预算	直接约束各资产或因子的风险贡献
多窗口检验	检查权重和绩效是否依赖特定样本区间

强基准

任何复杂优化都应与等权、GMV 和简单约束组合比较。

本讲位置

1. 从可行域到有效前沿
2. 关键组合与无风险资产
3. 估计误差与稳健优化
4. 课堂实践：用真实数据计算前沿

实验原理：从参数估计到组合配置

使用第三讲的共同样本估计 $\widehat{\boldsymbol{\mu}}$ 与 $\widehat{\boldsymbol{\Sigma}}$，对非卖空组合计算

$$\widehat{\mu}_p = \boldsymbol{w}^\top \widehat{\boldsymbol{\mu}}, \qquad \widehat{\sigma}_p = \sqrt{\boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{w}}, \qquad \mathbf{1}^\top \boldsymbol{w} = 1, \quad w_i \geq 0.$$

- 先求 GMV，再从其收益水平向上逐点求解有效前沿。
- 最大 Sharpe 组合决定样本最优 CAL；与等权、GMV 比较权重和统计量。
- 更换估计窗口，检查权重对输入参数的敏感性。

本实验的解释范围

所有结果均为样本内估计；股票池存在前视选择，窗口对比不构成样本外回测。

实践步骤与框架脚本

1. 继续使用固定的 2026 年 8 月 31 日沪深 300 前十大权重股及 2020–2025 共同样本。
2. 在第三讲随机组合可行域上，使用约束优化逐点计算有效前沿。
3. 求解 GMV 与最大 Sharpe 组合，比较权重和样本统计量。
4. 加入 $r_f = 2\%$ 绘制该股票池的最优 CAL。
5. 分割估计区间，观察最优权重是否稳定。

参考脚本

`code/lab04/lab04_framework.py`。

实验包：复用第三讲的离线数据

- 使用 `code/data/` 中的逐股 CSV，包含原始收盘价与后复权因子。
- 在 Spyder 打开 `code/lab04/lab04_framework.py`。
- 导入、逐股读取、共同样本与绘图已提供，无需联网和其他讲的函数。
- 按 L04-01 至 L04-06 的编号，将代码填入对应 TODO 区域。
- 全部补齐后从头运行；结果自动保存到 `code/output/lab04/`。

样本

2020–2025 研究期取十只股票与沪深 300 的共同有效日期，始于 2020-07-21。股票池**需要你自行选择，课件代码中的 10 只个股仅作为示例，可以选择更大的股票池或其他的个股。**

L04-01：年化参数与随机可行域

```
mu = R.mean().to_numpy() * 252  # 算术年化平均收益率
Sigma = R.cov().to_numpy() * 252  # 同一共同样本的年化协方差
rf = 0.02  # 教学假设：年化无风险利率为2%
n = len(codes)
w0 = np.full(n, 1 / n)  # 等权初始点
bounds = [(0, 1)] * n  # 非卖空约束
budget = {"type": "eq", "fun": lambda w: w.sum() - 1}
options = {"ftol": 1e-12, "maxiter": 3000}
rng = np.random.default_rng(20260914)
W = rng.dirichlet(np.ones(n), size=50000)  # 权重非负、和为1
random_mean = W @ mu
random_vol = np.sqrt(np.einsum("ij,jk,ik->i", W, Sigma, W))
```

任务 1：逐点求解非卖空有效前沿

对从 GMV 收益到最高单股收益之间的多个目标收益率 μ_0，分别求解：

$$\min_{\boldsymbol{w}} \ \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}, \quad \text{s.t. } \boldsymbol{w}^\top \boldsymbol{\mu} = \mu_0, \ \mathbf{1}^\top \boldsymbol{w} = 1, \ \boldsymbol{w} \geq 0.$$

- 将优化结果叠加在第三讲的随机组合散点云上。
- 检查每个优化是否成功，权重和与目标收益约束是否满足。

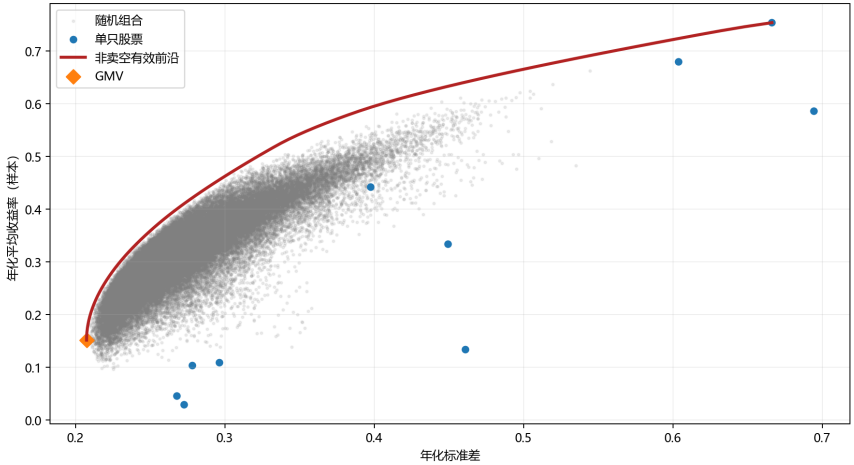
L04-02：求解 GMV

```
gmv = minimize(lambda w: w @ Sigma @ w, w0,
               method="SLSQP", bounds=bounds,
               constraints=[budget], options=options)
assert gmv.success, gmv.message  # 先检查求解状态
w_gmv = gmv.x
assert abs(w_gmv.sum() - 1) < 1e-7
assert w_gmv.min() >= -1e-8
mu_gmv = w_gmv @ mu
vol_gmv = np.sqrt(w_gmv @ Sigma @ w_gmv)
```

L04-03：逐点计算有效前沿

```
targets = np.linspace(mu_gmv, mu.max(), 80)  # 只取有效上支
frontier_w = []
for target in targets:
    target_constraint = {"type": "eq",
                         "fun": lambda w: w @ mu - target}
    result = minimize(lambda w: w @ Sigma @ w, w_gmv,
                      method="SLSQP", bounds=bounds,
                      constraints=[budget, target_constraint], options=options)
    assert result.success, result.message
    assert abs(result.x.sum() - 1) < 1e-7
    assert abs(result.x @ mu - target) < 1e-7
    assert result.x.min() >= -1e-8
    frontier_w.append(result.x)
frontier_w = np.vstack(frontier_w)
frontier_vol = np.sqrt(
    np.einsum("ij,jk,ik->i", frontier_w, Sigma, frontier_w))
```

任务 1 结果：随机可行域与精确有效前沿



任务 2：求解并比较两个关键组合

1. 求解非卖空 GMV 组合。
2. 在 $r_f = 2\%$ 下求解非卖空最大 Sharpe 组合。
3. 与等权组合比较权重、年化算术均值、年化波动率及 Sharpe。
4. 解释为什么两种目标给出不同的集中方向。

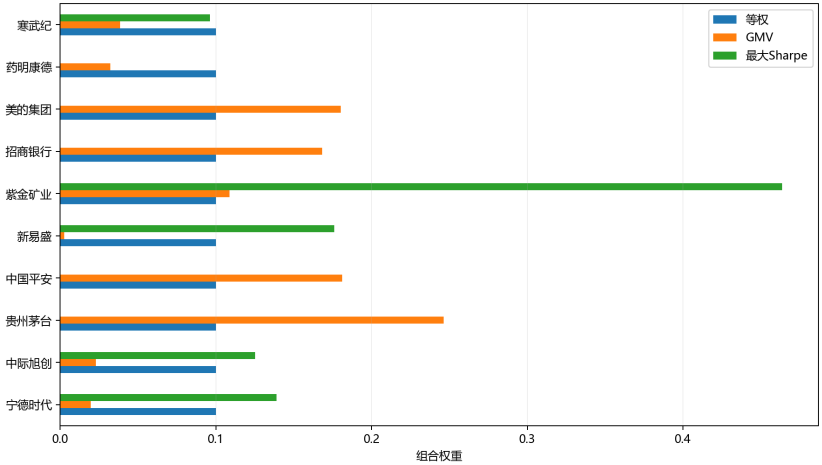
解释要求

所有“收益”和“Sharpe”都必须称为样本历史估计，不得表述为未来保证。

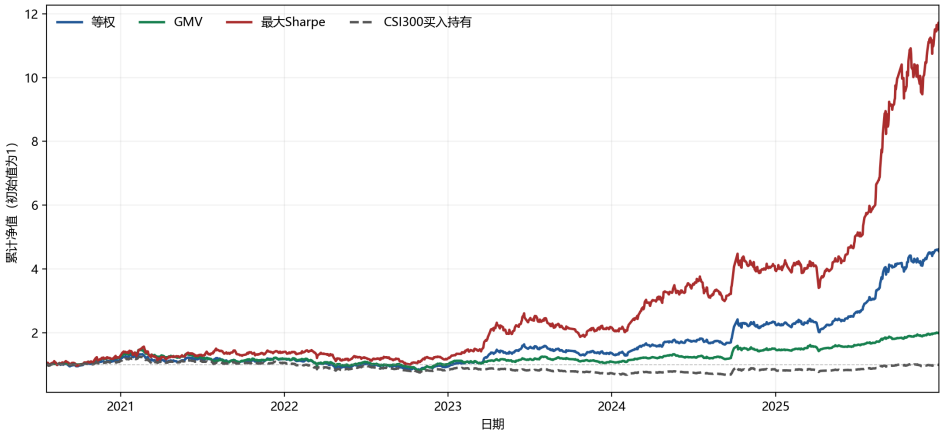
L04-04：最大 Sharpe 与等权比较

```
negative_sharpe = lambda w: -(w @ mu - rf) / np.sqrt(w @ Sigma @ w)
tangent = minimize(negative_sharpe, w0, method="SLSQP",
                   bounds=bounds, constraints=[budget], options=options)
assert tangent.success, tangent.message
w_tangent = tangent.x
assert abs(w_tangent.sum() - 1) < 1e-7
assert w_tangent.min() >= -1e-8
weights = pd.DataFrame({"等权": w0, "GMV": w_gmv,
                        "最大Sharpe": w_tangent}, index=codes)
summary = pd.DataFrame(index=weights.columns)
for label in weights:
    w = weights[label].to_numpy()
    mean = w @ mu
    vol = np.sqrt(w @ Sigma @ w)
    summary.loc[label, ["mean_ann", "vol_ann", "sharpe_ann"]] = (
        mean, vol, (mean - rf) / vol)  # 三组组合使用同一个rf
print(summary.round(4))
```

任务 2 结果：目标函数决定组合权重



任务 2 结果：三种组合与 CSI300 的净值对比



三种组合使用全样本权重、每日再平衡，忽略交易成本；与同期 CSI300 买入持有比较，初始净值均为 1。

任务 3：加入无风险资产并绘制最优 CAL

使用最大 Sharpe 组合的样本统计量 $(\widehat{\mu}_T, \widehat{\sigma}_T)$：

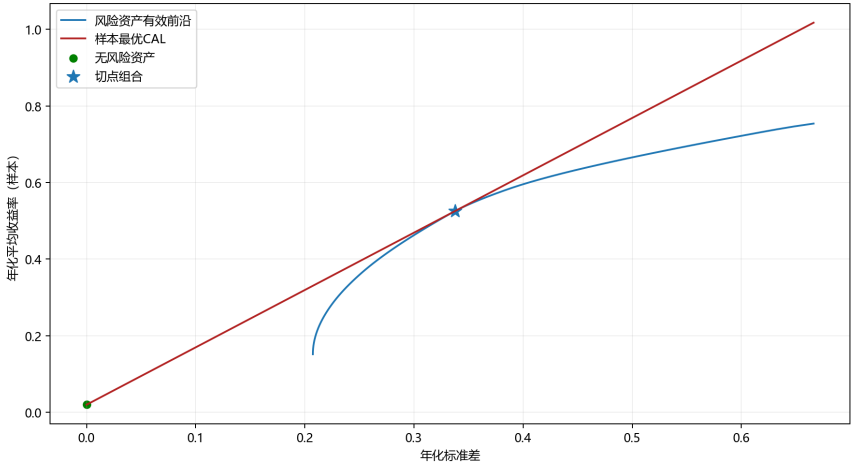
$$\widehat{\mu}_c = r_f + \frac{\widehat{\mu}_T - r_f}{\widehat{\sigma}_T}\sigma_c.$$

- 绘制风险资产有效前沿、无风险利率点、切点组合和最优 CAL。
- 说明为什么该直线只能称为样本股票池的最优 CAL。
- 写出在 CAPM 中进一步称其为 CML 所需要的条件。

L04-05：绘制最优 CAL

```
mu_t, vol_t, sharpe_t = summary.loc["最大Sharpe"]
cal_vol = np.linspace(0, frontier_vol.max(), 100)
cal_return = rf + sharpe_t * cal_vol  # 斜率为最大样本Sharpe
fig, ax = plt.subplots(figsize=(10, 5.6))
ax.plot(frontier_vol, targets, label="风险资产有效前沿")
ax.plot(cal_vol, cal_return, color="firebrick", label="样本最优CAL")
ax.scatter(0, rf, color="green", label="无风险资产")
ax.scatter(vol_t, mu_t, marker="*", s=120, label="切点组合")
```

任务 3 结果：样本股票池的最优 CAL



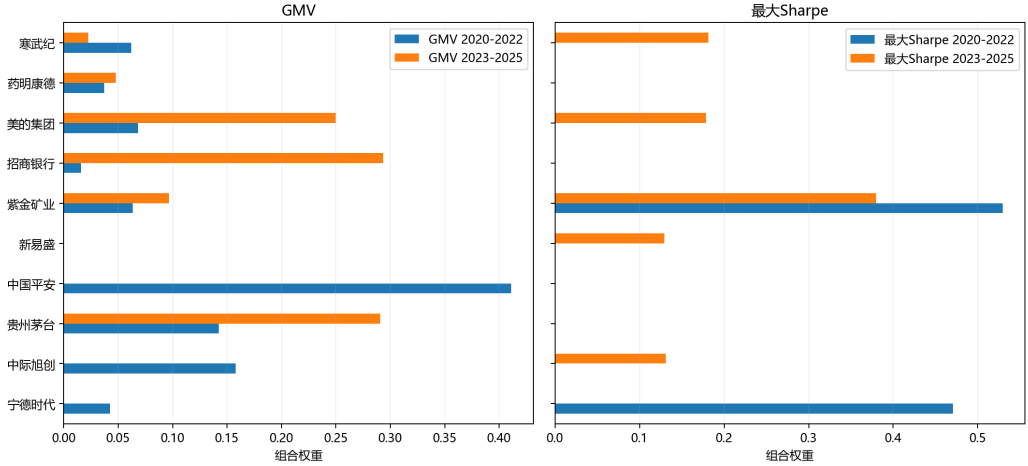
任务 4：检验估计窗口敏感性

1. 分别使用 2020–2022 和 2023–2025 数据估计 μ 与 Σ。
2. 在两个窗口中分别求解 GMV 和最大 Sharpe 组合。
3. 比较同一目标在两个窗口中的权重变化。
4. 区分权重敏感性与样本外绩效；提出下一步样本外验证方案。

L04-06：窗口敏感性

```
window_weights = pd.DataFrame(index=codes)
windows = {"2020-2022": R.loc[:"2022-12-31"],
           "2023-2025": R.loc["2023-01-01":]}
for label, sample in windows.items():
    mu_w = sample.mean().to_numpy() * 252
    Sigma_w = sample.cov().to_numpy() * 252
    objectives = {
        "GMV": lambda w: w @ Sigma_w @ w,
        "最大Sharpe": lambda w: -(w @ mu_w - rf)
                                / np.sqrt(w @ Sigma_w @ w)}
    for model, objective in objectives.items():
        fit = minimize(objective, w0, method="SLSQP", bounds=bounds,
                       constraints=[budget], options=options)
        assert fit.success, fit.message
        assert abs(fit.x.sum() - 1) < 1e-7 and fit.x.min() >= -1e-8
        window_weights[f"{model} {label}"] = fit.x
```

任务 4 结果：最优权重依赖估计窗口



实践提交内容

1. 数据与口径：股票池、样本区间、复权方法、共同样本和无风险利率假设。
2. 有效前沿：随机组合云、精确前沿及优化约束检查。
3. 关键组合：GMV 与最大 Sharpe 的权重表和样本统计量。
4. 无风险资产：最优 CAL 图，以及它不能直接称为 CML 的原因。
5. 稳定性：两个估计窗口的权重对比，并讨论样本外风险；本实验未实施样本外回测。
6. 提交填好的 `lab04_framework.py`、结果 CSV、四张图和简短实验报告。

本讲小结

- 有效前沿由不被其他可行组合支配的风险–收益组合构成，可以通过目标收益约束下的最小方差问题逐点计算。
- GMV 只依赖协方差矩阵；最大 Sharpe 同时依赖收益和协方差估计，因此通常更加不稳定。
- 引入无风险资产后，最大 Sharpe 组合决定样本股票池的最优 CAL；只有在 CAPM 均衡中才进一步得到 CML。
- 历史参数、资产池和约束共同决定样本前沿；最优权重不是资产的固定属性。
- 组合优化必须接受样本外检验，并与等权和简单约束组合比较。