多因子模型：Fama-French、APT 与 Barra 框架

肖亮海

信息科学技术学院

课程 GitHub：`github.com/styluck/quant`

CAPM 的预期收益关系

第三讲的资本资产定价模型（CAPM）给出风险与预期收益的关系：

$$\mathbb{E}[R_i] - r_f = \beta_i \big(\mathbb{E}[R_M] - r_f\big), \qquad \beta_i = \frac{\mathrm{Cov}(R_i, R_M)}{\mathrm{Var}(R_M)}.$$

- R_i、R_M 分别为股票与市场组合收益，r_f 为无风险利率。
- 市场 Beta 衡量股票对市场波动的敏感度，即承担的市场风险。
- 在模型假设下，预期超额收益由市场 Beta 与市场风险溢价决定。
- 可分散的特质风险不获得风险补偿；定价关系体现在证券市场线（SML）上。

证券市场线的含义

证券市场线的斜率为市场风险溢价；Beta 每增加一单位，模型给出的预期超额收益增加一个市场风险溢价。

均值—方差组合优化

第四讲的现代投资组合理论（MPT）用均值与方差描述组合：

$$\mu_p = \boldsymbol{w}^\top \boldsymbol{\mu}, \qquad \sigma_p^2 = \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}.$$

- $\boldsymbol{w}$ 为资产权重，$\boldsymbol{\mu}$ 为预期收益向量，$\boldsymbol{\Sigma}$ 为收益协方差矩阵。
- 分散化效果取决于资产之间的协方差，不只是每只股票自身的波动。

给定目标收益率，寻找风险最低的组合

$$\min_{\boldsymbol{w}} \ \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}, \qquad \text{s.t. } \boldsymbol{w}^\top \boldsymbol{\mu} = \mu_0, \quad \mathbf{1}^\top \boldsymbol{w} = 1.$$

改变目标收益率 μ_0，得到组合前沿及其有效部分。

优化所需的预期收益和协方差未知，实际计算时需要先用数据估计。

市场 Beta 未能解释的收益差异

CAPM 的预测与实证检验

CAPM 预测：市场 Beta 相同的股票，应具有相同的预期超额收益。但在实证中，单靠市场 Beta 往往不能充分解释股票之间的平均收益差异。

- 规模、价值等股票特征，可能对应市场 Beta 之外的平均收益差异。
- 用市场因子回归个股收益时，残差也可能包含遗漏的共同因素。

增加解释变量

可以在市场因子之外加入规模、价值等因素，检验它们是否解释了额外的收益差异。

组合优化中的参数估计误差

实际优化使用估计值 $\widehat{\mu}$ 与 $\widehat{\Sigma}$，而真实参数未知。

- **预期收益难估计**：样本平均收益含有噪声，换一个样本窗口，估计结果可能明显变化。
- **协方差参数多**：N 只股票需要估计 $N(N+1)/2$ 个不同的协方差矩阵元素；100 只股票对应 5050 个。
- **优化会放大误差**：微小的输入变化可能带来较大的权重变化，尤其在资产高度相关、约束较少时。
- 样本内最优组合可能出现权重集中、频繁调仓或样本外表现下降。

协方差的因子表示

若股票间的共同波动主要来自少数因素，就可以先估计这些因素的协方差，再据此计算股票收益的协方差。

多因子模型的基本思路

股票收益既受市场、行业等共同因素影响，也包含公司自身的变化。因子模型将这两部分分开表示：

$$\text{股票收益} = \text{共同因素解释的收益} + \text{个股剩余收益}.$$

- 每只股票对共同因素的反应程度可以不同，这种差别用因子暴露表示。
- 增加市场以外的因素，可以考察规模、价值等特征是否解释了额外的收益差异。
- 多只股票受同一组因素影响，因此可以用因子收益的协方差描述股票之间的共同波动。

本讲的模型

Fama–French 用市场、规模和价值因子解释收益；APT 讨论暴露与预期收益的关系；Barra 类模型用股票特征估计协方差和组合风险。

本讲目标

- 用具体例子区分因子、因子暴露、因子收益和特质收益。
- 看懂回归数据的每一行，判断系数估计的是暴露还是因子收益。
- 从单因子推广到多因子，区分当期收益、预期收益和风险。
- 理解因子结构如何帮助估计协方差、分解组合风险。
- 比较 Fama–French、APT 与 Barra 的问题和方法。
- 用 BP、市值和下一月收益完成横截面回归实践。

四个核心概念

因子模型用共同因素解释收益相关性，用不同暴露描述个股反应的差异。

概念	含义	以市场因子为例
因子	解释多只股票收益变化的共同因素，如市场、行业、规模、价值	市场涨跌会影响多只股票
因子暴露	一只股票对该因子的敏感度，或在该特征上的取值	市场 Beta 为 1.2，表示对市场的敏感度
因子收益	该因子在某一期、每单位暴露对应的收益	本月市场超额收益为 2%
特质收益	扣除模型解释部分后，某只股票本期剩余的收益	实际收益减去模型解释的收益

因子对个股收益的贡献

某因子对个股的收益贡献 = **该股的因子暴露** × **当期因子收益。**

例：市场因子与个股收益

只考虑市场这一个因子，暂设截距为零；股票和市场收益均指超额收益。

$$\underbrace{r_{i,t}}_{\text{股票本月收益}} = \underbrace{\beta_i}_{\text{因子暴露}} \times \underbrace{f_t}_{\text{因子收益}} + \underbrace{\epsilon_{i,t}}_{\text{特质收益}} .$$

已知：股票 Beta 为 1.2，市场本月收益为 2%，股票实际收益为 3%

市场因子解释的收益：$1.2 \times 2\% = 2.4\%$。

特质收益：$3\% - 2.4\% = 0.6\%$，即模型本月未解释的部分。

- 1.2 是股票对市场的敏感度，2% 是本月市场收益；市场下跌时，因子收益为负。
- Beta 可用这只股票与市场在多个月份的收益数据回归估计。
- 0.6% 只是本月残差，可能含公司事件、遗漏因素与噪声。

例：用行业归属定义暴露

固定月份 t，假设市场上只有银行、科技两个行业，用行业分类解释超额收益。

股票	银行暴露	科技暴露	本月收益
银行甲	1	0	4%
银行乙	1	0	2%
科技甲	0	1	0%
科技乙	0	1	-2%

$$r_{i,t} = b_{i,\text{银行}} f_{\text{银行},t} + b_{i,\text{科技}} f_{\text{科技},t} + u_{i,t}.$$

- **因子：**两个行业；**暴露：**属于该行业记为 1，否则为 0。
- 行业归属已经知道，待估计的是两个行业**本月的共同收益。**
- 两个行业变量之和恒为 1，因此保留全部行业变量时不再另加截距。

参考：Zivot (2012), Factor Models for Asset Returns，PDF pp. 17–18。

行业模型的回归结果

每个行业内的股票具有相同的拟合值。使该行业残差平方和最小的拟合值，就是行业平均收益：

$$\widehat{f}_{\text{银行},t} = \frac{4\% + 2\%}{2} = 3\%, \qquad \widehat{f}_{\text{科技},t} = \frac{0\% - 2\%}{2} = -1\%.$$

股票	实际收益	行业解释部分	特质收益（残差）
银行甲	4%	$1 \times 3\% = 3\%$	1%
银行乙	2%	$1 \times 3\% = 3\%$	-1%
科技甲	0%	$1 \times (-1\%) = -1\%$	1%
科技乙	-2%	$1 \times (-1\%) = -1\%$	-1%

结果解释

这个例子以行业为因子，以行业归属的 0/1 变量为暴露。估计的行业收益是组内平均值，个股收益与其之差就是残差。

参考：Zivot (2012), Factor Models for Asset Returns，PDF pp. 17–18。

用 BP 定义价值暴露

行业归属用 0/1 表示；BP 是连续变量，可以用来描述股票的价值特征。

$$BP_{i,t} = \frac{\text{账面权益}_{i,t}}{\text{市值}_{i,t}}, \qquad b_{i,\mathrm{BP},t} = z(BP_{i,t}) = \frac{BP_{i,t} - \overline{BP}_t}{s_{BP,t}}.$$

其中 $\overline{BP}_t$ 和 $s_{BP,t}$ 分别为当期股票池中 BP 的均值与标准差。

固定一期，对多只股票做回归

$$r_{i,t} = a_t + b_{i,\mathrm{BP},t} f_{\mathrm{BP},t} + u_{i,t}.$$

BP 暴露和股票收益是已知数据；截距 a_t 与斜率 $f_{\mathrm{BP},t}$ 由回归估计。

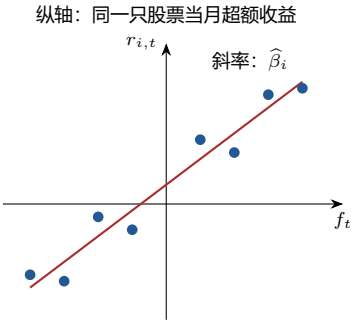
- 标准化暴露相差 1，表示原始 BP 相差一个横截面标准差。
- 收益用小数表示时，若斜率为 0.02，暴露相差 1 对应的拟合收益差为 2 个百分点。

参考：CFA Institute, Using Multifactor Models。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 实践二：构建自己的多因子模型并解释因子收益

时间序列回归：每个点是一个月



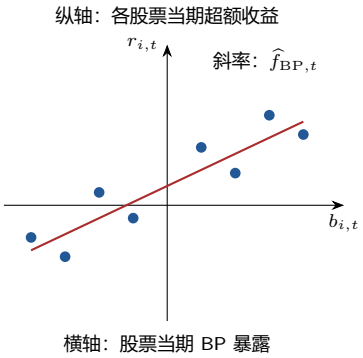
同一只股票的月度数据

$r_{i,t} = \alpha_i + \beta_i f_t + \epsilon_{i,t}$。

- 每个点对应一个月份。
- 已知股票收益与市场收益。
- 估计截距和**市场暴露** β_i。
- 暴露在这个估计窗口内视为不变。

参考：Zivot (2012), Factor Models for Asset Returns，PDF pp. 9–10。

横截面回归：每个点是一只股票



参考：CFA Institute, Using Multifactor Models。

同一个月的多只股票数据

$r_{i,t} = a_t + b_{i,t} f_{\mathrm{BP},t} + u_{i,t}$。

- 每个点对应一只股票。
- 已知股票收益与 BP 暴露。
- 估计截距和**当期 BP 因子收益**。
- 同一期各股票共用这一组系数。

两种回归的比较

	时间序列回归	横截面回归
固定什么	一只股票 i	一个月份 t
每行观测	一个月	一只股票
被解释变量	该股票各月收益	各股票当月收益
解释变量	各月因子收益	各股票的因子暴露
斜率的含义	个股暴露 β_i	当期因子收益 f_t
例子	用市场收益估计 Beta	用 BP 暴露估计当月 BP 收益

回归系数的含义

时间序列回归用因子收益估计个股暴露；横截面回归用个股暴露估计当期因子收益。

课堂练习：改变 BP 的尺度，回归结果怎样变化？

固定月份 t，对同一批股票做含截距的一元 OLS 回归，得到

$$\widehat{r}_{i,t} = \widehat{a}_t + \widehat{f}_t BP_{i,t}.$$

假设各股票 BP 均为正且不完全相同。下面只改变解释变量，股票样本和收益保持不变。

1. 将所有 BP 乘以 10。怎样调整斜率，才能使每只股票的拟合收益保持不变？截距需要改变吗？
2. 将 BP 标准化为

   $$z_{i,t} = \frac{BP_{i,t} - \overline{BP}_t}{s_{BP,t}}.$$

   截距和斜率应怎样调整？每只股票的残差会不会变化？
3. 若改用 $PB_{i,t} = 1/BP_{i,t}$，还能仅靠调整截距和斜率，使所有股票的拟合收益保持不变吗？

提示：将变换后的变量代回原来的拟合方程，观察常数项和一次项。

课堂练习：推导与解释

1. **BP 乘以 10：** 令 $BP^*_{i,t} = 10BP_{i,t}$，则

$$\widehat{r}_{i,t} = \widehat{a}_t + \frac{\widehat{f}_t}{10} BP^*_{i,t}.$$

斜率除以 10，截距不变，拟合收益不变。

2. **BP 标准化：** 由 $BP_{i,t} = \overline{BP}_t + s_{BP,t} z_{i,t}$，得

$$\widehat{r}_{i,t} = \underbrace{(\widehat{a}_t + \widehat{f}_t \overline{BP}_t)}_{\text{新的截距}} + \underbrace{(s_{BP,t} \widehat{f}_t)}_{\text{新的斜率}} z_{i,t}.$$

拟合收益不变，实际收益也不变，因此残差不变。这两种变换重新做 OLS，会得到上述换算后的系数。

3. **BP 换成 PB：** 原方程变为 $\widehat{r}_{i,t} = \widehat{a}_t + \widehat{f}_t / PB_{i,t}$，一般不是 PB 的直线函数。因此改用 PB 做线性回归，通常会改变拟合收益和残差。

代码练习：BP 与次日收益的回归

`simple_cross` 每行是一只股票，含 `bp` 与 `return_next` 两列。

$$BP_{i,t} = 1/PB_{i,t}, \qquad R_{i,t+1} = 100\left(\frac{P^{\text{adj}}_{i,t+1}}{P^{\text{adj}}_{i,t}} - 1\right).$$

补全回归公式，拟合结果命名为 simple

```
# pb、close、adj 已用 pd.read_csv 读取
bp = (1 / pb.loc[date]).rename("bp")
price = close * adj
ret = 100 * (price.loc[next_date] / price.loc[date] - 1)
simple_cross = pd.concat([bp, ret.rename("return_next")], axis=1)
simple_cross = simple_cross.replace([np.inf, -np.inf], np.nan)
simple_cross = simple_cross.loc[simple_cross.bp > 0].dropna()
simple = smf.ols("________", data=simple_cross).fit()
print(simple.params)
print(simple.nobs, simple.rsquared)
```

在 `lab05_framework.py` 的 `L05-BP` 段完成练习。保留正 BP，删除无穷值和缺失值；绘图使用同一份回归样本。

单日 BP 回归结果的解释

$$\widehat{R}_{i,t+1} = 1.1249 + 0.0942\, BP_{i,t} \qquad \text{(收益单位：\%)}.$$

样本数 $N = 2262$，$R^2 = 0.000238$。

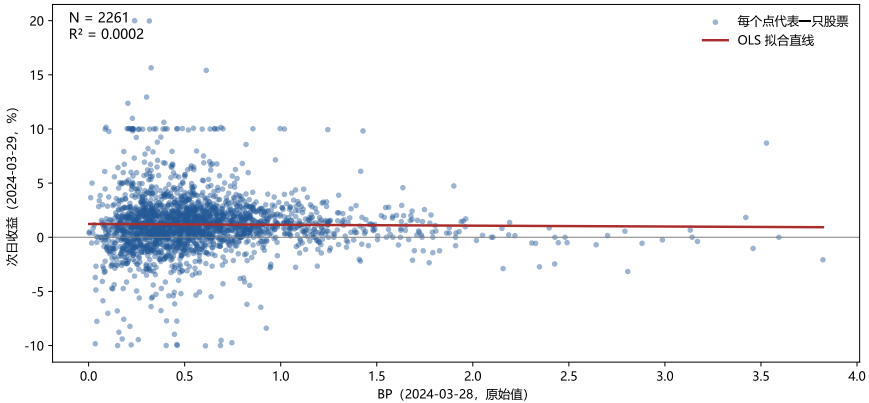
回归公式

```
smf.ols("return_next ~ bp", data=simple_cross).fit()
```

- 斜率是这一天的 BP 收益系数；BP 是已知的股票特征。
- BP 相差 1，拟合收益相差约 0.0942 个百分点；相差 0.5 时，约相差 0.0471 个百分点。
- 个股实际收益与拟合直线上的值之差，就是这只股票的残差。
- 本例的 R^2 接近零，BP 对这一天个股收益差异的解释能力很弱。

BP 与次日收益的散点图

2024 年 3 月 28 日的 BP 与 3 月 29 日收益；每个点代表一只上证股票。



横轴为原始 BP，纵轴为次日收益（%）；红线为含截距的一元 OLS 拟合结果。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 实践二：构建自己的多因子模型并解释因子收益

从单因子到多因子

市场单因子回归

$$r_{i,t} = \alpha_i + \beta_i r_{m,t} + \epsilon_{i,t}.$$

- 只使用市场收益作为解释变量。
- Beta 是市场暴露。
- 残差是市场因子未解释的部分。

多因子模型

$$r_{i,t} = \alpha_i + \sum_{k=1}^{K} \beta_{ik} f_{k,t} + \epsilon_{i,t}.$$

- 同时使用 K 个因子收益作为解释变量。
- 每个系数表示控制其他因子后的敏感度。
- 残差仍可能包含遗漏的共同因素。

多因子模型的基本形式

收益分解

$$r_{i,t} = \alpha_i + \boldsymbol{\beta}_i^\top \boldsymbol{f}_t + \epsilon_{i,t}.$$

- $r_{i,t}$：资产 i 在 t 期的超额收益。
- $\boldsymbol{f}_t = (f_{1,t}, \ldots, f_{K,t})^\top$：因子收益向量。
- $\boldsymbol{\beta}_i = (\beta_{i1}, \ldots, \beta_{iK})^\top$：资产对各因子的暴露。
- α_i：模型无法解释的平均超额收益。
- $\epsilon_{i,t}$：特质收益，通常假设与因子收益不相关。

矩阵形式

将上一页每只股票的模型按行排列，得到

$$\boldsymbol{r}_t = \boldsymbol{\alpha} + B\boldsymbol{f}_t + \boldsymbol{\epsilon}_t.$$

- $\boldsymbol{r}_t \in \mathbb{R}^N$：同一期 N 只股票的超额收益。
- $B \in \mathbb{R}^{N\times K}$：第 i 行是股票 i 的因子暴露 $\boldsymbol{\beta}_i^\top$。
- $\boldsymbol{f}_t \in \mathbb{R}^K$：这一期所有股票共同面对的因子收益。
- $\boldsymbol{\alpha}$、$\boldsymbol{\epsilon}_t$：各股票的截距与这一期的残差。

说明

矩阵乘积 $B\boldsymbol{f}_t$ 的第 i 个元素为 $\sum_k \beta_{ik} f_{k,t}$，即各因子对股票 i 的收益贡献之和。这里沿用上一页在估计区间内固定的暴露 B。

多元回归的设计矩阵

固定一期 t，用 N 只股票的已知暴露估计当期因子收益：

$$r_{i,t} = a_t + \sum_{k=1}^{K} b_{ik,t} f_{k,t} + u_{i,t}.$$

将常数列并入 B_t，将截距 a_t 作为 $\boldsymbol{f}_t$ 的第一个元素：

$$\underbrace{\begin{bmatrix} r_{1,t} \\ r_{2,t} \\ \vdots \\ r_{N,t} \end{bmatrix}}_{\boldsymbol{r}_t \in \mathbb{R}^N} = \underbrace{\begin{bmatrix} 1 & b_{11,t} & \cdots & b_{1K,t} \\ 1 & b_{21,t} & \cdots & b_{2K,t} \\ \vdots & \vdots & & \vdots \\ 1 & b_{N1,t} & \cdots & b_{NK,t} \end{bmatrix}}_{B_t \in \mathbb{R}^{N \times (K+1)}} \underbrace{\begin{bmatrix} a_t \\ f_{1,t} \\ \vdots \\ f_{K,t} \end{bmatrix}}_{\boldsymbol{f}_t \in \mathbb{R}^{K+1}} + \boldsymbol{u}_t.$$

- 每行是一只股票，每列是一项暴露；常数列的暴露均为 1。
- $\boldsymbol{r}_t$ 和 B_t 是已知数据，$\boldsymbol{f}_t$ 中的 $K+1$ 个系数待估。
- 以下估计公式均含常数列；K 仍表示不含常数项的因子数量。

多元回归的最小二乘估计

在 t 期的股票横截面上，选择使残差平方和最小的因子收益：

$$\widehat{\boldsymbol{f}}_t = \arg\min_{\boldsymbol{f}_t} \|\boldsymbol{r}_t - B_t \boldsymbol{f}_t\|^2.$$

对 $\boldsymbol{f}_t$ 求导并令其为零，得到正规方程：

$$-2B_t^\top (\boldsymbol{r}_t - B_t \widehat{\boldsymbol{f}}_t) = 0 \quad \Longrightarrow \quad B_t^\top B_t \widehat{\boldsymbol{f}}_t = B_t^\top \boldsymbol{r}_t.$$

暴露矩阵满列秩时，系数解唯一

$$\widehat{\boldsymbol{f}}_t = (B_t^\top B_t)^{-1} B_t^\top \boldsymbol{r}_t.$$

满列秩要求 B_t 的各列不存在精确的线性关系。例如，全部行业虚拟变量与常数列不能同时保留。

实际计算使用 QR 或 SVD 等数值方法，无需在代码中显式求逆。

拟合值、残差与正交投影

将估计的因子收益代入模型，得到拟合收益与残差：

$$\widehat{\boldsymbol{r}}_t = B_t \widehat{\boldsymbol{f}}_t = H_t \boldsymbol{r}_t, \qquad \widehat{\boldsymbol{u}}_t = \boldsymbol{r}_t - \widehat{\boldsymbol{r}}_t,$$

$$H_t = B_t (B_t^\top B_t)^{-1} B_t^\top.$$

- B_t 的列空间由各列暴露的所有线性组合构成，拟合收益属于这个空间。
- 正规方程给出 $B_t^\top \widehat{\boldsymbol{u}}_t = 0$：残差与每一列暴露正交。
- 因此 $\widehat{\boldsymbol{r}}_t$ 是 $\boldsymbol{r}_t$ 在该列空间上的正交投影，H_t 为投影矩阵。

含截距时的两个结果

$\mathbf{1}^\top \widehat{\boldsymbol{u}}_t = 0$，即残差和为零；$\widehat{\boldsymbol{r}}_t^\top \widehat{\boldsymbol{u}}_t = 0$，即拟合收益与残差正交。

上述关系来自 OLS 正规方程。

平方和分解与拟合优度

记 $\bar{r}_t = N^{-1}\sum_i r_{i,t}$ 为当期股票的平均收益。含截距时，拟合收益的均值也等于 $\bar{r}_t$，且

$$\underbrace{\sum_i (r_{i,t}-\bar{r}_t)^2}_{SST_t:\ \text{总平方和}} = \underbrace{\sum_i (\widehat{r}_{i,t}-\bar{r}_t)^2}_{SSR_t:\ \text{回归平方和}} + \underbrace{\sum_i \widehat{u}_{i,t}^2}_{SSE_t:\ \text{残差平方和}} .$$

$$R_t^2 = 1 - \frac{SSE_t}{SST_t}, \qquad \bar{R}_t^2 = 1 - \frac{SSE_t/(N-K-1)}{SST_t/(N-1)}.$$

- R_t^2 表示当期股票收益差异被回归解释的比例，要求 $SST_t > 0$。
- 同一样本中增加暴露变量，普通 R_t^2 不下降；调整后 $\bar{R}_t^2$ 考虑参数数量，可能下降。
- N 为股票数，K 为不含截距的因子数量；调整后 $\bar{R}_t^2$ 要求 $N > K+1$。
- 比较模型时，收益口径、股票样本和截距设定应相同。
- 前面的 BP 缩放与标准化练习中，收益和残差均未改变，所以 SST_t、SSE_t 与 R_t^2 都不变。

多个特征的横截面模型

以 BP、市值等股票特征作为暴露，仍按上面的横截面模型估计：

$$r_{i,t} = a_t + \sum_{k=1}^{K} b_{ik,t} f_{k,t} + u_{i,t}, \qquad i = 1, \ldots, N.$$

- 每行是一只股票；$b_{ik,t}$ 是这只股票在第 k 个特征上的暴露。
- $f_{k,t}$ 是**控制其他特征后**，该暴露每增加一单位对应的拟合收益变化。
- 特征的单位影响系数的数值；标准化后，一单位表示一个横截面标准差。

含截距的矩阵形式

沿用前面的约定，B_t 第一列为常数列，$\boldsymbol{f}_t = (a_t, f_{1,t}, \ldots, f_{K,t})^\top$，因此

$$\boldsymbol{r}_t = B_t \boldsymbol{f}_t + \boldsymbol{u}_t.$$

a_t 表示该期截面的共同截距项。

代码练习：构造对数总市值

使用 2024 年 3 月 28 日的 BP、总市值和 3 月 29 日的收益，每行是一只股票。

读取市值并匹配股票代码

```
mv = pd.read_csv(DATA_DIR / "daily_total_mv_sh.csv",
                 index_col=0).loc[date]
log_mv = np.log(mv.where(mv > 0)).rename("log_mv")
cross = simple_cross.join(log_mv)
cross = cross.replace([np.inf, -np.inf], np.nan).dropna()
```

- `total_mv` 为总市值，单位为万元；`log_mv` 为其自然对数。
- `cross` 保留 BP、次日收益和对数市值均有效的股票。
- 一元、多元回归都使用 `cross`，以便在同一份样本上比较系数。

代码练习：BP 与总市值的多元回归

$$R_{i,t+1} = a + c_{BP} BP_{i,t} + c_{MV} \log MV_{i,t} + u_{i,t+1}.$$

在 `lab05_framework.py` 的 `L05-BP-MV` 段填写以下回归。

在相同样本上估计两个模型

```
model = smf.ols("return_next ~ bp + log_mv",
                data=cross).fit()
simple_same = smf.ols("return_next ~ bp", data=cross).fit()
print(simple_same.params)
print(model.params)
print(simple_same.rsquared_adj, model.rsquared_adj)
```

记录样本数、BP 系数、对数市值系数与调整后 R^2。

BP 与总市值回归的结果

2024 年 3 月 28 日特征与 3 月 29 日收益；两个模型使用同一批股票。

指标	BP 一元回归	BP + 对数总市值
样本数	2262	2262
BP 系数	0.0942	0.1357
对数市值系数	—	-0.1636
R^2	0.000238	0.005622
调整后 R^2	-0.000205	0.004742

$$\widehat{R}_{i,t+1} = 3.3142 + 0.1357\, BP_{i,t} - 0.1636 \log MV_{i,t} \qquad \text{(收益单位：\%)}.$$

- 市值相同时，BP 增加 1，拟合收益增加约 0.1357 个百分点。
- BP 相同时，市值增加 1%，拟合收益变化为 $-0.1636 \log(1.01) \approx -0.00163$ 个百分点。
- 加入市值后调整后 R^2 提高，但这一天收益差异的解释比例仍较低。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 实践二：构建自己的多因子模型并解释因子收益

收益归因、预期收益与风险估计

在暴露 B 固定、$\mathbb{E}[\boldsymbol{\epsilon}_t] = 0$ 的模型中：

当期收益归因

$\boldsymbol{r}_t = \boldsymbol{\alpha} + B\boldsymbol{f}_t + \boldsymbol{\epsilon}_t$。
用已经实现的因子收益解释个股当期收益，得到残差。

预期收益

$\mathbb{E}[\boldsymbol{r}_t] = \boldsymbol{\alpha} + B\mathbb{E}[\boldsymbol{f}_t]$。
对收益分解式取期望，得到个股预期收益与因子预期收益的关系。

风险估计

研究因子收益与残差的波动，构造资产协方差矩阵。
因子风险由因子收益的波动及相关性刻画。

参考：MOSEK Portfolio Optimization Cookbook, Ch. 5。

因子模型的协方差分解

从 $\boldsymbol{r}_t = \boldsymbol{\alpha} + B\boldsymbol{f}_t + \boldsymbol{\epsilon}_t$ 出发，设 B 在估计区间内固定。

- 因子协方差：$\Omega = \mathrm{Cov}(\boldsymbol{f}_t)$。
- 残差协方差：$\Delta = \mathrm{Cov}(\boldsymbol{\epsilon}_t)$。
- 假设因子与残差不相关：$\mathrm{Cov}(\boldsymbol{f}_t, \boldsymbol{\epsilon}_t) = 0$。

$$\underbrace{\Sigma}_{\text{资产协方差}} = \underbrace{B\Omega B^\top}_{\text{共同因子带来的协方差}} + \underbrace{\Delta}_{\text{剩余风险}}.$$

特质收益与特质风险

$\epsilon_{i,t}$ 是一次收益；$\mathrm{Var}(\epsilon_{i,t})$ 衡量它跨期的波动。
若进一步假设不同股票的残差互不相关，Δ 就是对角矩阵。

参考：MOSEK Portfolio Optimization Cookbook, Ch. 5。

组合收益的方差分解

将资产协方差 $\Sigma = B\Omega B^\top + \Delta$ 代入组合方差公式：

$$\mathrm{Var}(R_p) = \boldsymbol{w}^\top \Sigma \boldsymbol{w} = \boldsymbol{w}^\top B\Omega B^\top \boldsymbol{w} + \boldsymbol{w}^\top \Delta \boldsymbol{w}.$$

组合暴露是个股暴露的加权平均

记 $\boldsymbol{x}_p = B^\top \boldsymbol{w}$，则

$$\mathrm{Var}(R_p) = \underbrace{\boldsymbol{x}_p^\top \Omega \boldsymbol{x}_p}_{\text{共同因子方差}} + \underbrace{\boldsymbol{w}^\top \Delta \boldsymbol{w}}_{\text{特质方差}}.$$

- 当 Δ 为对角阵时，特质方差为 $\sum_i w_i^2 \sigma_{\epsilon_i}^2$。
- 分散持股可以降低特质方差；共同因子风险取决于组合暴露。
- 组合波动率为总方差的平方根。

协方差估计误差对组合权重的影响

GMV 的解析解直接依赖协方差矩阵的逆：

$$\widehat{\boldsymbol{w}}_{\mathrm{GMV}} = \frac{\widehat{\boldsymbol{\Sigma}}^{-1}\mathbf{1}}{\mathbf{1}^{\top}\widehat{\boldsymbol{\Sigma}}^{-1}\mathbf{1}}.$$

若样本协方差矩阵的特征分解为

$$\widehat{\boldsymbol{\Sigma}} = Q\,\mathrm{diag}(\widehat{\lambda}_1,\ldots,\widehat{\lambda}_N)Q^{\top}, \qquad \widehat{\boldsymbol{\Sigma}}^{-1} = Q\,\mathrm{diag}\left(\frac{1}{\widehat{\lambda}_1},\ldots,\frac{1}{\widehat{\lambda}_N}\right)Q^{\top},$$

则估计得过小的特征值会在求逆时被放大。

- 当资产数 N 接近样本数 T 时，小特征值的估计可能很不稳定；$N \geq T$ 时样本协方差必然奇异。
- 因此，估计窗口略有变化就可能导致权重大幅变化，甚至出现极端多空头寸。

数值求解与统计估计

数值优化即使没有显式计算 $\widehat{\boldsymbol{\Sigma}}^{-1}$，也不会自动消除这种统计敏感性。

提高组合稳定性的常用方法

改进风险估计

- **收缩估计**：把样本协方差向单位矩阵、常相关矩阵等结构目标收缩。
- **因子模型**：用少数共同因子加结构化特质风险替代完全自由的协方差矩阵。
- **稀疏估计**：对协方差或精度矩阵施加阈值、Graphical Lasso 等结构。
- **稳健估计**：降低异常值、厚尾和市场状态变化的影响。

约束组合权重

- 禁止卖空、设置个股权重和总杠杆上限。
- 对权重范数、相对基准偏离和换手率加入惩罚。
- 在参数不确定集合中做稳健或分布鲁棒优化。
- 始终与等权、波动率倒数和风险平价等简单基准比较。

作用

这些方法通过调整协方差估计或限制组合权重，降低估计误差对组合的影响。

因子模型需要估计多少参数?

对 N 只股票，直接估计协方差需要 $N(N+1)/2$ 个参数。因子模型采用 $\Sigma = B\Omega B^\top + \Delta$，并假设 Δ 为对角阵。

估计对象	参数数量	$N = 100,\ K = 3$
暴露矩阵 B	NK	300
因子协方差 Ω	$K(K+1)/2$	6
特质方差 Δ	N	100
合计	$NK + K(K+1)/2 + N$	406

- 前面的例子：100 只股票直接估计需 5050 个参数，因子表示只需 406 个。
- 若暴露由股票特征给定，则还需估计的是因子协方差和特质方差。

参考：MOSEK Portfolio Optimization Cookbook, Ch. 5。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 实践二：构建自己的多因子模型并解释因子收益

实践一：选出低 PB、小市值股票

每个月末按 PB 和总市值评分，选出 20 只股票，等权持有一个月。

- 股票池：上证日线宽表的前 300 只股票；每期保留非 ST、有成交、PB 与总市值为正的股票。
- 特征：月末 PB 与总市值（`total_mv_sh.csv`）；PB 越低、市值越小，得分越高。
- 调仓：每月重新评分、重新选股，将入选股票的权重恢复为 $1/20$。
- 收益区间：2020 年 1 月至 2025 年 12 月；首次建仓为 2019 年 12 月末。

评分规则

$$score_{i,t} = rank_{\text{desc}}(PB_{i,t}) + rank_{\text{desc}}(MC_{i,t}).$$

降序排名把最大值排第 1 名，因此低 PB、小市值获得更大的名次。MC 表示总市值。

两项特征的单位不同，先分别排名再相加，赋予两项排名相同权重。

L05-00：计算评分并选出 20 只股票

运行第 0 段和 L05-00 的数据准备部分，得到月末股票池 `pool`。先以 2021 年 12 月末为例，观察哪些股票入选。

```
month = pool.loc[pool['date'] == '2021-12-31'].copy()

month['score'] = (month['pb'].rank(ascending=False)
                  + month['total_mv'].rank(ascending=False))
selected = month.nlargest(20, 'score')
print(selected[['code', 'pb', 'total_mv', 'score']])
```

观察入选股票

对比入选股票与当月股票池的 PB、市值，观察综合排名如何决定持仓。

从单月选股到逐月调仓

t 月末选股，持有到 $t+1$ 月末，再用新的特征确定下一期持仓。

$$R_{p,t+1} = \frac{1}{20} \sum_{i \in S_t} r_{i,t+1}, \qquad V_{t+1} = V_t(1 + R_{p,t+1}), \quad V_0 = 1.$$

- S_t 是 t 月末选出的 20 只股票，$r_{i,t+1}$ 是其下一月持有期收益。
- 同时计算三个组合：评分最高 20 只、总市值最小 20 只、当月股票池全部股票；均按月恢复等权。
- 记录新进入和退出持仓的股票数量，以及恢复等权所需的权重调整。

回测约定

按月末收盘价调仓，不计交易费用。收益用复权价格计算；月末无报价时按最近交易日价格估值。这只是一种简化估值，停牌、退市时不保证能按该价格卖出。

L05-00A：逐月选股并计算组合收益

按日期分组，每次循环完成一个月的选股。收益记录在下一个月末。

```
return_rows, holding_rows, change_rows = [], [], []
previous = set()
for date, g in pool.groupby('date'):
    g = g.copy()
    g['score'] = (g['pb'].rank(ascending=False)
                  + g['total_mv'].rank(ascending=False))
    chosen = g.nlargest(20, 'score').copy()
    small = g.nsmallest(20, 'total_mv')
    end = dates[dates.get_loc(date) + 1]
    return_rows.append({'date': end,
        '低PB十小市值': chosen['next_ret'].mean(skipna=False),
        '仅小市值': small['next_ret'].mean(skipna=False),
        '股票池等权': g['next_ret'].mean(skipna=False)})
```

下一页继续记录本次选股的持仓，前几行仍在同一个循环内。

L05-00A：记录持仓与调仓数量（续）

集合之差给出本月新入选和不再入选的股票。

```
    chosen['weight'] = 1 / len(chosen)
    chosen['return_end'] = end
    holding_rows.append(chosen)
    current = set(chosen['code'])
    change_rows.append({'date': date,
        '买入数量': len(current - previous),
        '卖出数量': len(previous - current)})
    previous = current
strategy_returns = pd.DataFrame(return_rows).set_index('date')
holdings = pd.concat(holding_rows, ignore_index=True)
changes = pd.DataFrame(change_rows).set_index('date')
```

- `holdings` 保存每月股票名单和目标权重；`changes` 保存进入、退出持仓的数量。
- 初次建仓买入 20 只；后续每月的买入、卖出数量不包括留存股票的权重调整。

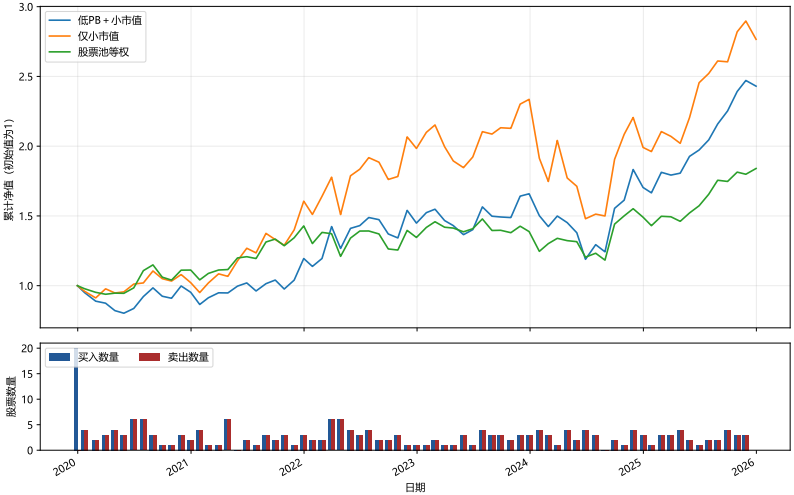
L05-00B：计算净值和回撤

月收益连乘得到净值；净值相对历史最高点的跌幅就是回撤。

```
nav = (1 + strategy_returns).cumprod(skipna=False)
nav.loc[dates[0]] = 1.0
nav = nav.sort_index()
drawdown = nav / nav.cummax() - 1
performance = pd.DataFrame({
    '累计收益': nav.iloc[-1] - 1,
    '年化收益': nav.iloc[-1] ** (12 / len(strategy_returns)) - 1,
    '年化波动率': strategy_returns.std() * np.sqrt(12),
    '最大回撤': drawdown.min()
})
```

年化收益按复利折算；年化波动率由月收益标准差乘 $\sqrt{12}$ 得到。最大回撤以负数表示，越接近零，历史跌幅越小。

实践一：净值与持仓调整



上图为按月恢复等权的累计净值；下图为评分组合每月新进入、退出的股票数量。

实践一：如何比较三个组合？

2020 年 1 月至 2025 年 12 月，共 72 个月，未扣除交易费用。

组合	累计收益	年化收益	年化波动率	最大回撤
低 PB ＋小市值	143.01%	15.95%	25.15%	−28.33%
仅小市值	176.60%	18.48%	27.97%	−36.65%
股票池等权	84.01%	10.70%	19.11%	−19.98%

- 在这段样本中，加入 PB 排名后，收益、波动和最大回撤都发生了变化。
- 比较两个选股组合：收益降低的同时，波动和回撤是否也减小了？
- 比较股票池等权组合：较高收益是否伴随着较高风险？
- 若计入交易费用，还需要知道哪些信息？仅有买入、卖出的股票数量够不够？

低 PB、小市值策略的收益如何解释?

实践结果

在本次回测中，低 PB、小市值组合的收益高于股票池等权组合，但波动和最大回撤幅度也更大。

进一步思考

收益较高，是否与组合承担了不同的共同风险有关?

我们观察到的表现，是这批股票的偶然结果，还是与规模、价值特征有关的普遍现象?

Fama 和 French 从类似的经验现象出发，将规模、价值与市场共同纳入因子模型，研究它们能否解释股票之间的收益差异。

下面从策略的回测表现，进一步讨论收益的因子解释。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 实践二：构建自己的多因子模型并解释因子收益

从 CAPM 到 Fama–French 三因子模型

CAPM 用市场 Beta 解释预期超额收益，但样本中的平均收益差异并不总能由市场 Beta 充分解释。

Eugene F. Fama 与 Kenneth R. French

- **1992 年**：研究股票横截面的平均收益，发现市值和账面市值比具有市场 Beta 难以充分解释的信息。
- **1993 年**：构造与规模、账面市值比有关的组合收益，和市场超额收益一起形成股票三因子模型。

研究的问题是：加入规模和价值的共同收益变化后，能否更好地解释股票组合的收益，以及不同组合的平均收益差异？

Fama & French (1992), *The Cross-Section of Expected Stock Returns*, *Journal of Finance*, 47(2), 427–465.

Fama & French (1993), *Common Risk Factors in the Returns on Stocks and Bonds*, *Journal of Financial Economics*, 33(1), 3–56.

三因子模型是什么?

对股票或股票组合 i，用三种共同收益变化解释其超额收益：

$$\underbrace{R_{i,t} - R_{f,t}}_{\text{股票超额收益}} = \alpha_i + \beta_{i,MKT} MKT_t + \beta_{i,SMB} SMB_t + \beta_{i,HML} HML_t + \epsilon_{i,t}.$$

因子收益	含义
$MKT_t = R_{m,t} - R_{f,t}$	市场组合收益减去无风险收益
SMB_t (Small Minus Big)	小市值组合相对大市值组合的收益
HML_t (High Minus Low)	高 BP 组合相对低 BP 组合的收益

- 三个因子都是随时间变化的**收益序列**；$\beta_{i,MKT}$、$\beta_{i,SMB}$、$\beta_{i,HML}$ 是股票的暴露。
- α_i 是回归截距；$\epsilon_{i,t}$ 是第 t 期仍未解释的残差。

从股票特征到因子收益

市值和 BP 描述股票的特征。模型还需要刻画：具有这些特征的股票，在某一期是否出现了共同的收益变化。

1. **提取共同变化。**汇总多只股票，可以减弱个别公司事件的影响，更清楚地观察规模、价值风格的表现。
2. **用收益差刻画风格差异。**小市值组合减去大市值组合、高 BP 组合减去低 BP 组合，分别衡量小盘相对大盘、价值相对成长的表现。
3. **把特征转化为收益。**将具有相似特征的股票组成组合，用组合收益观察该类股票的整体表现。

构造因子：先按市值和 BP 交叉分组

按市值分为小、大两组，按 BP 分为低、中、高三组，交叉得到六个组合：

	低 BP（L，成长）	中 BP（M）	高 BP（H，价值）
小市值（S）	S/L	S/M	S/H
大市值（B）	B/L	B/M	B/H

$R_{S/H,t}$ 表示小市值、高 BP 组合在 t 月的收益，各组内按市值加权。

$$SMB_t = \frac{R_{S/L,t} + R_{S/M,t} + R_{S/H,t}}{3} - \frac{R_{B/L,t} + R_{B/M,t} + R_{B/H,t}}{3},$$

$$HML_t = \frac{R_{S/H,t} + R_{B/H,t}}{2} - \frac{R_{S/L,t} + R_{B/L,t}}{2}.$$

SMB：三类 BP 组合等权平均后，小市值减大市值。
HML：两类市值组合等权平均后，高 BP 减低 BP。

参考：Kenneth French Data Library: Fama/French Factors。

例：计算一个月的 SMB 和 HML

假设某月六个组合的收益如下：

某月收益	低 BP	中 BP	高 BP
小市值	1%	2%	3%
大市值	0%	1%	2%

例：计算一个月的 SMB 和 HML

假设某月六个组合的收益如下：

某月收益	低 BP	中 BP	高 BP
小市值	1%	2%	3%
大市值	0%	1%	2%

规模因子：小市值减大市值

$$SMB = \underbrace{\frac{1\% + 2\% + 3\%}{3}}_{\text{小市值：}2\%} - \underbrace{\frac{0\% + 1\% + 2\%}{3}}_{\text{大市值：}1\%} = 1\%.$$

例：计算一个月的 SMB 和 HML

假设某月六个组合的收益如下：

某月收益	低 BP	中 BP	高 BP
小市值	1%	2%	3%
大市值	0%	1%	2%

规模因子：小市值减大市值

$$SMB = \underbrace{\frac{1\% + 2\% + 3\%}{3}}_{\text{小市值：}2\%} - \underbrace{\frac{0\% + 1\% + 2\%}{3}}_{\text{大市值：}1\%} = 1\%.$$

价值因子：高 BP 减低 BP

$$HML = \underbrace{\frac{3\% + 2\%}{2}}_{\text{高 BP：}2.5\%} - \underbrace{\frac{1\% + 0\%}{2}}_{\text{低 BP：}0.5\%} = 2\%.$$

估计暴露：对一只股票做时间序列回归

固定股票 i，每行是一个月；股票超额收益和三项因子收益都已知。

月份	股票超额收益	MKT	SMB	HML
1	$R_{i,1} - R_{f,1}$	MKT_1	SMB_1	HML_1
2	$R_{i,2} - R_{f,2}$	MKT_2	SMB_2	HML_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
T	$R_{i,T} - R_{f,T}$	MKT_T	SMB_T	HML_T

用 OLS 估计截距与三个暴露系数。例如，估计结果为

$$\widehat{\beta}_{i,MKT} = 1.2, \qquad \widehat{\beta}_{i,SMB} = 0.5, \qquad \widehat{\beta}_{i,HML} = -0.3.$$

若某月 $MKT = 2\%$、$SMB = 1\%$、$HML = 2\%$，三项因子的合计贡献为

$$1.2 \times 2\% + 0.5 \times 1\% - 0.3 \times 2\% = 2.3\%.$$

- 负的 HML 暴露：控制另外两项因子后，股票收益随 HML 反向变化。
- 拟合超额收益还要加上 $\widehat{\alpha}_i$；实际超额收益还包含残差。

从三因子到五因子和更多因子

- 后续 Fama-French 五因子加入盈利能力和投资风格因子。
- 动量因子常被单独加入形成四因子或扩展模型。
- 不同市场、不同样本期、不同资产类别中的因子表现可能不同。
- 新增因子后，应检查其是否提供额外解释，以及结论在其他样本中是否成立。

与本讲实验的区别

三因子回归先构造因子收益，再估计个股暴露。本讲的 BP、市值实验先由股票特征构造暴露，再估计各月的因子收益。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 实践二：构建自己的多因子模型并解释因子收益

APT 的背景：用无套利约束预期收益

- **CAPM：**用市场 Beta 解释预期超额收益，风险补偿由市场风险溢价决定。
- **Fama–French 三因子模型：**在市场因子之外加入规模、价值因子，解释股票之间的收益差异。

APT 要回答什么？

资产对多个共同因子的暴露，与其预期收益应满足怎样的定价关系？

Ross（1976）提出套利定价理论（Arbitrage Pricing Theory, APT），从共同因子结构、充分分散和无套利条件出发研究这一关系。

什么是无套利假设？

套利交易同时满足三个条件：

1. **初始无需净投入：**例如，买入支出由卖空收入抵消。
2. **未来不会亏损：**在所有可能情形下，结算后的净收益都不为负。
3. **存在获利机会：**至少有正的概率获得严格为正的净收益。

无套利假设认为：市场中不存在同时满足上述三个条件的交易机会。

Ross, S. A. (1976). *The Arbitrage Theory of Capital Asset Pricing*. *Journal of Economic Theory*, 13(3), 341–360.

APT 的收益结构

$R_{i,t}$ 为资产收益，R_f 为固定的无风险利率，$\mu_i = \mathbb{E}[R_{i,t}]$ 为预期收益。

因子冲击 $F_{k,t}$：第 k 个因子在 t 期的实现值 $f_{k,t}$ 相对其期望的偏离：

$$F_{k,t} = f_{k,t} - \mathbb{E}[f_{k,t}], \qquad \mathbb{E}[F_{k,t}] = 0.$$

资产收益由预期收益、因子冲击与特质收益组成：

$$R_{i,t} = \mu_i + \sum_{k=1}^{K} \beta_{i,k} F_{k,t} + \epsilon_{i,t}.$$

- $\beta_{i,k}$：资产 i 对第 k 个因子冲击的敏感度，即因子暴露。
- $\epsilon_{i,t}$：均值为零的特质收益，其影响可通过充分分散降低。

进一步的问题：哪些预期收益与无套利相容？

在特质风险可以忽略时，若两个组合的因子暴露相同而预期收益不同，等额买入高收益组合、卖空低收益组合，就会留下无风险的收益差。

参考：Ross (1976), The Arbitrage Theory of Capital Asset Pricing。

为什么有定价约束：比较相同暴露的组合

假设以下三个组合都已充分分散，特质风险可以忽略；收益均采用年化口径。

组合	因子 1 暴露 $\beta_{p,1}$	因子 2 暴露 $\beta_{p,2}$	预期收益 μ_p
A	1	0	6%
B	0	1	5%
C	0.5	0.5	6.5%

用 A、B 各一半构造组合 D

D 的暴露为 $(\beta_{D,1}, \beta_{D,2}) = (0.5, 0.5)$，预期收益为

$$\mu_D = 0.5\mu_A + 0.5\mu_B = 0.5 \times 6\% + 0.5 \times 5\% = 5.5\%.$$

- 做多 1 元 C，同时分别做空 0.5 元 A、B：净初始投入为零，两项共同因子暴露均抵消。
- 若特质风险可忽略，每 1 元多头名义本金对应的预期盈利为 $\mu_C - \mu_D = 6.5\% - 5.5\% = 1\%$。
- 无套利要求消除这种收益差异：相同因子暴露的充分分散组合应有相同预期收益。

APT：构造相同暴露的组合

忽略特质风险，假设可构造 K 个组合 Q_k：每个组合只对第 k 个因子具有单位暴露。

定义每单位暴露的风险溢价

风险溢价 λ_k：承担一单位第 k 个因子暴露所对应的预期超额收益。组合 Q_k 仅承担这项单位暴露，因此

$$\lambda_k = \mathbb{E}[R_{Q_k,t}] - R_f, \qquad R_{Q_k,t} = R_f + \lambda_k + F_{k,t}.$$

复制资产 i 的因子暴露

在各个组合 Q_k 上配置权重 $\beta_{i,k}$，其余权重 $1 - \sum_k \beta_{i,k}$ 配置无风险资产，得到组合 P：

$$\begin{aligned} R_{P,t} &= \left(1 - \sum_{k=1}^{K} \beta_{i,k}\right) R_f + \sum_{k=1}^{K} \beta_{i,k} R_{Q_k,t} \\ &= R_f + \sum_{k=1}^{K} \beta_{i,k}\lambda_k + \sum_{k=1}^{K} \beta_{i,k} F_{k,t}. \end{aligned}$$

组合 P 对各因子的暴露与资产 i 相同，权重之和为 1。

APT：无套利要求收益差为零

资产 i 与组合 P 的收益分别为

$$R_{i,t} = \mu_i + \sum_{k=1}^{K} \beta_{i,k} F_{k,t},$$

$$R_{P,t} = R_f + \sum_{k=1}^{K} \beta_{i,k} \lambda_k + \sum_{k=1}^{K} \beta_{i,k} F_{k,t}.$$

等额买入资产 i、卖空组合 P：初始净投入为零，因子冲击项抵消，留下

$$R_{i,t} - R_{P,t} = \mu_i - R_f - \sum_{k=1}^{K} \beta_{i,k} \lambda_k.$$

用无套利确定预期收益

收益差为正时，做多 i、做空 P；为负时，反向交易。无套利要求该确定的收益差为零，因此

$$\boxed{\mu_i = R_f + \sum_{k=1}^{K} \beta_{i,k} \lambda_k.}$$

存在特质风险时，在充分分散等条件下采用近似形式：$\mu_i \approx R_f + \sum_k \beta_{i,k} \lambda_k$。

APT 的一种实证估计方法

给定一组可观测因子，按同一频率和样本期估计 $\beta_{i,k}$、μ_i 与 λ_k：

1. **准备因子冲击。**将因子序列去均值，得到 $F_{k,t}$。
2. **估计暴露。**对每只资产做时间序列回归，用 $F_{k,t}$ 解释 $R_{i,t}$，保留截距并估计斜率 $\widehat{\beta}_{i,k}$。
3. **估计平均收益。**用样本平均收益估计 μ_i：

$$\overline{R}_i = \frac{1}{T}\sum_{t=1}^{T} R_{i,t}.$$

4. **估计风险溢价。**在资产横截面上，用平均超额收益对估计暴露回归：

$$\overline{R}_i - R_f \approx \sum_{k=1}^{K} \widehat{\beta}_{i,k}\widehat{\lambda}_k.$$

将估计值代入定价式，考察未解释的平均收益和样本外表现。

应用 APT：由暴露计算预期收益

沿用同一定价关系：

$$\mu_i \approx R_f + \sum_{k=1}^{K} \beta_{i,k}\lambda_k.$$

- $\beta_{i,k}$：资产对第 k 个因子的暴露。
- λ_k：每单位该因子暴露对应的风险溢价。
- μ_i、R_f 与 λ_k 使用相同的期间口径。

两因子数值例子：均采用年收益口径

无风险利率 $R_f = 2\%$；风险溢价 $\lambda_1 = 4\%$、$\lambda_2 = 3\%$；股票暴露 $\beta_{i,1} = 1.2$、$\beta_{i,2} = 0.5$。

$$\mu_i \approx 2\% + 1.2 \times 4\% + 0.5 \times 3\% = 8.3\%.$$

该股票的预期年收益为 8.3%；当期实际收益 $R_{i,t}$ 还随因子冲击和特质收益变化。

参考：CFA Institute, Using Multifactor Models。

风险溢价与当期因子收益的区别

	风险溢价 λ_k	因子冲击 $F_{k,t}$
含义	每单位因子暴露的预期收益补偿	该因子在 t 期的意外变化
时间特征	给定定价期间的预期量	随各期实现情况变化，均值为零
在模型中	决定预期收益 μ_i	使实际收益 $R_{i,t}$ 偏离预期

与前文因子收益 $f_{k,t}$ 的对应

对按单位暴露归一化、以预期超额收益刻画风险溢价的可交易因子：

$$\underbrace{f_{k,t}}_{\text{当期因子收益}} = \underbrace{\lambda_k}_{\text{预期补偿}} + \underbrace{F_{k,t}}_{\text{意外变化}}, \qquad \mathbb{E}[F_{k,t}] = 0.$$

例如，$\lambda_k = 4\%$，当期冲击 $F_{k,t} = 6\%$，则当期因子收益 $f_{k,t} = 10\%$。

模型比较

维度	CAPM	FF3	APT
出发点	投资者的均值–方差选择与市场均衡	规模、价值等特征对应的收益差异	共同因子结构、充分分散与无套利
因子设定	市场超额收益	市场超额收益、SMB、HML	一个或多个共同因子，具体选择由研究问题确定
暴露含义	对市场收益的敏感度	对市场、规模、价值因子收益的敏感度	对各共同因子变化的敏感度
预期收益	市场 Beta 乘以市场风险溢价，得到预期超额收益	用三项暴露与因子预期收益解释平均超额收益，考察剩余 Alpha	无套利约束预期超额收益近似等于各项暴露与风险溢价乘积之和
模型作用	给出市场风险的均衡定价基准	提供具有具体因子的实证解释模型	给出多因子预期收益的理论定价约束

Barra：持仓等权，风险也分散了吗？

两个组合都持有两只股票，每只各占资金的 50%，但股票的风格不同：

组合	持仓及资金权重	价值风格构成
甲	A：50%，B：50%	A 偏价值，B 偏成长
乙	A：50%，C：50%	A、C 都偏价值

当价值风格走弱时

甲中两只股票的价值风格影响可以部分抵消；乙中两只股票可能同时承压。持股数量与资金权重相同，共同风险仍可能不同。

Barra 类模型解决的问题：用市场、行业和风格识别共同风险，预测当前持仓的风险。

下面沿用这两个组合，考察规模和价值暴露如何影响风险。

参考：MOSEK, Portfolio Optimization Cookbook, Ch. 5。持仓与数值均为假设例子。

用因子暴露描述持仓

下表给出同一月末三只股票的规模、价值暴露，两个组合均保持等权：

股票	规模暴露	价值暴露	甲的权重	乙的权重
A	1	1	0.5	0.5
B	0	−1	0.5	0
C	0	1	0	0.5

规模、价值暴露分别由标准化的对数市值、BP 构造；正的价值暴露表示偏价值，负值表示偏成长。

组合暴露是个股暴露的加权平均

按（规模，价值）排列组合暴露 $\boldsymbol{x}$：

$$\boldsymbol{x}_{\text{甲}} = 0.5(1,1)^\top + 0.5(0,-1)^\top = (0.5,0)^\top,$$
$$\boldsymbol{x}_{\text{乙}} = 0.5(1,1)^\top + 0.5(0,1)^\top = (0.5,1)^\top.$$

两组规模暴露相同；甲的价值暴露相抵，乙的价值暴露叠加。

从股票收益中估计因子收益

t 月末的股票特征给出暴露矩阵 B_t，每行是一只股票，每列是一个因子。

下月收益实现后，做一次股票横截面回归

$$\underbrace{\boldsymbol{r}_{t+1}}_{\text{股票收益}} = \underbrace{B_t}_{\text{已知暴露}} \underbrace{\boldsymbol{f}_{t+1}}_{\text{因子收益}} + \underbrace{\boldsymbol{u}_{t+1}}_{\text{个股残差}}.$$

- **输入**：月末暴露 B_t 与随后一个月的股票收益 $\boldsymbol{r}_{t+1}$。
- **估计**：同一月份的一组因子收益 $\widehat{\boldsymbol{f}}_{t+1}$。
- **剩余部分**：各股票残差 $\widehat{\boldsymbol{u}}_{t+1} = \boldsymbol{r}_{t+1} - B_t\widehat{\boldsymbol{f}}_{t+1}$。

逐月重复，得到规模、价值因子收益的历史序列，以及每只股票的残差序列。

从因子收益到风险预测

在 t 月末，利用截至当时已实现的因子收益和个股残差估计风险：

$$\widehat{\Omega}_t = \widehat{\mathrm{Cov}}(\widehat{\boldsymbol{f}}_s : \ s \le t), \quad \text{因子收益的协方差,}$$
$$\widehat{d}_{i,t} = \widehat{\mathrm{Var}}(\widehat{u}_{i,s} : \ s \le t), \quad \text{股票}i\text{ 的特质方差.}$$

- $\widehat{\Omega}_t$ 描述规模、价值等因子的波动及其共同变化。
- 将各股票的特质方差组成对角矩阵：$\widehat{\Delta}_t = \mathrm{diag}(\widehat{d}_{1,t}, \ldots, \widehat{d}_{N,t})$。
- 采用因子与特质收益不相关、各股票特质收益互不相关的结构。

用当前暴露预测下月股票收益的协方差

$$\widehat{\Sigma}_t = \underbrace{B_t \widehat{\Omega}_t B_t^\top}_{\text{共同因子带来的协方差}} + \underbrace{\widehat{\Delta}_t}_{\text{个股特质方差}} .$$

参考：MOSEK, Portfolio Optimization Cookbook, Sec. 5.2。

风险模型怎样计算组合风险?

给定 t 月末的持仓权重 $\boldsymbol{w}_t$，先汇总组合的因子暴露：

$$\boldsymbol{x}_t = B_t^\top \boldsymbol{w}_t.$$

再用因子协方差与个股特质方差计算下月风险：

$$\widehat{\sigma}_{p,t}^2 = \boldsymbol{w}_t^\top \widehat{\Sigma}_t \boldsymbol{w}_t = \underbrace{\boldsymbol{x}_t^\top \widehat{\Omega}_t \boldsymbol{x}_t}_{\text{共同风险}} + \underbrace{\sum_i w_{i,t}^2 \widehat{d}_{i,t}}_{\text{特质风险}}.$$

回到两个等权组合

甲的暴露为 $(0.5, 0)^\top$，乙为 $(0.5, 1)^\top$。风险差异取决于这两组暴露与因子协方差，以及各持仓的特质方差。

- 共同风险：股票的暴露先加总，再结合因子的波动与相关性计算。
- 特质风险：在残差互不相关的结构下，个股方差按权重平方加总。
- 组合波动率为总方差的平方根。

比较两个等权组合的风险

统一采用年化口径：规模、价值因子的波动率分别为 20%、10%，两因子不相关。各股票的特质波动率均为 30%，特质收益彼此不相关且与因子不相关。

$$\sigma_p^2 = \underbrace{x_{\text{规模}}^2 \times 0.04 + x_{\text{价值}}^2 \times 0.01}_{\text{共同风险}} + \underbrace{\sum_i w_i^2 \times 0.09}_{\text{特质风险}}.$$

风险组成	甲：$\boldsymbol{x} = (0.5, 0)^\top$	乙：$\boldsymbol{x} = (0.5, 1)^\top$
规模因子方差	$0.5^2 \times 0.04 = 0.010$	0.010
价值因子方差	0	$1^2 \times 0.01 = 0.010$
特质方差	$(0.5^2 + 0.5^2) \times 0.09 = 0.045$	0.045
总方差	0.055	0.065
年化波动率	$\sqrt{0.055} \approx 23.45\%$	$\sqrt{0.065} \approx 25.50\%$

解释开头的现象：两组特质方差相同，乙集中承担价值风险，增加了 0.010 的共同方差。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 实践二：构建自己的多因子模型并解释因子收益

实践二：构建自己的多因子模型

自选公司特征作为因子，构建多因子模型，并解释估计的因子收益。

1. 选择因子，说明选择理由，计算各股票月末的因子暴露并按月标准化。
2. 用月末暴露解释下一月收益，逐月做横截面回归：

$$r_{i,t+1} = a_{t+1} + \sum_{k=1}^{K} z_{i,k,t} f_{k,t+1} + u_{i,t+1}.$$

   $z_{i,k,t}$ 为标准化暴露，回归系数 $f_{k,t+1}$ 为当月因子收益。
3. 绘制各因子收益曲线，解释系数的含义及跨月表现。
4. 用实践一的组合持仓，将组合收益分解为截距项、各因子贡献和残差部分。

示例代码沿用实践一的 BP 和市值，演示上述步骤。

`code/lab05/lab05_practice2_example.py`

实践二：报告内容

1. **模型设定：**所选因子、选择理由、暴露的计算方法及回归方程。
2. **单月回归与解释：**截距、各因子系数及调整后 R^2；解释控制其他暴露后，某项暴露增加 1 对应的拟合收益变化。
3. **跨月结果：**各因子收益曲线，以及平均系数、标准差和正值月份比例。
4. **组合收益分解：**截距项、各因子贡献、残差部分与实际收益。

提交自己的模型代码和上述结果。