多因子模型：Fama-French、APT 与 Barra 框架

肖亮海

信息科学技术学院

课程 GitHub：`github.com/styluck/quant`

CAPM 的预期收益关系

第三讲的资本资产定价模型（CAPM）给出风险与预期收益的关系：

$$\mathbb{E}[R_i] - r_f = \beta_i \big(\mathbb{E}[R_M] - r_f\big), \qquad \beta_i = \frac{\mathrm{Cov}(R_i, R_M)}{\mathrm{Var}(R_M)}.$$

- R_i、R_M 分别为股票与市场组合收益，r_f 为无风险利率。
- 市场 Beta 衡量股票对市场波动的敏感度，即承担的市场风险。
- 在模型假设下，预期超额收益由市场 Beta 与市场风险溢价决定。
- 可分散的特质风险不获得风险补偿；定价关系体现在证券市场线（SML）上。

证券市场线的含义

证券市场线的斜率为市场风险溢价；Beta 每增加一单位，模型给出的预期超额收益增加一个市场风险溢价。

均值—方差组合优化

第四讲的现代投资组合理论（MPT）用均值与方差描述组合：

$$\mu_p = \boldsymbol{w}^\top \boldsymbol{\mu}, \qquad \sigma_p^2 = \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}.$$

- $\boldsymbol{w}$ 为资产权重，$\boldsymbol{\mu}$ 为预期收益向量，$\boldsymbol{\Sigma}$ 为收益协方差矩阵。
- 分散化效果取决于资产之间的协方差，不只是每只股票自身的波动。

给定目标收益率，寻找风险最低的组合

$$\min_{\boldsymbol{w}} \ \boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w}, \qquad \text{s.t. } \boldsymbol{w}^\top \boldsymbol{\mu} = \mu_0, \quad \mathbf{1}^\top \boldsymbol{w} = 1.$$

改变目标收益率 μ_0，得到组合前沿及其有效部分。

优化所需的预期收益和协方差未知，实际计算时需要先用数据估计。

市场 Beta 未能解释的收益差异

CAPM 的预测与实证检验

CAPM 预测：市场 Beta 相同的股票，应具有相同的预期超额收益。但在实证中，单靠市场 Beta 往往不能充分解释股票之间的平均收益差异。

- 规模、价值等股票特征，可能对应市场 Beta 之外的平均收益差异。
- 用市场因子回归个股收益时，残差也可能包含遗漏的共同因素。
- **预期收益的定价检验**与**当期收益波动的解释**是两个问题；回归拟合程度不能替代定价检验。

增加解释变量

可以在市场因子之外加入规模、价值等因素，检验它们是否解释了额外的收益差异。

组合优化中的参数估计误差

实际优化使用估计值 $\widehat{\mu}$ 与 $\widehat{\Sigma}$，而真实参数未知。

- **预期收益难估计：**样本平均收益含有噪声，换一个样本窗口，估计结果可能明显变化。
- **协方差参数多：**N 只股票需要估计 $N(N+1)/2$ 个不同的协方差矩阵元素；100 只股票对应 5050 个。
- **优化会放大误差：**微小的输入变化可能带来较大的权重变化，尤其在资产高度相关、约束较少时。
- 样本内的最优组合，可能出现权重集中、频繁调仓或样本外表现下降。

协方差的因子表示

若股票间的共同波动主要来自少数因素，就可以先估计这些因素的协方差，再据此计算股票收益的协方差。

多因子模型的基本思路

股票收益既受市场和行业等共同因素影响，也包含公司自身的变化。因子模型将这两部分分开表示：

$$\text{股票收益} = \text{共同因素解释的收益} + \text{个股剩余收益}.$$

- 每只股票对共同因素的反应程度可以不同，这种差别用因子暴露表示。
- 增加市场以外的因素，可以考察规模、价值等特征是否解释了额外的收益差异。
- 多只股票受同一组因素影响，因此可以用因子收益的协方差描述股票之间的共同波动。

本讲的模型

Fama–French 用市场、规模和价值因子解释收益；APT 讨论暴露与预期收益的关系；Barra 类模型用股票特征估计协方差和组合风险。

本讲目标

- 用具体例子区分因子、因子暴露、因子收益和特质收益。
- 看懂回归数据的每一行，判断系数估计的是暴露还是因子收益。
- 从单因子推广到多因子，区分当期收益、预期收益和风险。
- 理解因子结构如何帮助估计协方差、分解组合风险。
- 比较 Fama–French、APT 与 Barra 的问题和方法。
- 用 BP、市值和下一月收益完成横截面回归实践。

四个核心概念

因子模型用共同因素解释收益的相关性，用不同的暴露描述个股反应的差异。

概念	含义	以市场因子为例
因子	解释多只股票收益变化的共同因素，如市场、行业、规模、价值	市场涨跌会影响多只股票
因子暴露	一只股票对该因子的敏感度，或在该特征上的取值	市场 Beta 为 1.2，表示对市场的敏感度
因子收益	该因子在某一期、每单位暴露对应的收益	本月市场超额收益为 2%
特质收益	扣除模型解释部分后，某只股票本期剩余的收益	实际收益减去模型解释的收益

因子对个股收益的贡献

某因子对个股的收益贡献 = **该股的因子暴露** × **当期因子收益。**

例：市场因子与个股收益

只考虑市场这一个因子，暂设截距为零；股票和市场收益均指超额收益。

$$\underbrace{r_{i,t}}_{\text{股票本月收益}} = \underbrace{\beta_i}_{\text{因子暴露}} \times \underbrace{f_t}_{\text{因子收益}} + \underbrace{\epsilon_{i,t}}_{\text{特质收益}} .$$

已知：股票 Beta 为 1.2，市场本月收益为 2%，股票实际收益为 3%

市场因子解释的收益：$1.2 \times 2\% = 2.4\%$。

特质收益：$3\% - 2.4\% = 0.6\%$，即模型本月未解释的部分。

- 1.2 是股票对市场的敏感度，2% 是本月市场收益；市场下跌时，因子收益为负。
- Beta 可用这只股票与市场在多个月份的收益数据回归估计。
- 0.6% 只是本月残差，可能包含公司事件、遗漏因素和噪声。

例：用行业归属定义暴露

固定月份 t，假设市场上只有银行、科技两个行业，用行业分类解释超额收益。

股票	银行暴露	科技暴露	本月收益
银行甲	1	0	4%
银行乙	1	0	2%
科技甲	0	1	0%
科技乙	0	1	-2%

$$r_{i,t} = b_{i,\text{银行}} f_{\text{银行},t} + b_{i,\text{科技}} f_{\text{科技},t} + u_{i,t}.$$

- **因子：**两个行业；**暴露：**属于该行业记为 1，否则为 0。
- 行业归属已经知道，待估计的是两个行业**本月的共同收益。**
- 两个行业变量之和恒为 1，因此保留全部行业变量时不再另加截距。

参考：Zivot (2012), Factor Models for Asset Returns，PDF pp. 17–18。

行业模型的回归结果

每个行业内的股票具有相同的拟合值。使该行业残差平方和最小的拟合值，就是行业平均收益：

$$\widehat{f}_{\text{银行},t} = \frac{4\% + 2\%}{2} = 3\%, \qquad \widehat{f}_{\text{科技},t} = \frac{0\% - 2\%}{2} = -1\%.$$

股票	实际收益	行业解释部分	特质收益（残差）
银行甲	4%	$1 \times 3\% = 3\%$	1%
银行乙	2%	$1 \times 3\% = 3\%$	-1%
科技甲	0%	$1 \times (-1\%) = -1\%$	1%
科技乙	-2%	$1 \times (-1\%) = -1\%$	-1%

结果解释

这个例子以行业为因子，以行业归属的 $0/1$ 变量为暴露。估计的行业收益是组内平均值，个股收益与该平均值之差就是残差。

参考：Zivot (2012), Factor Models for Asset Returns，PDF pp. 17–18；数值例子为本讲自拟。

用 BP 定义价值暴露

行业归属用 0/1 表示；BP 是连续变量，可以用来描述股票的价值特征。

$$BP_{i,t} = \frac{\text{账面权益}_{i,t}}{\text{市值}_{i,t}}, \qquad b_{i,\mathrm{BP},t} = z(BP_{i,t}) = \frac{BP_{i,t} - \overline{BP}_t}{s_{BP,t}}.$$

其中 $\overline{BP}_t$ 和 $s_{BP,t}$ 分别为当期股票池中 BP 的均值与标准差。

固定一期，对多只股票做回归

$$r_{i,t} = a_t + b_{i,\mathrm{BP},t} f_{\mathrm{BP},t} + u_{i,t}.$$

BP 暴露和股票收益是已知数据；截距 a_t 与斜率 $f_{\mathrm{BP},t}$ 由回归估计。

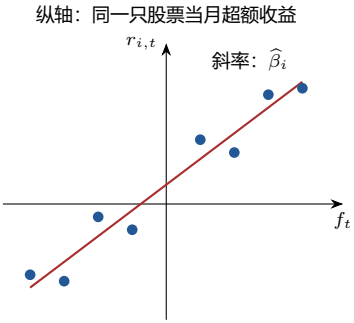
- 标准化暴露相差 1，表示原始 BP 相差一个横截面标准差。
- 收益用小数表示时，若斜率为 0.02，暴露相差 1 对应的拟合收益差为 2 个百分点。

参考：CFA Institute, Using Multifactor Models。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

时间序列回归：每个点是一个月



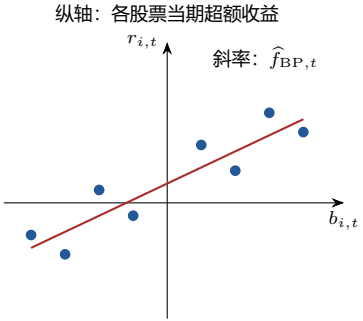
同一只股票的月度数据

$r_{i,t} = \alpha_i + \beta_i f_t + \epsilon_{i,t}$。

- 每个点对应一个月份。
- 已知股票收益与市场收益。
- 估计截距和**市场暴露** β_i。
- 暴露在这个估计窗口内视为不变。

参考：Zivot (2012), Factor Models for Asset Returns，PDF pp. 9–10。

横截面回归：每个点是一只股票



图为本讲自绘示意，点位不代表实证数据。

参考：CFA Institute, Using Multifactor Models。

同一个月的多只股票数据

$r_{i,t} = a_t + b_{i,t} f_{\mathrm{BP},t} + u_{i,t}$。

- 每个点对应一只股票。
- 已知股票收益与 BP 暴露。
- 估计截距和**当期 BP 因子收益**。
- 同一期各股票共用这一组系数。

两种回归的比较

	时间序列回归	横截面回归
固定什么	一只股票 i	一个月份 t
每行观测	一个月	一只股票
被解释变量	该股票各月收益	各股票当月收益
解释变量	各月因子收益	各股票的因子暴露
斜率的含义	个股暴露 β_i	当期因子收益 f_t
例子	用市场收益估计 Beta	用 BP 暴露估计当月 BP 收益

回归系数的含义

时间序列回归用因子收益估计个股暴露；横截面回归用个股暴露估计当期因子收益。

课堂练习：判断回归系数的含义

两种回归都以股票收益为被解释变量。请判断：**每行观测是什么？估计哪个量？**

情境 A：固定一只股票，观察 60 个月

已有这只股票每月的收益，以及市场每月的收益。
用市场收益解释这只股票的收益，回归系数表示什么？

情境 B：固定月份 t，观察多只股票

已有各股票当月的收益，以及各股票标准化后的 BP。
用 BP 暴露解释各股票的收益，回归系数表示什么？

课堂练习：判断回归系数的含义

两种回归都以股票收益为被解释变量。请判断：**每行观测是什么？估计哪个量？**

情境 A：固定一只股票，观察 60 个月

已有这只股票每月的收益，以及市场每月的收益。
用市场收益解释这只股票的收益，回归系数表示什么？

情境 B：固定月份 t，观察多只股票

已有各股票当月的收益，以及各股票标准化后的 BP。
用 BP 暴露解释各股票的收益，回归系数表示什么？

参考答案

A：每行是一个月；因子收益已知，估计个股的**市场暴露** β_i。
B：每行是一只股票；因子暴露已知，估计当月的 **BP 因子收益** $f_{\mathrm{BP},t}$。
判断时先看解释变量是因子收益还是因子暴露。

代码练习：BP 与次日收益的回归

`simple_cross` 每行是一只股票，含 `bp` 与 `return_next` 两列。

$$BP_{i,t} = 1/PB_{i,t}, \qquad R_{i,t+1} = 100\left(\frac{P^{\text{adj}}_{i,t+1}}{P^{\text{adj}}_{i,t}} - 1\right).$$

补全回归公式，拟合结果命名为 simple

```
# pb、close、adj 已用 pd.read_csv 读取
bp = (1 / pb.loc[date]).rename("bp")
price = close * adj
ret = 100 * (price.loc[next_date] / price.loc[date] - 1)
simple_cross = pd.concat([bp, ret.rename("return_next")], axis=1)
simple_cross = simple_cross.replace([np.inf, -np.inf], np.nan)
simple_cross = simple_cross.loc[simple_cross.bp > 0].dropna()
simple = smf.ols("________", data=simple_cross).fit()
print(simple.params)
print(simple.nobs, simple.rsquared)
```

在 `lab05_framework.py` 的 `L05-BP` 段完成练习。保留正 BP，删除无穷值和缺失值；绘图使用同一份回归样本。

单日 BP 回归结果的解释

$$\widehat{R}_{i,t+1} = 1.1249 + 0.0942\, BP_{i,t} \qquad \text{(收益单位：\%)}.$$

样本数 $N = 2262$，$R^2 = 0.000238$。

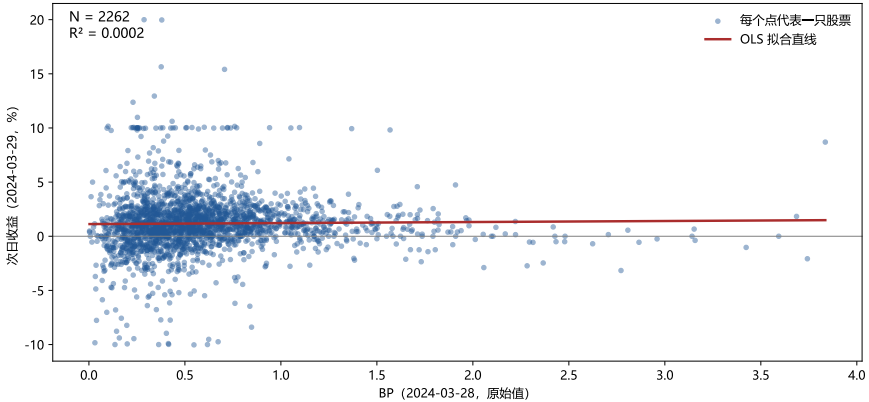
回归公式

```
smf.ols("return_next ~ bp", data=simple_cross).fit()
```

- 斜率是这一天的 BP 收益系数；BP 是已知的股票特征。
- BP 相差 1，拟合收益相差约 0.0942 个百分点；相差 0.5 时，约相差 0.0471 个百分点。
- 个股实际收益与拟合直线上的值之差，就是这只股票的残差。
- 本例的 R^2 接近零，BP 对这一天个股收益差异的解释能力很弱。

BP 与次日收益的散点图

2024 年 3 月 28 日的 BP 与 3 月 29 日收益；每个点代表一只上证股票。



横轴为原始 BP，纵轴为次日收益（%）；红线为含截距的一元 OLS 拟合结果。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

从单因子到多因子

市场单因子回归

$$r_{i,t} = \alpha_i + \beta_i r_{m,t} + \epsilon_{i,t}.$$

- 只使用市场收益作为解释变量。
- Beta 是市场暴露。
- 残差是市场因子未解释的部分。

多因子模型

$$r_{i,t} = \alpha_i + \sum_{k=1}^{K} \beta_{ik} f_{k,t} + \epsilon_{i,t}.$$

- 同时使用 K 个因子收益作为解释变量。
- 每个系数表示控制其他因子后的敏感度。
- 残差仍可能包含遗漏的共同因素。

多因子模型的基本形式

收益分解

$$r_{i,t} = \alpha_i + \boldsymbol{\beta}_i^\top \boldsymbol{f}_t + \epsilon_{i,t}.$$

- $r_{i,t}$：资产 i 在 t 期的超额收益。
- $\boldsymbol{f}_t = (f_{1,t}, \ldots, f_{K,t})^\top$：因子收益向量。
- $\boldsymbol{\beta}_i = (\beta_{i1}, \ldots, \beta_{iK})^\top$：资产对各因子的暴露。
- α_i：模型无法解释的平均超额收益。
- $\epsilon_{i,t}$：特质收益，通常假设与因子收益不相关。

矩阵形式

将上一页每只股票的模型按行排列，得到

$$\boldsymbol{r}_t = \boldsymbol{\alpha} + B\boldsymbol{f}_t + \boldsymbol{\epsilon}_t.$$

- $\boldsymbol{r}_t \in \mathbb{R}^N$：同一期 N 只股票的超额收益。
- $B \in \mathbb{R}^{N\times K}$：第 i 行是股票 i 的因子暴露 $\boldsymbol{\beta}_i^\top$。
- $\boldsymbol{f}_t \in \mathbb{R}^K$：这一期所有股票共同面对的因子收益。
- $\boldsymbol{\alpha}$、$\boldsymbol{\epsilon}_t$：各股票的截距与这一期的残差。

说明

矩阵乘积 $B\boldsymbol{f}_t$ 的第 i 个元素为 $\sum_k \beta_{ik} f_{k,t}$，即各因子对股票 i 的收益贡献之和。这里沿用上一页在估计区间内固定的暴露 B。

多元回归的设计矩阵

先用一般回归记号说明估计方法。对 n 条观测和 k 个解释变量，

$$y_i = \theta_0 + \theta_1 x_{i1} + \cdots + \theta_k x_{ik} + \varepsilon_i, \qquad \boldsymbol{y} = X\boldsymbol{\theta} + \boldsymbol{\varepsilon}.$$

$$\underbrace{\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}}_{\boldsymbol{y}\in\mathbb{R}^n} = \underbrace{\begin{bmatrix} 1 & x_{11} & \cdots & x_{1k} \\ 1 & x_{21} & \cdots & x_{2k} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{bmatrix}}_{X\in\mathbb{R}^{n\times(k+1)}} \underbrace{\begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_k \end{bmatrix}}_{\boldsymbol{\theta}\in\mathbb{R}^{k+1}} + \boldsymbol{\varepsilon}.$$

- X 每行对应一条观测，每列对应一个解释变量；第一列为截距的常数列。
- $\boldsymbol{y}$ 和 X 是已知数据，$\boldsymbol{\theta}$ 是待估系数，共 $k+1$ 个。
- 这里用 θ 表示一般回归系数；其金融含义由回归所用的数据决定。

参考：第三章 Part3《回归分析》，“多元线性回归”“矩阵形式”。

多元回归的最小二乘估计

OLS 选择使残差平方和最小的系数：

$$\widehat{\boldsymbol{\theta}} = \arg\min_{\boldsymbol{\theta}} \|\boldsymbol{y} - X\boldsymbol{\theta}\|^2.$$

对 $\boldsymbol{\theta}$ 求导并令其为零，得到正规方程：

$$-2X^\top(\boldsymbol{y} - X\widehat{\boldsymbol{\theta}}) = 0 \quad \Longrightarrow \quad X^\top X\widehat{\boldsymbol{\theta}} = X^\top \boldsymbol{y}.$$

设计矩阵满列秩时，系数解唯一

$$\widehat{\boldsymbol{\theta}} = (X^\top X)^{-1} X^\top \boldsymbol{y}.$$

满列秩要求 X 的各列不存在精确的线性关系。例如，全部行业虚拟变量与常数列不能同时保留。

实际计算使用 QR 或 SVD 等数值方法，无需在代码中显式求逆。

参考：第三章 Part3《回归分析》，“多元回归的最小二乘解”。

拟合值、残差与正交投影

将最小二乘系数代入模型，得到拟合值与残差：

$$\widehat{\boldsymbol{y}} = X\widehat{\boldsymbol{\theta}} = H\boldsymbol{y}, \qquad H = X(X^\top X)^{-1}X^\top, \qquad \boldsymbol{e} = \boldsymbol{y} - \widehat{\boldsymbol{y}}.$$

- X 的列空间由各列的所有线性组合构成，拟合值 $\widehat{\boldsymbol{y}}$ 属于这个空间。
- 正规方程给出 $X^\top \boldsymbol{e} = 0$：残差与 X 的每一列正交。
- 因此 $\widehat{\boldsymbol{y}}$ 是 $\boldsymbol{y}$ 在该列空间上的正交投影，H 为投影矩阵。

含截距时的两个结果

$\mathbf{1}^\top \boldsymbol{e} = 0$，即残差和为零；$\widehat{\boldsymbol{y}}^\top \boldsymbol{e} = 0$，即拟合值与残差正交。

这是样本内 OLS 的代数性质，不表示残差与解释变量统计独立。

参考：第三章 Part3《回归分析》，“OLS 的几何解释”“为什么拟合值是正交投影?”。

平方和分解与拟合优度

含截距的 OLS 满足 $\bar{\hat{y}} = \bar{y}$。利用拟合值与残差的正交性，

$$\underbrace{\sum_i (y_i - \bar{y})^2}_{SST:\ \text{总平方和}} = \underbrace{\sum_i (\hat{y}_i - \bar{y})^2}_{SSR:\ \text{回归平方和}} + \underbrace{\sum_i (y_i - \hat{y}_i)^2}_{SSE:\ \text{残差平方和}}.$$

$$R^2 = 1 - \frac{SSE}{SST}, \qquad \bar{R}^2 = 1 - \frac{SSE/(n-k-1)}{SST/(n-1)}.$$

- R^2 表示样本内收益差异被回归解释的比例，要求 $SST > 0$。
- 在同一样本上增加变量，普通 R^2 不下降；调整后 R^2 考虑参数数量，可能下降。
- n 为样本数，k 为不含截距的解释变量数；调整后 R^2 要求 $n > k + 1$。
- 比较模型时，因变量、样本和截距设定应相同。

参考：第三章 Part3《回归分析》，“平方和分解”“判定系数”“调整后的判定系数”。

多个特征的横截面模型

固定一期 t，将一般回归中的解释变量换成 BP、市值等 K 个特征暴露：

$$r_{i,t} = a_t + \sum_{k=1}^{K} b_{ik,t} f_{k,t} + u_{i,t}, \qquad i = 1, \ldots, N.$$

- 每行是一只股票；$b_{ik,t}$ 是这只股票在第 k 个特征上的暴露。
- $f_{k,t}$ 是**控制其他特征后**，该暴露每增加一单位对应的拟合收益变化。
- 特征的单位影响系数的数值；标准化后，一单位表示一个横截面标准差。

含截距的矩阵形式

此时 $X = [\mathbf{1}, B_t]$，待估系数为 $\boldsymbol{\theta}_t = (a_t, f_{1,t}, \ldots, f_{K,t})^\top$。
将常数列与截距并入 B_t 和 $\boldsymbol{f}_t$ 后，可简写为 $\boldsymbol{r}_t = B_t \boldsymbol{f}_t + \boldsymbol{u}_t$。

这里的 a_t 是当期截面截距，与时间序列回归的个股 α_i 含义不同。

代码练习：构造对数总市值

使用 2024 年 3 月 28 日的 BP、总市值和 3 月 29 日的收益，每行是一只股票。

读取市值并匹配股票代码

```
mv = pd.read_csv(DATA_DIR / "daily_total_mv_sh.csv",
                 index_col=0).loc[date]
log_mv = np.log(mv.where(mv > 0)).rename("log_mv")
cross = simple_cross.join(log_mv)
cross = cross.replace([np.inf, -np.inf], np.nan).dropna()
```

- `total_mv` 为总市值，单位为万元；`log_mv` 为其自然对数。
- `cross` 保留 BP、次日收益和对数市值均有效的股票。
- 一元、多元回归都使用 `cross`，以便在同一份样本上比较系数。

代码练习：BP 与总市值的多元回归

$$R_{i,t+1} = a + c_{BP} BP_{i,t} + c_{MV} \log MV_{i,t} + u_{i,t+1}.$$

在 `lab05_framework.py` 的 `L05-BP-MV` 段填写以下回归。

在相同样本上估计两个模型

```
model = smf.ols("return_next ~ bp + log_mv",
                data=cross).fit()
simple_same = smf.ols("return_next ~ bp", data=cross).fit()
print(simple_same.params)
print(model.params)
print(simple_same.rsquared_adj, model.rsquared_adj)
```

记录样本数、BP 系数、对数市值系数与调整后 R^2。

BP 与总市值回归的结果

2024 年 3 月 28 日特征与 3 月 29 日收益；两个模型使用同一批股票。

指标	BP 一元回归	BP + 对数总市值
样本数	2262	2262
BP 系数	0.0942	0.1357
对数市值系数	—	-0.1636
R^2	0.000238	0.005622
调整后 R^2	-0.000205	0.004742

$$\widehat{R}_{i,t+1} = 3.3142 + 0.1357\, BP_{i,t} - 0.1636 \log MV_{i,t} \qquad \text{(收益单位：\%)}.$$

- 市值相同时，BP 增加 1，拟合收益增加约 0.1357 个百分点。
- BP 相同时，市值增加 1%，拟合收益变化为 $-0.1636 \log(1.01) \approx -0.00163$ 个百分点。
- 加入市值后调整后 R^2 提高，但这一天收益差异的解释比例仍较低。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

收益归因、预期收益与风险估计

在暴露 B 固定、$\mathbb{E}[\boldsymbol{\epsilon}_t] = 0$ 的模型中：

当期收益归因

$\boldsymbol{r}_t = \boldsymbol{\alpha} + B\boldsymbol{f}_t + \boldsymbol{\epsilon}_t$。
用已经实现的因子收益解释个股当期收益，得到残差。

预期收益

$\mathbb{E}[\boldsymbol{r}_t] = \boldsymbol{\alpha} + B\mathbb{E}[\boldsymbol{f}_t]$。
对收益分解式取期望，得到个股预期收益与因子预期收益的关系。

风险估计

研究因子收益与残差的波动，构造资产协方差矩阵。
即使某因子的平均收益接近零，它仍可能带来显著风险。

参考：MOSEK Portfolio Optimization Cookbook, Ch. 5。

因子模型的协方差分解

从 $\boldsymbol{r}_t = \boldsymbol{\alpha} + B\boldsymbol{f}_t + \boldsymbol{\epsilon}_t$ 出发，设 B 在估计区间内固定。

- 因子协方差：$\Omega = \mathrm{Cov}(\boldsymbol{f}_t)$。
- 残差协方差：$\Delta = \mathrm{Cov}(\boldsymbol{\epsilon}_t)$。
- 假设因子与残差不相关：$\mathrm{Cov}(\boldsymbol{f}_t, \boldsymbol{\epsilon}_t) = 0$。

$$\underbrace{\Sigma}_{\text{资产协方差}} = \underbrace{B\Omega B^\top}_{\text{共同因子带来的协方差}} + \underbrace{\Delta}_{\text{剩余风险}}.$$

特质收益与特质风险

$\epsilon_{i,t}$ 是一次收益；$\mathrm{Var}(\epsilon_{i,t})$ 衡量它跨期的波动。
若进一步假设不同股票的残差互不相关，Δ 就是对角矩阵。

参考：MOSEK Portfolio Optimization Cookbook, Ch. 5。

组合收益的方差分解

将资产协方差 $\Sigma = B\Omega B^\top + \Delta$ 代入组合方差公式：

$$\mathrm{Var}(R_p) = \boldsymbol{w}^\top \Sigma \boldsymbol{w} = \boldsymbol{w}^\top B\Omega B^\top \boldsymbol{w} + \boldsymbol{w}^\top \Delta \boldsymbol{w}.$$

组合暴露是个股暴露的加权平均

记 $\boldsymbol{x}_p = B^\top \boldsymbol{w}$，则

$$\mathrm{Var}(R_p) = \underbrace{\boldsymbol{x}_p^\top \Omega \boldsymbol{x}_p}_{\text{共同因子方差}} + \underbrace{\boldsymbol{w}^\top \Delta \boldsymbol{w}}_{\text{特质方差}}.$$

- 当 Δ 为对角阵时，特质方差为 $\sum_i w_i^2 \sigma_{\epsilon_i}^2$。
- 分散持股可以降低特质方差；共同因子风险取决于组合暴露。
- 两部分方差可以相加，标准差不能直接相加。

协方差估计误差对组合权重的影响

GMV 的解析解直接依赖协方差矩阵的逆：

$$\widehat{\boldsymbol{w}}_{\mathrm{GMV}} = \frac{\widehat{\boldsymbol{\Sigma}}^{-1}\mathbf{1}}{\mathbf{1}^{\top}\widehat{\boldsymbol{\Sigma}}^{-1}\mathbf{1}}.$$

若样本协方差矩阵的特征分解为

$$\widehat{\boldsymbol{\Sigma}} = Q\,\mathrm{diag}(\widehat{\lambda}_1,\ldots,\widehat{\lambda}_N)Q^{\top}, \qquad \widehat{\boldsymbol{\Sigma}}^{-1} = Q\,\mathrm{diag}\left(\frac{1}{\widehat{\lambda}_1},\ldots,\frac{1}{\widehat{\lambda}_N}\right)Q^{\top},$$

则估计得过小的特征值会在求逆时被放大。

- 当资产数 N 接近样本数 T 时，小特征值的估计可能很不稳定；$N \geq T$ 时样本协方差必然奇异。
- 因此，估计窗口略有变化就可能导致权重大幅变化，甚至出现极端多空头寸。

数值求解与统计估计

数值优化即使没有显式计算 $\widehat{\boldsymbol{\Sigma}}^{-1}$，也不会自动消除这种统计敏感性。

提高组合稳定性的常用方法

改进风险估计

- **收缩估计**：把样本协方差向单位矩阵、常相关矩阵等结构目标收缩。
- **因子模型**：用少数共同因子加结构化特质风险替代完全自由的协方差矩阵。
- **稀疏估计**：对协方差或精度矩阵施加阈值、Graphical Lasso 等结构。
- **稳健估计**：降低异常值、厚尾和市场状态变化的影响。

约束组合权重

- 禁止卖空、设置个股权重和总杠杆上限。
- 对权重范数、相对基准偏离和换手率加入惩罚。
- 在参数不确定集合中做稳健或分布鲁棒优化。
- 始终与等权、波动率倒数和风险平价等简单基准比较。

作用

这些方法通过调整协方差估计或限制组合权重，降低估计误差对组合的影响。

因子模型需要估计多少参数?

对 N 只股票，直接估计协方差需要 $N(N+1)/2$ 个参数。因子模型采用 $\Sigma = B\Omega B^\top + \Delta$，并假设 Δ 为对角阵。

估计对象	参数数量	$N = 100,\ K = 3$
暴露矩阵 B	NK	300
因子协方差 Ω	$K(K+1)/2$	6
特质方差 Δ	N	100
合计	$NK + K(K+1)/2 + N$	406

- 直接估计 100 只股票的协方差需要 5050 个参数；上述因子表示需要 406 个。
- 若暴露由股票特征给定，则还需估计的是因子协方差和特质方差。
- 参数减少依赖于模型假设；遗漏共同因素会使协方差估计产生偏差。

参考：MOSEK Portfolio Optimization Cookbook, Ch. 5。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

实践一：选出低 PB、小市值股票

每个月末按 PB 和总市值评分，选出 20 只股票，等权持有一个月。

- 股票池：上证日线宽表的前 300 只股票；每期保留非 ST、有成交、PB 与总市值为正的股票。
- 特征：月末 PB 与总市值（`total_mv_sh.csv`）；PB 越低、市值越小，得分越高。
- 调仓：每月重新评分、重新选股，将入选股票的权重恢复为 $1/20$。
- 收益区间：2020 年 1 月至 2025 年 12 月；首次建仓为 2019 年 12 月末。

评分规则

$$score_{i,t} = rank_{\text{desc}}(PB_{i,t}) + rank_{\text{desc}}(MC_{i,t}).$$

降序排名把最大值排第 1 名，因此低 PB、小市值获得更大的名次。MC 表示总市值。

两项特征的单位不同，先分别排名再相加，赋予两项排名相同权重。

L05-00：计算评分并选出 20 只股票

运行第 0 段和 L05-00 的数据准备部分，得到月末股票池 `pool`。先以 2021 年 12 月末为例，观察哪些股票入选。

```
month = pool.loc[pool['date'] == '2021-12-31'].copy()

month['score'] = (month['pb'].rank(ascending=False)
                  + month['total_mv'].rank(ascending=False))
selected = month.nlargest(20, 'score')
print(selected[['code', 'pb', 'total_mv', 'score']])
```

观察入选股票

对比入选股票与当月股票池的 PB、市值。评分最高表示两项排名之和较大，不要求一只股票的 PB 和市值都最小。

从单月选股到逐月调仓

t 月末选股，持有到 $t+1$ 月末，再用新的特征确定下一期持仓。

$$R_{p,t+1} = \frac{1}{20} \sum_{i \in S_t} r_{i,t+1}, \qquad V_{t+1} = V_t(1 + R_{p,t+1}), \quad V_0 = 1.$$

- S_t 是 t 月末选出的 20 只股票；下一月收益不参与本月评分。
- 同时计算三个组合：评分最高 20 只、总市值最小 20 只、当月股票池全部股票；均按月恢复等权。
- 记录新进入和退出持仓的股票数量；继续持有的股票也可能需要交易，才能恢复等权。

回测约定

按月末收盘价调仓，不计交易费用。收益用复权价格计算；月末无报价时按最近交易日价格估值。这只是一种简化估值，停牌、退市时不保证能按该价格卖出。

L05-00A：逐月选股并计算组合收益

按日期分组，每次循环完成一个月的选股。收益记录在下一个月末。

```
return_rows, holding_rows, change_rows = [], [], []
previous = set()
for date, g in pool.groupby('date'):
    g = g.copy()
    g['score'] = (g['pb'].rank(ascending=False)
                  + g['total_mv'].rank(ascending=False))
    chosen = g.nlargest(20, 'score').copy()
    small = g.nsmallest(20, 'total_mv')
    end = dates[dates.get_loc(date) + 1]
    return_rows.append({'date': end,
        '低PB十小市值': chosen['next_ret'].mean(skipna=False),
        '仅小市值': small['next_ret'].mean(skipna=False),
        '股票池等权': g['next_ret'].mean(skipna=False)})
```

下一页继续记录本次选股的持仓，前几行仍在同一个循环内。

L05-00A：记录持仓与调仓数量（续）

集合之差给出本月新入选和不再入选的股票。

```
    chosen['weight'] = 1 / len(chosen)
    chosen['return_end'] = end
    holding_rows.append(chosen)
    current = set(chosen['code'])
    change_rows.append({'date': date,
        '买入数量': len(current - previous),
        '卖出数量': len(previous - current)})
    previous = current
strategy_returns = pd.DataFrame(return_rows).set_index('date')
holdings = pd.concat(holding_rows, ignore_index=True)
changes = pd.DataFrame(change_rows).set_index('date')
```

- `holdings` 保存每月股票名单和目标权重；`changes` 保存进入、退出持仓的数量。
- 初次建仓买入 20 只；后续每月的买入、卖出数量不包括留存股票的权重调整。

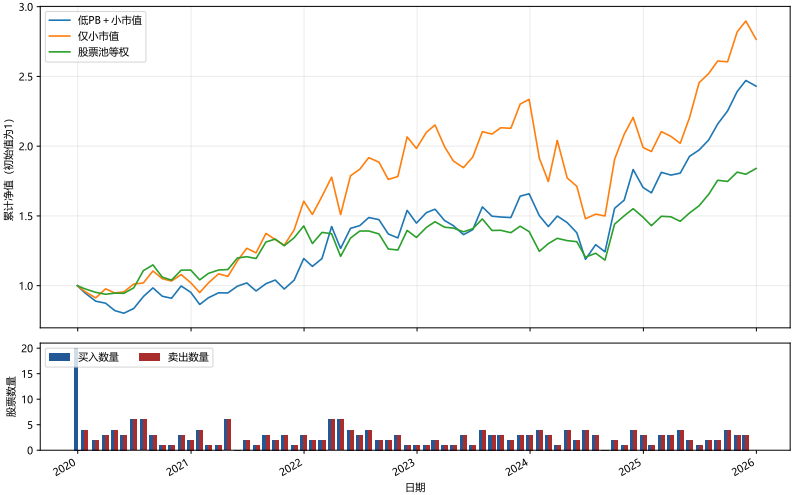
L05-00B：计算净值和回撤

月收益连乘得到净值；净值相对历史最高点的跌幅就是回撤。

```
nav = (1 + strategy_returns).cumprod(skipna=False)
nav.loc[dates[0]] = 1.0
nav = nav.sort_index()
drawdown = nav / nav.cummax() - 1
performance = pd.DataFrame({
    '累计收益': nav.iloc[-1] - 1,
    '年化收益': nav.iloc[-1] ** (12 / len(strategy_returns)) - 1,
    '年化波动率': strategy_returns.std() * np.sqrt(12),
    '最大回撤': drawdown.min()
})
```

年化收益按复利折算；年化波动率由月收益标准差乘 $\sqrt{12}$ 得到。最大回撤以负数表示，越接近零，历史跌幅越小。

实践一：净值与持仓调整



上图为按月恢复等权的累计净值；下图为评分组合每月新进入、退出的股票数量。

实践一：如何比较三个组合？

2020 年 1 月至 2025 年 12 月，共 72 个月，未扣除交易费用。

组合	累计收益	年化收益	年化波动率	最大回撤
低 PB ＋小市值	143.01%	15.95%	25.15%	−28.33%
仅小市值	176.60%	18.48%	27.97%	−36.65%
股票池等权	84.01%	10.70%	19.11%	−19.98%

- 在这段样本中，加入 PB 排名后，收益、波动和最大回撤都发生了变化。
- 比较两个选股组合：收益降低的同时，波动和回撤是否也减小了？
- 比较股票池等权组合：较高收益是否伴随着较高风险？
- 若计入交易费用，还需要知道哪些信息？仅有买入、卖出的股票数量够不够？

这些结果描述本样本中的组合表现，不能单凭净值差异认定 PB 具有独立的收益解释能力。

评分组合与规模、价值因子

评分组合的收益

把低 PB、小市值两个偏好合成一个分数，形成一个做多组合。组合收益同时受到市场、规模、价值等多种因素影响。

规模与价值的多空组合

分别按规模和账面市值比分组，构造小减大、高减低的多空收益，再估计股票对这些因子的暴露。

- 对正 PB 股票，$BP = 1/PB$：低 PB 对应高 BP，与价值因子的分组方向一致。
- 小市值偏好对应规模特征，但评分组合的收益不等于 SMB 或 HML。
- 后面的回归实验同时加入 BP 和市值，考察控制另一特征后的收益关系。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

Fama-French 模型的实证背景

Fama-French 在市场因子之外加入规模和价值因子，用于解释股票收益差异。

经验事实

市场 Beta 不能完全解释股票横截面平均收益差异。

- 小市值股票长期平均收益不同于大市值股票。
- 高账面市值比股票长期平均收益不同于低账面市值比股票。
- 若市场因子回归不能解释这些平均收益差异，估计的截距可能显著偏离零。
- Fama-French 用规模和价值多空组合的收益作为额外解释变量，再检验截距是否减小。

三因子模型

模型形式

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_{i,MKT}(R_{m,t} - R_{f,t}) + \beta_{i,SMB}SMB_t + \beta_{i,HML}HML_t + \epsilon_{i,t}.$$

- MKT：市场超额收益因子。
- SMB：Small Minus Big，小市值相对大市值的收益。
- HML：High Minus Low，高账面市值比相对低账面市值比的收益。
- α_i：三因子模型仍无法解释的平均收益。

SMB 与 HML 的分组原理

SMB

- 按市值把股票分为小市值和大市值。
- 做多小市值组合，做空大市值组合。
- 衡量小市值相对大市值的收益差。

HML

- 按账面市值比把股票分为高、中、低。
- 做多高账面市值比组合，做空低账面市值比组合。
- 衡量价值股相对成长股的收益差。

- 在 Fama–French 模型中，SMB、HML 是多空组合的收益序列；股票的 BP 数值不等于它对 HML 的回归暴露。

三因子回归系数的解释

系数	解释	例子
β_{MKT}	对市场风险的敏感度	高 Beta 股票
β_{SMB}	对小市值因子的暴露	小盘股通常较高
β_{HML}	对价值因子的暴露	价值股通常较高
α	三因子无法解释的平均收益	未解释收益
R^2	三个因子对收益波动的解释比例	风格解释力

解释方式

三个回归系数分别表示股票对市场、规模和价值因子收益的敏感度。

从三因子到五因子和更多因子

- 后续 Fama-French 五因子加入盈利能力和投资风格因子。
- 动量因子常被单独加入形成四因子或扩展模型。
- 不同市场、不同样本期、不同资产类别中的因子表现可能不同。
- 新增因子后，应检查其是否提供额外解释，以及结论在其他样本中是否成立。

与本讲实验的区别

三因子回归先构造因子收益，再估计个股暴露。本讲的 BP、市值实验先由股票特征构造暴露，再估计各月的因子收益。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

APT：从收益的因子结构出发

多因子收益回归本身不限定预期收益的取值。套利定价理论（APT）在因子结构上加入无套利条件，推导预期收益与暴露的关系。

$$R_{i,t} = \mu_i + \sum_{k=1}^{K} \beta_{ik} F_{k,t} + \epsilon_{i,t}.$$

- $\mu_i = \mathbb{E}[R_{i,t}]$：资产的预期收益。
- $F_{k,t}$：共同因素的意外变化，设 $\mathbb{E}[F_{k,t}] = 0$；β_{ik} 为资产对该变化的敏感度。
- $\epsilon_{i,t}$：均值为零的特质收益；充分分散的组合可以降低其影响。

APT 推理所需的条件

收益具有共同因子结构；特质风险可以充分分散；市场不存在相应的套利机会。在这些条件下，预期收益与因子暴露近似呈线性关系。

参考：Ross (1976), The Arbitrage Theory of Capital Asset Pricing。

APT 例子：相同暴露应对应相同预期收益

假设以下三个组合都已充分分散，特质风险可以忽略；收益均采用年化口径。

组合	因子 1 暴露	因子 2 暴露	预期收益
A	1	0	6%
B	0	1	5%
C	0.5	0.5	6.5%

用 A、B 各一半构造组合 D

D 的暴露也是 $(0.5, 0.5)$，但预期收益为 $0.5 \times 6\% + 0.5 \times 5\% = 5.5\%$。

- 做多 1 元 C，同时分别做空 0.5 元 A、B：净初始投入为零，两项共同因子暴露均抵消。
- 若特质风险可忽略，每 1 元多头名义本金对应的预期盈利为 $6.5\% - 5.5\% = 1\%$。
- 无套利要求消除这种收益差异：相同因子暴露的充分分散组合应有相同预期收益。

数值为教学假设。两只个股即使暴露相同，多空头寸也可能仍有特质风险，不能直接视为无风险套利。

为什么预期收益与暴露呈线性关系?

设 B 为暴露矩阵，$\boldsymbol{\mu}$ 为预期收益向量。构造多空头寸 $\boldsymbol{w}$，使

$$\underbrace{\mathbf{1}^\top \boldsymbol{w} = 0}_{\text{净初始投入为零}}, \qquad \underbrace{B^\top \boldsymbol{w} = 0}_{\text{共同因子暴露为零}}.$$

头寸的收益按多头名义本金归一化后为

$$\boldsymbol{w}^\top \boldsymbol{R}_t = \boldsymbol{w}^\top \boldsymbol{\mu} + \boldsymbol{w}^\top \boldsymbol{\epsilon}_t.$$

忽略特质风险时的推导

若 $\boldsymbol{w}^\top \boldsymbol{\mu} \neq 0$，可以选择头寸方向获得无风险正收益。无套利要求所有这类头寸都满足 $\boldsymbol{w}^\top \boldsymbol{\mu} = 0$。因此 $\boldsymbol{\mu}$ 必须属于 $[\mathbf{1}, B]$ 的列空间，即

$$\boldsymbol{\mu} = \lambda_0 \mathbf{1} + B\boldsymbol{\lambda}.$$

存在无风险资产时，$\lambda_0 = r_f$。

有特质风险时：还需充分分散及相应条件；不能要求有限股票池中每只股票都严格满足定价式。

参考：Ross (1976)，无套利头寸与线性定价关系。

APT 定价式：暴露与风险溢价

存在无风险资产时，APT 的常见表达为

$$\mathbb{E}[R_i] - r_f \approx \sum_{k=1}^{K} \beta_{ik} \lambda_k .$$

- β_{ik}：资产承担多少第 k 类共同风险。
- λ_k：一单位该因子暴露所对应的预期超额收益，即因子风险溢价。
- 收益、无风险利率与风险溢价必须采用同一期间口径。

计算例子：两因子模型

设年无风险利率为 2%，两项年风险溢价为 4%、3%，股票暴露为 1.2、0.5：

$$\mathbb{E}[R_i] \approx 2\% + 1.2 \times 4\% + 0.5 \times 3\% = 8.3\%.$$

8.3% 是预期收益；实际收益还受到因子冲击与特质收益的影响。

参考：CFA Institute, Using Multifactor Models；数值为教学假设。

风险溢价与当期因子收益的区别

	风险溢价 λ_k	当期因子收益 $f_{k,t}$
含义	一单位暴露对应的预期超额收益	因子在某一期实现的收益
用途	APT 的预期收益定价	解释当期收益、估计因子波动
例子	预期年风险溢价为 4%	本年实际收益可为 10% 或 -8%

- 上述意外冲击 $F_{k,t}$ 的均值设为零，用来描述收益的随机变化；这不意味着 $\lambda_k = 0$。
- 对适当构造的可交易因子组合，可将其预期超额收益与风险溢价联系起来；宏观变量的平均值不等于风险溢价。

与本讲实验的关系

月度 BP、市值回归系数是收益实现后的截面估计，不能直接当作下一月已知的风险溢价。即使估计历史平均系数，也仍需检验其样本外表现。

参考：CFA Research Foundation, A Practitioner's Guide to Factor Models。

APT 与 CAPM 的关系

维度	CAPM	APT
因子数量	一个市场因子	一个或多个共同因子
定价逻辑	均值–方差与市场组合	无套利约束
因子指定	市场组合明确指定	理论不指定具体因子
预期收益	由市场 Beta 决定	由多个因子暴露决定
市场组合	在定价中有特殊地位	不必以市场组合作为唯一因子

- APT 不指定因子名称、数量和风险溢价数值，仍需经济分析与实证估计。
- 单因子 APT 可写出与 CAPM 相似的公式，但两者的假设与推导不同。
- Barra 类风险模型使用因子结构估计协方差，所需估计量是因子波动与残差方差。

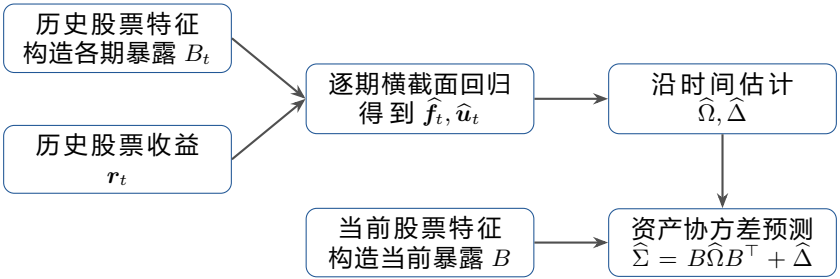
Barra 风险模型的目标

目标

Barra 类风险模型主要用于解释和预测投资组合风险，而不只是预测收益。

- 把股票收益拆成国家/市场、行业、风格和特质部分。
- 由行业归属、财务与交易特征构造股票的因子暴露。
- 估计因子协方差矩阵和特质风险。
- 用于组合风险预测、主动风险控制、风格暴露约束和绩效归因。

Barra 风险模型的估计步骤



各步骤的估计对象

暴露来自股票属性；因子收益来自横截面回归；风险来自收益和残差的跨期波动。

参考：MOSEK Portfolio Optimization Cookbook, Sec. 5.2.1.2；流程图为本讲自绘。

Barra 常见因子类别

类别	说明	例子
市场因子	整体市场共同波动	全市场共同项
行业因子	行业层面的共同收益来源	银行、医药
风格因子	跨行业的股票特征暴露	规模、价值
货币/国家因子	跨市场投资时的区域和汇率暴露	国家、汇率
特质风险	因子无法解释的个股风险	残差风险

- Barra 更强调风险解释和组合约束，和纯收益预测因子不同。

行业因子与风格因子

行业因子

- 通常用哑变量表示行业归属。
- 每只股票属于一个或多个行业。
- 解释行业共同涨跌。
- 常用于行业中性和行业暴露控制。

风格因子

- 用连续变量描述股票特征。
- 例子：规模、价值、动量、波动率、质量。
- 需要去极值、标准化和中性化。
- 常用于风险归因和选股信号。

课程提纲

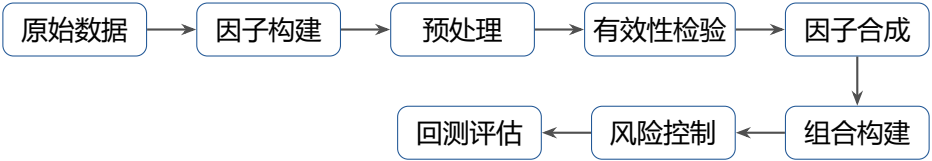
1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

风险因子与选股因子

风险模型关注股票收益的共同波动；选股模型关注股票特征能否预测后续收益。两者可以使用相同的特征，但检验的目标不同。

- 风险模型因子用于估计组合方差，并限制行业、规模等暴露。
- 选股因子用于预测后续收益，需检验其样本外预测能力。
- 有些因子既是风险来源，也可能有收益预测能力，例如价值、规模、动量。
- 组合优化可以将预测收益作为目标，同时对风险和因子暴露设置约束。

因子研究的基本流程



- 本讲介绍因子模型，第 6–10 讲继续讨论因子构建、检验和合成。

常见误区

- 把高因子暴露误认为高 Alpha。
- 只看因子平均收益，不看风险、换手和稳定性。
- 因子之间高度相关，却当作独立信息叠加。
- 没有区分行业暴露和风格暴露。
- 用样本内拟合结果解释为稳定规律。
- 忽略因子收益的周期性和拥挤交易风险。

原则

评价因子时，需要同时检查经济依据、统计显著性、样本外表现和交易成本。

课程提纲

1. 时间序列与横截面视角
2. 从单因子到多因子模型
3. 收益解释与风险分解
4. 实践一：用 PB 和市值排序选股
5. Fama-French 三因子模型
6. APT 与 Barra 框架
7. 与因子选股的关系
8. 实践二：用 BP 和市值解释下一期收益

月度回归的数据配对

每个月末记录股票特征，再计算随后一个月的收益。以 2022 年 1 月收益为例：

变量	取值日期或区间	用途
BP、流通市值	2021 年 12 月 31 日	解释变量
股票收益	2021 年 12 月 31 日至 2022 年 1 月末	被解释变量

$$R_{i,t+1} = a_{t+1} + f_{BP,t+1} z(BP_{i,t}) + f_{Size,t+1} z(\log MC_{i,t}) + u_{i,t+1}.$$

- MC 为流通市值；两个特征均在 t 月末的股票截面内标准化。
- R 为股票原始收益率，以小数表示，例如 0.02 表示 2%。
- 本次回归使用已实现的收益，估计特征与随后一个月收益的样本关系。
- 若用于事前预测，系数也只能用预测时已经实现的历史收益估计。

本讲实验：用 BP 与市值解释下一月收益

- 股票池：上交所全部 A 股，包含主板、科创板；沿用第一讲下载作业。
- 解释变量只有两个：账面市值比 BP、流通市值的对数。
- 先比较单月的一元与多元回归，再逐月估计系数并观察其变化。
- 拓展任务：用逐月系数估计因子协方差，用个股残差估计特质方差。
- Fama–French 保留为理论参照；本实验直接回归股票特征，不构造 SMB、HML。

实验准备：从日线数据到月度面板

- 复用第一讲的沪市 A 股日线数据，研究区间为 2015–2025 年。
- 检查字段：`pb`、`circ_mv`、`close`、`adj_factor`，以及交易状态筛选所需的字段。
- 提取 2019 年 12 月至 2025 年 12 月的月末观测，构造 BP、市值和下一月收益。
- 打开 `lab05_framework.py`，按 L05-01–06 的顺序完成计算。
- 先核对日期、股票代码和缺失值，再进行回归并解释结果。

数据口径与样本筛选

- 覆盖与 2015–2025 区间有交集的沪市 A 股；统计筛选前后的股票数量。
- 从 2020 年 1 月末开始形成暴露，配对截至 2025 年 12 月实现的收益；每期报告有效股票数。
- 月末取交易所最后交易日；不把停牌前的估值向后填充。
- 剔除 BP 非正、换手率非正、ST、缺失值及两端停牌样本；新上市股票按数据可用性进入。
- 按本次作业约定忽略股票池前视偏差；结果用于理解模型，不视为无偏策略回测。

月度特征与收益的计算

当前数据表中，pb 是市净率，circ_mv 是以万元计的流通市值。

$$BP_{i,t} = \frac{1}{PB_{i,t}}, \qquad MC_{i,t} = 10000 \times \texttt{circ_mv}_{i,t}.$$

$$P^{\text{adj}}_{i,t} = \texttt{close}_{i,t} \times \texttt{adj_factor}_{i,t}, \qquad R_{i,t+1} = \frac{P^{\text{adj}}_{i,t+1}}{P^{\text{adj}}_{i,t}} - 1.$$

- BP 越高，表示每单位市值对应的账面权益越多。
- 市值先取对数，再在当月股票截面内标准化，以减小数量级差异。
- 收益用相邻月末的复权价格计算，避免把分红、拆股等价格调整误计为收益。

准备回归数据：每一行是一只股票

以 2022 年 1 月为例，我们需要为每只股票准备三个数：

股票	BP	对数市值	1 月收益
股票 A	BP_A	$\log MC_A$	$R_{A,\text{Jan}}$
股票 B	BP_B	$\log MC_B$	$R_{B,\text{Jan}}$
⋮	⋮	⋮	⋮

- 收益：1 月末后复权价格除以 12 月末后复权价格，再减 1。
- 特征：使用 12 月末的 BP 与对数市值，分别在该月末的股票截面内标准化。
- 标准化 $z(x) = (x - \bar{x})/s_x$，便于比较两种特征的系数。

日期核对

回归表中每行都应使用 12 月末特征和随后 1 月的收益，不能混用不同月份的数据。

L05-01：构造当月 BP 与市值暴露

```
panel["size"] = np.log(panel["float_mcap"])
features = panel.dropna(subset=["bp", "size"]).copy()
for col in ["bp", "size"]:
    group = features.groupby("date")[col]
    features[col + "_z"] = (
        (features[col] - group.transform("mean"))
        / group.transform("std"))
sample = features.dropna(
    subset=["bp_z", "size_z", "next_ret"]).copy()
sample = sample.loc[(sample["next_tradestatus"] == 1)
                    & (sample["date"] >= "2020-01-01")]
```

BP 与流通市值已由原始字段计算；这里按月标准化。下面检查：这些暴露应与哪个月的收益配对？

哪组数据可以放在同一次回归中?

在 12 月末预测 1 月收益时，**哪些 BP、市值数据已经可用?** 应该选择哪组数据?

A. 2021 年 12 月末的 BP、市值与 2022 年 1 月收益。

B. 2022 年 1 月末的 BP、市值与 2022 年 1 月收益。

哪组数据可以放在同一次回归中?

在 12 月末预测 1 月收益时，**哪些 BP、市值数据已经可用?** 应该选择哪组数据?

A. 2021 年 12 月末的 BP、市值与 2022 年 1 月收益。

B. 2022 年 1 月末的 BP、市值与 2022 年 1 月收益。

选 A：预测变量必须在预测时已经可得

12 月末的特征描述股票进入 1 月时的状态。

若使用 1 月末的特征，1 月的涨跌已经改变价格，也会改变 BP 和市值，而且这些特征在 12 月末尚不可得，会使用未来信息。

任务 1：先只用 BP，再加入市值

- 沿用投票题的配对：2021 年 12 月末特征解释 2022 年 1 月收益，在同一批股票上比较两个模型。
- 先估计 $R_{i,t+1} = a_{t+1} + f_{BP,t+1} z(BP_{i,t}) + u_{i,t+1}$。
- 再估计 $R_{i,t+1} = a_{t+1} + f_{BP,t+1} z(BP_{i,t}) + f_{Size,t+1} z(\log MC_{i,t}) + u_{i,t+1}$。
- 记录两个模型的 BP 系数和调整后 R^2，比较增加市值变量后的变化。

L05-02：只用 BP 做一次截面回归

```
y = month["next_ret"]
X_bp = sm.add_constant(month[["bp_z"]])
one = sm.OLS(y, X_bp).fit()
print("BP only:", one.params)
```

`month` 是 2021 年 12 月末的截面；`next_ret` 是随后一个月收益。

L05-03：加入市值后的多元回归

```
X = sm.add_constant(month[["bp_z", "size_z"]])
two = sm.OLS(y, X).fit()
comparison = pd.DataFrame({
    "BP only": [one.params["bp_z"], one.rsquared_adj],
    "BP + size": [two.params["bp_z"], two.rsquared_adj]
}, index=["BP coefficient", "adjusted R2"])
print(two.params)
print(comparison)
```

系数表示控制另一特征后，暴露增加一个标准差所对应的下一月拟合收益差异。

任务 1：绘制并解释回归结果

- 左图：BP 暴露与下一月收益的散点，颜色表示市值暴露。
- 右图：实际收益与两特征回归拟合值，画出 45 度参考线。
- 观察：加入市值后 BP 系数如何变化？拟合误差集中在哪些股票？

记录结果

报告两个模型的 BP 系数、调整后 R^2 和样本数，检查比较时使用的股票是否相同。

课堂记录与讨论：增加变量就一定更好吗？

指标	BP 单因子	BP + 市值
BP 系数（小数收益/标准差）	_____	_____
调整后 R^2	_____	_____

- 同一样本加入变量，普通 R^2 不下降；调整后 R^2 未必提高。
- BP 系数反映条件关系，不等于证明 BP 造成收益变化。
- 截面截距是该期共同收益项，不是时间序列回归中的个股 Alpha。
- 这里的 f_{BP}、f_{Size} 是特征回归系数，不是 HML、SMB 的收益率。

算一算：BP 系数为 0.02，意味着什么？

某月的横截面回归得到

$$\widehat{R}_{i,t+1} = a_{t+1} + 0.02\, z(BP_{i,t}) - 0.01\, z(\log MC_{i,t}).$$

两只股票的市值暴露相同，A 的 BP 标准化值为 1，B 为 -1。

1. 模型拟合的月收益相差多少个百分点？
2. 能否据此断言，买 A、卖 B，下一月一定赚到这个差额？

先独立计算，再解释（约 1 分钟）。

算一算：BP 系数为 0.02，意味着什么？

某月的横截面回归得到

$$\widehat{R}_{i,t+1} = a_{t+1} + 0.02\, z(BP_{i,t}) - 0.01\, z(\log MC_{i,t}).$$

两只股票的市值暴露相同，A 的 BP 标准化值为 1，B 为 -1。

1. 模型拟合的月收益相差多少个百分点？
2. 能否据此断言，买 A、卖 B，下一月一定赚到这个差额？

先独立计算，再解释（约 1 分钟）。

核对答案

拟合差异为 $0.02 \times [1 - (-1)] = 0.04$，即 **4 个百分点**。实际收益还包含残差差异；该系数也是收益实现后估计的，不能直接当作下一月的已知收益。

任务 2：将同一个回归逐月重复

- 每月重新读取 BP 和市值暴露，使用下一月收益做一次 OLS。
- 保存三个系数：共同截距、BP 系数、市值系数；另存各股票残差。
- 画系数随时间变化的曲线：正负是否会切换？是否存在极端月份？
- 月度系数序列用于观察收益关系的时间变化，第七讲再讨论显著性与稳定性检验。

L05-04：逐月估计因子收益与个股残差

```
factor_rows, residual_rows = [], []
for date, g in sample.groupby("date"):
    X_t = sm.add_constant(g[["bp_z", "size_z"]])
    if len(g) < 10 or np.linalg.matrix_rank(X_t) < 3:
        continue
    fit = sm.OLS(g["next_ret"], X_t).fit()
    factor_rows.append({"date": date,
        "return_end": g["return_end"].iloc[0],
        **fit.params.to_dict(), "adj_r2": fit.rsquared_adj})
    residual_rows.append(pd.DataFrame({"date": date,
        "code": g["code"], "resid": fit.resid}))
factor = pd.DataFrame(factor_rows).set_index("date")
residual = pd.concat(residual_rows).pivot(
    index="date", columns="code", values="resid")
```

日期索引记录暴露月份；画图用 `return_end`，对应真正的收益实现月份。

任务 2：观察逐月系数的变化

- 横轴：收益实现月份；三条曲线分别为截距、BP 系数、市值系数。
- 每幅图画零线，对比正负切换、波动幅度与极端月份。
- 讨论：单月正系数与长期有效是否是一回事?

记录结果

选取 BP 系数为正和为负的各一个月，分别说明当月的条件收益关系。

拓展任务：用回归结果估计风险

$$B_t = \begin{bmatrix} 1 & z(BP_{1,t}) & z(\log MC_{1,t}) \\ \vdots & \vdots & \vdots \\ 1 & z(BP_{N,t}) & z(\log MC_{N,t}) \end{bmatrix}, \quad \widehat{\Sigma}_t = B_t \widehat{\Omega} B_t^\top + \widehat{\Delta}.$$

- B_t：当前月末的已知特征；Ω：过去逐月截面系数的协方差。
- Δ：过去个股残差方差组成的对角阵；共同截距也纳入因子向量。
- 教学近似：固定当前暴露，忽略残差之间及因子与残差的协方差；不是完整 Barra 实现。
- 截止 2022 年末，只用此前已经实现的收益；风险演示选有完整共同训练样本的股票。

L05-05：用历史系数和残差估计协方差

```
train_f = factor.loc[factor["return_end"] <= cutoff, cols]
train_e = residual.reindex(train_f.index)
codes = sorted(set(asof.index) & set(
    train_e.columns[train_e.notna().all()]))
B = sm.add_constant(asof.loc[codes, ["bp_z", "size_z"]])
Omega = train_f.cov().to_numpy()
d = train_e[codes].var(ddof=1).to_numpy()
Delta = np.diag(d)
Sigma_factor = B.to_numpy() @ Omega @ B.to_numpy().T + Delta
```

`return_end <= cutoff` 才能进入训练集；2022 年 12 月的暴露所配 2023 年 1 月收益不能进入。

拓展练习：比较两种协方差估计

- 使用相同股票顺序、相同年化口径和同一个颜色范围。
- 并排画样本协方差与因子协方差的同一组 15 只股票子矩阵。
- 检查：对称性、对角元素、共同波动；颜色差异不代表预测优劣。

记录结果

记录两种估计的对角元素范围，并检查矩阵是否对称；预测准确性需要另用样本外数据比较。

比较样本协方差与因子协方差

- 计算并记录股票数 N、共同样本期数 T 以及样本协方差的秩。
- 当 $N > T - 1$，样本协方差必然奇异，不能直接套用含 Σ^{-1} 的 GMV 解析式。
- 因子模型估计小规模的 Ω 和个股残差方差；若每个特质方差为正，得到正定矩阵。
- 结构化估计便于解释，也引入模型误差；正定不等于预测更准确。

L05-06：等权组合的共同风险与特质风险

```
w = np.full(len(codes), 1 / len(codes))
exposure = B.to_numpy().T @ w
common_var = exposure @ Omega @ exposure
specific_var = w @ Delta @ w
total_var = w @ Sigma_factor @ w
assert np.isclose(common_var + specific_var, total_var)
print("Equal-weight exposures:", exposure)
print("Common/specific variance:", common_var, specific_var)
```

先算组合暴露 $x = B^\top w$；共同方差和特质方差可加，波动率不可直接相加。

拓展练习：比较单只股票与组合的风险

- 比较单只股票与等权组合；分别画年化方差及方差占比。
- 每根柱分为共同因子方差与特质方差，核验两者之和。
- 讨论：分散持股改变了哪些暴露？为什么波动率不能直接相加？

记录结果

分别报告个股与组合的共同方差、特质方差和总方差，核对两部分之和。

课堂讨论：持有 100 只股票，风险会接近零吗？

假设每只股票都满足 $R_i = f + \epsilon_i$：共同因子年化波动率为 20%，个股特质波动率为 30%；特质收益彼此不相关，且与因子不相关。

等权持有 100 只股票，组合年化波动率约为多少？

A. 3%　　B. 20.2%　　C. 50%

先投票（约 1 分钟）：持股数量增加时，哪部分方差会缩小？

课堂讨论：持有 100 只股票，风险会接近零吗？

假设每只股票都满足 $R_i = f + \epsilon_i$：共同因子年化波动率为 20%，个股特质波动率为 30%；特质收益彼此不相关，且与因子不相关。

等权持有 100 只股票，组合年化波动率约为多少？

A. 3%　　B. 20.2%　　C. 50%

先投票（约 1 分钟）：持股数量增加时，哪部分方差会缩小？

核对答案

选 B。共同暴露仍为 1，而特质方差随持股数缩小：

$$\sigma_p = \sqrt{0.20^2 + \frac{0.30^2}{100}} \approx 20.2\%.$$

即使持股数继续增加，共同因子风险仍然存在。

实验步骤回顾

- 数据：市净率 pb、流通市值 circ_mv、收盘价与复权因子。
- 暴露：BP、$\log$(流通市值)，每月标准化。
- 回归：本月末特征 $\longrightarrow$ 下一月收益；先 BP，再 BP $+$ 市值。
- 解释：每个回归系数的单位、符号与时间变化；截距与个股 Alpha 的区别。
- 拓展：历史系数与残差 $\longrightarrow$ 因子协方差 $\longrightarrow$ 组合风险分解。

实验提交与自查

- 实践一：完成 L05-00—00B，提交月度持仓、组合收益、净值与调仓图，并比较三个组合的收益与回撤。
- 实践二：完成 L05-01–04，提交单月回归比较表、逐月系数曲线及解释。
- 说明增加市值变量后 BP 系数和调整后 R^2 的变化；选两个符号不同的月份讨论。
- 说明特征日期与收益日期，报告每期样本数量和缺失值处理。
- 拓展：完成 L05-05–06，解释样本协方差的秩限制和等权组合的风险组成。
- 提交填好的脚本及结果；输出目录为 `code/output/lab05/`。

本讲小结

- 共同因子的收益贡献等于暴露乘以因子收益；扣除截距与共同贡献后得到残差。
- 时间序列回归估计个股暴露；基本面横截面回归用已知的股票特征估计因子收益。
- 收益归因使用当期因子收益，预期收益需要估计因子收益的期望，风险估计则需要因子收益的协方差。
- Fama-French 三因子模型把市场、规模、价值作为系统性收益来源。
- APT 用无套利思想说明多个因子可以共同决定预期收益。
- Barra 框架重点在风险解释、风险预测和组合风险控制。
- 将模型用于选股时，还需检验样本外收益并控制组合风险。

参考资料与图示说明

1. Zivot, E. (2012). *Factor Models for Asset Returns*. University of Washington.
   时间序列模型：PDF pp. 9–10；行业横截面模型：pp. 17–19。
2. CFA Institute (2026). *Using Multifactor Models*.
   参阅基本面模型中“先确定暴露，再估计因子收益”的说明。
3. MOSEK. *Portfolio Optimization Cookbook*, Chapter 5: Factor Models.
   参阅期望收益、协方差分解与模型分类。

本讲图示

行业与 APT 数值例子使用假设数据；两张回归示意图用于说明观察维度。单日 BP 散点图由本地股票数据回归生成。参考资料已在相关页面标注。