多因子选股：因子处理与有效性检验

肖亮海

信息科学技术学院

课程 GitHub：`github.com/styluck/quant`

从 BP、规模模型到因子检验

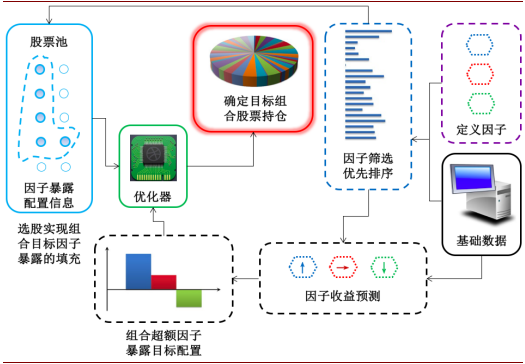
第五讲用月末 BP 和规模暴露解释下一月股票收益：

$$r_{i,t+1} = a_{t+1} + z(BP_{i,t}) f_{BP,t+1} + z(\log MV_{i,t}) f_{Size,t+1} + u_{i,t+1}.$$

- 股票特征来自当期数据；因子收益由横截面回归估计。
- 本讲以 BP、规模和 21 日收益为例，讲特征处理与因子检验。

多因子选股的研究流程

图 6 因子模型搭建与优化过程示意图



资料来源：招商证券

图：招商证券（2017），第 9 页，图 6。

数据与因子：确定股票样本和信息时点，构建股票特征，处理极端值与尺度差异。

因子检验：观察单因子的相关、分组收益和跨期表现，再检验新增因子的解释贡献。

组合构建：根据模型与投资目标确定暴露和持仓，评价收益、成本及风险。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

因子数据与时间口径

数据	全部股票宽表，逐月形成有效样本
股票状态	月末非 ST，价格、成交量、成交额和换手率有效
原始字段	PB、总市值、收盘价与复权因子
特征时点	每月最后一个交易日收盘后
收益区间	从本月末到下一月末

每月末用当时可得的数据构建因子，并检验其与下一月收益的关系。

因子数据预处理流程

步骤	处理内容
1. 构建原始特征	按因子定义计算特征，核对数据口径、单位与信息可得时点。
2. 检查缺失与异常	区分数据缺失、无效记录和有经济含义的负值；保留缺失标记，确定处理方案。
3. 预处理：缩尾	在当期有效观测上计算 MAD 边界，限制极端值的影响。
4. 预处理：标准化或其他赋值	用 Z-score 统一尺度，或按研究需要采用名次、区间赋值。
5. 按需中性化	若需控制行业、规模等影响，回归取残差；用于合成时可再标准化。

各期独立处理，仅使用当期可得信息。若选择填补标准化暴露，应在第 4 步后完成，并保留缺失标记。

构建原始特征：时点与信息可得性

常见情况	错误处理	正确处理
财务数据提前使用	将 4 月才公告的年报利润，用于上一年末的 EP。	按公告可得时间匹配，不能按报告期直接回填。
回填与事后修订	用后一期数据补前一期缺失，或用最新修订值替代历史已知值。	保留历史版本；仅用当时已知数据填补。
跨期预处理	用全样本均值、标准差或分位数，处理早期因子。	截面处理逐期计算；跨期参数仅用历史样本估计。
事后确定股票池	用今天的成分股名单回测过去，或事先排除后来退市的股票。	按历史时点确定成分、上市状态和可交易范围。
用检验期选择规则	看完整段收益后，再选因子、参数或多空方向，并报告该段表现。	在估计期确定规则，再用后续样本检验。

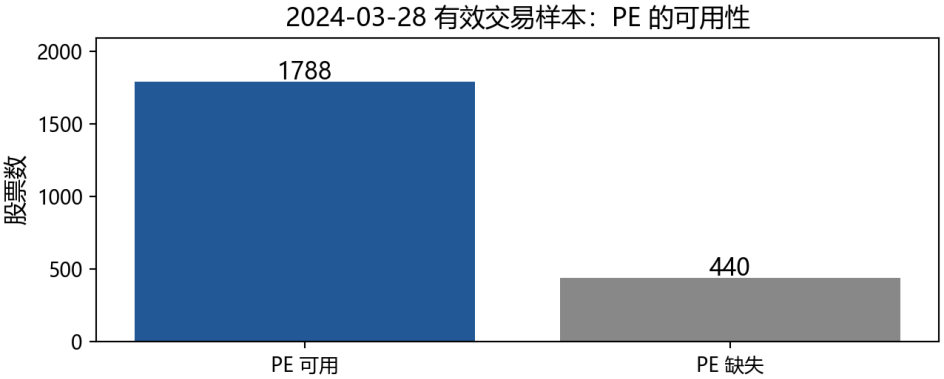
例如，年报若在 4 月 25 日收盘后公告，就不能用于 3 月末的选股。使用当日收盘数据形成信号，也应从之后可成交的时点计算策略收益。

检查缺失与异常：EP 的计算

$$PE = \frac{\text{市值}}{\text{TTM 归母净利润}}, \qquad EP = \frac{\text{TTM 归母净利润}}{\text{市值}}.$$

- 市值为正时，负 PE 表示亏损；相应的负 EP 仍有经济含义。
- 盈利接近零时，PE 可能很大，EP 则接近零；改用 EP 可避免这一比值问题。
- 盈利恰为零时，直接用利润除以市值可得 $EP = 0$；不能对缺失 PE 直接取倒数。
- 本数据集由 Tushare 提供，负 PE 被记为缺失。直接删除缺失 PE 会排除其中的亏损公司。

缺失 PE 会影响多少股票?



2024 年 3 月 28 日，有效交易样本 2228 只，PE 可用 1788 只、缺失 440 只。Tushare 将负 PE 记为缺失，缺失样本中包含亏损公司。如果对缺失 PE 值的股票统一剔除，将会大幅降低有效样本数量。

检查缺失与异常：EP 的计算

观测情况	处理方法
PE 有效且非零	口径一致时可用 $EP = 1/PE$
PE 缺失	优先用当时可得的 TTM 归母净利润除以总市值，保留负 EP
构建多因子输入	在有效 EP 上缩尾、标准化，再补充缺失暴露与指示变量

财务信息可用时，直接构造 EP；信息不足时，填充缺失暴露以补齐模型输入。

财务数据按公告可得时间匹配，记录有效值、缺失标记及填充比例。

缺失 EP 的几种处理思路

思路	做法	需要考虑的问题
补充财务信息	用可得利润和市值构造 EP	数据口径、公告时点与获取成本
统一赋分	标准化后填 0 或 -1	对缺失股票作何种评分假设
当期行业内填充	用同行中位数等替代	同行盈利水平能否代表缺失股票

预处理：缩尾

极端观测可能主导整个截面的统计结果。

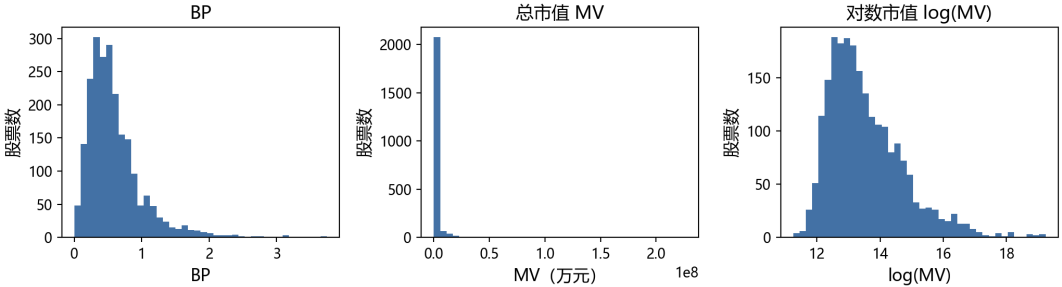
- 极端值拉高标准差，使多数股票标准化后的因子值集中在较窄区间。
- 极端值还会放大 Pearson 相关系数和回归系数的误差。
- 缩尾将超出边界的数值替换为边界值，保留股票，同时压低尾部影响。

例如，六只股票的 BP 为

$$0.2, \quad 0.3, \quad 0.4, \quad 0.5, \quad 0.6, \quad 3.0.$$

最后一个观测远离其余股票。缩尾后，可重新比较因子分布、相关系数和回归结果。

预处理缩尾：BP 与市值的截面分布



2024 年 3 月 28 日，同一批有效股票。市值具有明显右侧长尾；规模因子采用对数市值。下文分别对 BP 和 log(MV) 展示缩尾、标准化效果。

均值 $\pm$ 3 倍标准差缩尾

在同一时点的股票截面内，计算因子均值 $\bar{x}$ 和标准差 s，设置上下界：

$$L = \bar{x} - 3s, \qquad U = \bar{x} + 3s.$$

将边界外的数值替换为边界值：

$$x_i^{win} = \min\{\max(x_i, L), U\}.$$

- 正态分布约有 99.7% 的观测落在均值上下 3 倍标准差内，据此设置缩尾范围。
- 计算简单；极端值也会影响均值和标准差，使缩尾边界向外扩张。
- MAD 缩尾改用中位数和绝对偏差的中位数确定边界，对极端值更稳健。

MAD 缩尾

在同一交易日的股票截面内，计算中位数与绝对偏差的中位数：

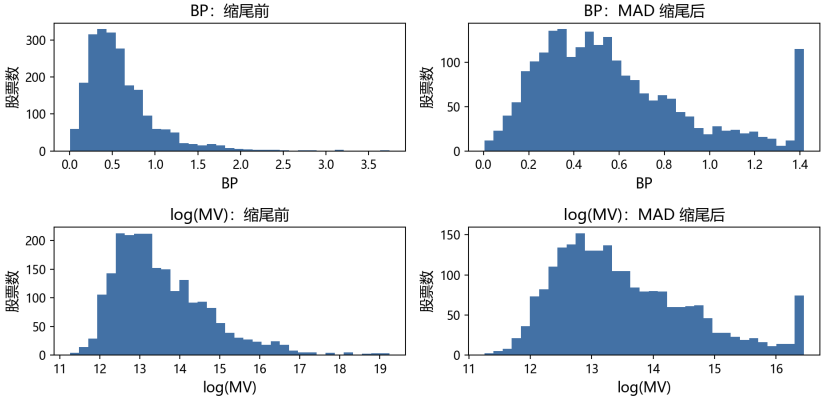
$$m = \text{median}_i(x_i), \qquad MAD = \text{median}_i\,|x_i - m|.$$

取 $L = m - 3 \times 1.4826MAD$、$U = m + 3 \times 1.4826MAD$，令

$$x_i^{win} = \min\{\max(x_i, L), U\}.$$

- 以 BP、对数市值为例，逐日独立计算边界。
- 缩尾保留股票，将边界之外的数值替换为边界值；截尾则删除记录。
- 为什么系数采用 1.4826?

MAD 缩尾：BP 与对数市值



股票数不变，尾部数值被压到边界，边界处可能出现堆积。

统一尺度：直接相加有什么问题？

直接合成时，尺度会影响评分。以 $S = BP + MV$ 为例：

		市值以万元计		市值以亿元计	
股票	BP	MV	评分 S	MV	评分 S
A	0.4	100000	100000.4	10.0	10.4
B	1.2	95000	95001.2	9.5	10.7

- 以万元计时，市值数值远大于 BP，A 的评分更高。
- 换成亿元后，BP 的相对影响增大，B 的评分更高。

合成前，先将不同特征转换到可比较的尺度。

三种赋值方法：数值、名次与区间

对每个时点的股票截面，分别处理各项特征：

方法	做法	保留的信息
Z-score	$z_{i,t} = (x_{i,t} - \bar{x}_t)/s_t$	数值距离的比例
名次赋值	$(rank_{i,t} - 1)/(N_t - 1) - 0.5$	股票之间的排序
等宽赋值	将最小值至最大值分为 N 个等宽区间，各区间按顺序赋予 $[-0.5, 0.5]$ 内的等距分数	所处的数值区间

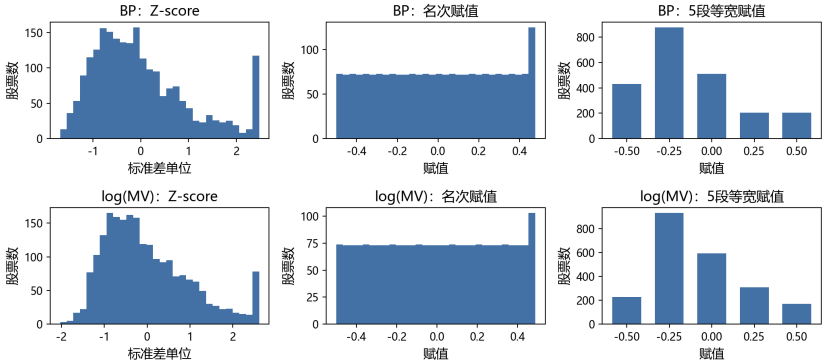
$\bar{x}_t$、s_t 为当期截面均值和样本标准差，N_t 为有效股票数；并列值采用平均秩。

Z-score 为 1，表示高于截面均值一个标准差。

lab05 对 PB 和市值分别排名后相加，使两项都以名次计分。

赋值方法参考：招商证券（2017），第 11 页。

三种赋值的截面效果：BP 与对数市值



2024 年 3 月 28 日，三种方法使用缩尾后的同一批股票。

- Z-score 保留分布形态，横轴变为标准差单位。
- 名次赋值按排序展开；缩尾产生的并列值仍取相同分数。
- 等宽赋值集中为五个离散分数，各区间的股票数不同。

中性化的动机

某品牌的眼霜历史投放数据中，**35–44 岁女性占 80%**。从这些数据得到的需求评分，可能较多地反映历史上主要触达的人群。

- 年龄、性别与需求评分相关，模型容易把投放人群的构成与需求差异混在一起。
- 即使删除年龄、性别，浏览关键词、成分偏好等特征仍可能间接包含这些信息。

若要比较**控制年龄、性别后的需求差异**，可将评分对这些变量回归，用残差表示高于或低于同类人群预期水平的部分。

股票因子也类似：BP 可能包含行业、规模差异。中性化后，可比较**相同行业、相近规模条件下的相对估值**。

中性化的本质：回归法

中性化的通用做法是**回归取残差**，分三步：

1. **确定变量**：待中性化的因子作为因变量 f，需要排除的影响（行业、规模等）作为自变量；
2. **线性回归**：估计 $f = Z\gamma + u$，得到拟合值 $\hat{f} = Z\hat{\gamma}$；
3. **计算残差**：$f^{\text{neutral}} = f - \hat{f}$，即实际值减去预测值。

行业内去均值

不同行业的 BP 水平可能不同。若希望比较一只股票相对于同行的位置，可减去所在行业的平均 BP：

$$BP_i^{\text{demean}} = BP_i - \overline{BP}_{g(i)}.$$

- $g(i)$ 表示股票 i 所属的行业，均值在同一天、同一行业内计算；
- 正值表示高于同行平均水平，负值表示低于同行平均水平；
- 处理后，每个行业的均值为零。

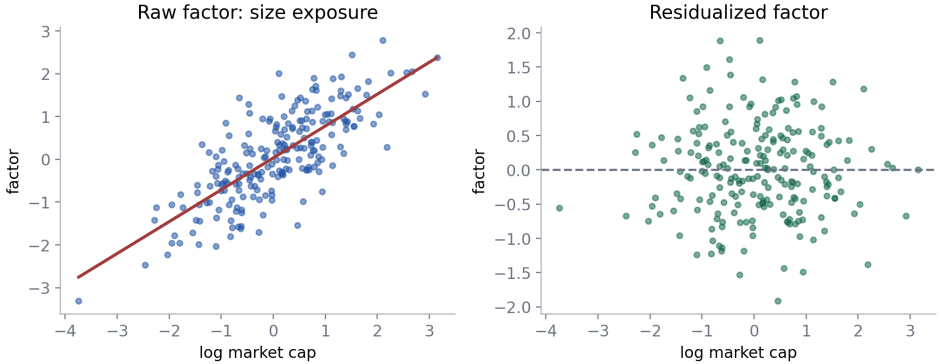
回归中性化

设待处理的因子为 f，行业、规模等控制变量组成矩阵 Z：

$$f = Z\gamma + u, \qquad f^{\text{neutral}} = \hat{u} = f - Z\hat{\gamma}.$$

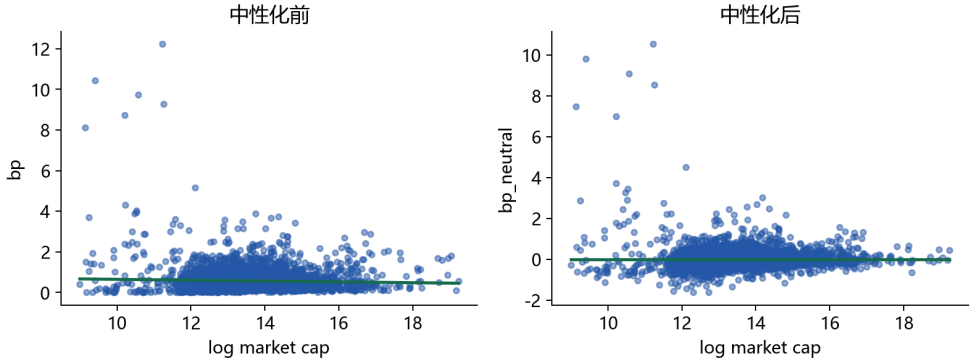
- Z 可包含行业虚拟变量、对数市值等；
- 残差保留原始因子中未被控制变量线性解释的部分；
- OLS 残差与 Z 的各列正交。

中性化前后



模拟数据中，取回归残差后，因子与对数市值的样本线性相关降为零。

行业与规模中性化：实例



5195 只股票中，中性化后 BP 与对数市值的样本相关系数由 -0.044 降至约 0。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

因子与收益的相关：IC

构建因子后要回答：**同一时点因子值不同的股票，下一期收益是否也有系统差异?**

例如，月末 BP 较高的股票，下一月收益是否倾向于更高？可将每只股票的当期因子值与下一期收益配对，在股票截面上计算相关系数：

$$IC_t = \mathrm{Corr}_i\big(x_{i,t}, r_{i,t+1}\big).$$

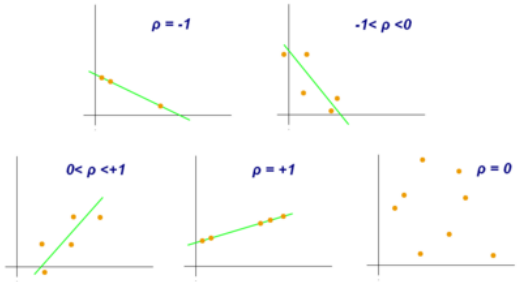
- **方向**：正值表示高因子值倾向于对应高收益，负值表示反向关联。
- **强度**：用一个无量纲指标概括整个截面的关联程度，便于比较不同因子和不同时期。
- **跨期表现**：逐期计算 IC，观察这种关系能否持续。

Pearson IC 衡量因子值与下一期收益的线性关联；Rank IC 衡量二者排序的一致性。

Pearson 相关系数

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2}\sqrt{\sum_i (y_i - \bar{y})^2}}.$$

- 协方差衡量共同变化，再用两列各自的标准差消除单位。
- 正值表示同向线性关联，负值表示反向线性关联。
- $-1 \le r \le 1$；任一列恒定时未定义。
- 零相关不等于独立。



Spearman 秩相关系数

分别将两列有效配对观测转换成名次，再计算 Pearson：

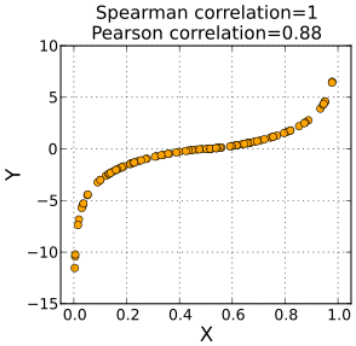
$$r_s = \mathrm{Corr}\big(\mathrm{rank}(x), \mathrm{rank}(y)\big).$$

- 秩相关衡量排序的一致性，不保留数值之间的距离。
- 严格递增变换不改变排序，因此不改变 Spearman 系数。
- 无并列值时，令 $d_i = R_i - S_i$，有

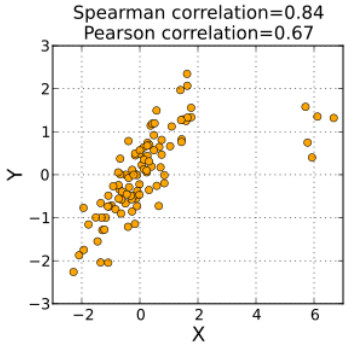
$$r_s = 1 - \frac{6\sum_i d_i^2}{N(N^2-1)}.$$

- 有并列值时采用平均秩；如 $(1, 2, 2, 4)$ 的秩为 $(1, 2.5, 2.5, 4)$。

秩相关的适用情形

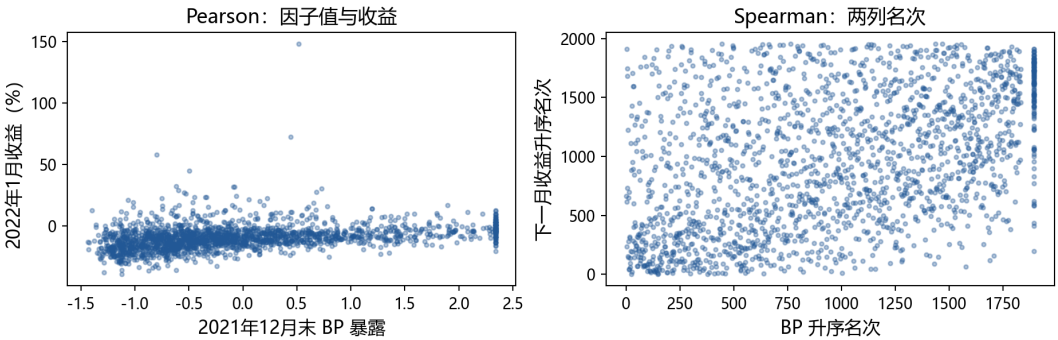


单调非线性关系：次序完全一致，Pearson 小于 1。



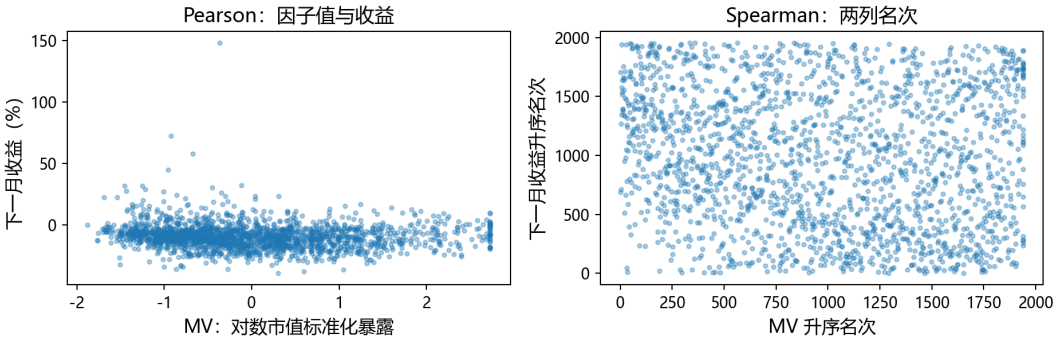
少数偏离点改变数值距离，秩相关受到的影响相对较小。

同一截面：BP 因子值与名次



2021 年 12 月末 BP 与 2022 年 1 月收益。左图比较数值，右图比较相同配对股票的名次。

同一截面：MV 因子值与名次



同为 2021 年 12 月末特征与 2022 年 1 月收益。MV 以对数市值标准化暴露入模；左图比较数值，右图比较相同股票的名次。两图分别对应 Pearson IC 与 Rank IC。

预处理对 IC 的影响

同一样本上的变换	Pearson IC	Rank IC
Z-score	不变	不变
严格递增非线性变换	通常改变	不变
缩尾、分箱	可能改变	并列名次可能改变
回归中性化	可能改变	可能改变

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

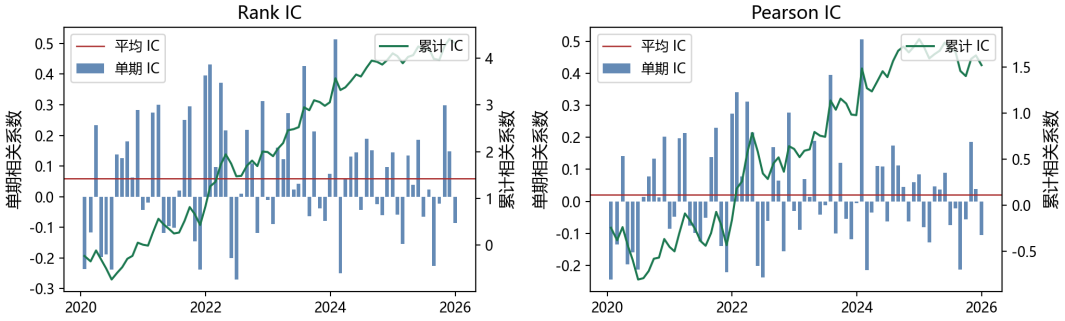
IC 时间序列与累计 IC

把各期 IC_t 按时间排列，累计 IC 定义为

$$C_T = \sum_{t=1}^{T} IC_t.$$

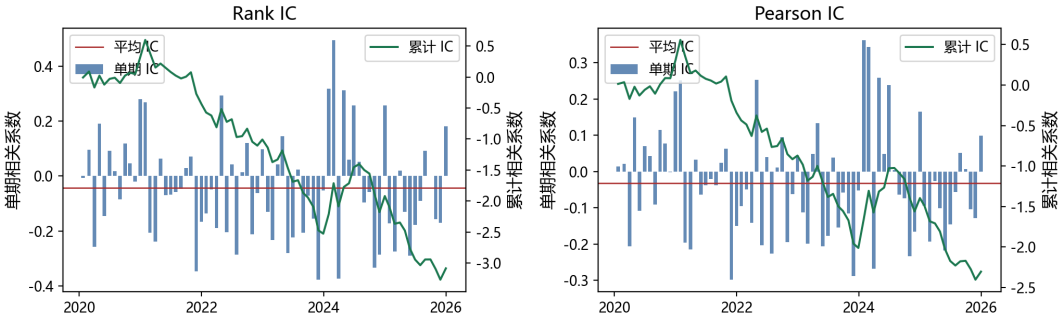
- 逐期 IC 显示方向与波动，便于识别异常月份。
- 累计曲线上升、横盘、下降，分别反映阶段内正、负 IC 的累积关系。
- 累计 IC 的斜率反映该阶段 IC 的平均水平。

BP 的逐月 IC 与累计 IC



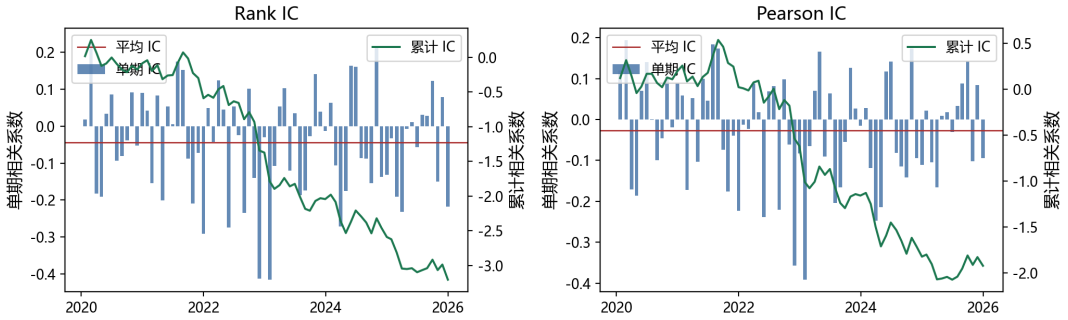
蓝柱为单期 IC、红线为平均 IC，绿色曲线为累计 IC（右轴）；左图为 Rank IC，右图为 Pearson IC。

MV 的逐月 IC 与累计 IC



规模因子为缩尾、标准化后的对数市值。左图为 Rank IC，右图为 Pearson IC；蓝柱为逐月 IC，红线为平均 IC，绿线为累计 IC（右轴）。

动量的逐月 IC 与累计 IC



动量以过去 21 个交易日的复权收益构建，经缩尾、标准化后，与下一月收益配对。左图为 Rank IC，右图为 Pearson IC；蓝柱为逐月 IC，红线为平均 IC，绿线为累计 IC（右轴）。

跨期汇总指标

$$\overline{IC} = \frac{1}{T}\sum_{t} IC_t, \qquad ICIR = \frac{\overline{IC}}{s(IC)}, \qquad p_+ = \frac{\#\{t : IC_t > 0\}}{T}.$$

- 均值描述平均关联方向与强度；标准差描述跨期波动。
- 正值比例描述 IC 为正的有效期数占比，负均值也可能对应稳定的反向关系。
- ICIR 是均值与标准差之比，本讲不年化；零标准差时不定义。
- 同时报告期数、股票数和覆盖率；均值检验还需考虑序列相关。

三个因子的 IC 汇总

	Pearson IC				Rank IC			
因子	均值	标准差	ICIR	p_+	均值	标准差	ICIR	p_+
BP	0.0211	0.1619	0.1305	50.0%	0.0601	0.1871	0.3210	58.3%
MV	-0.0320	0.1505	-0.2128	41.7%	-0.0428	0.1877	-0.2283	41.7%
动量（21 日）	-0.0267	0.1321	-0.2021	45.8%	-0.0445	0.1422	-0.3130	43.1%

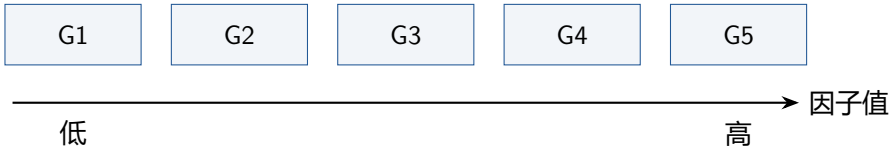
分组检验：观察收益结构

IC 概括因子与收益的整体关联。进一步将股票按因子值分组，可以看清**收益差异出现在排序的哪些位置，以及差异有多大**。

- **观察收益结构**：从低值组到高值组，平均收益是逐步上升、逐步下降，还是中间高、两端低？
- **衡量收益幅度**：用各组的平均收益比较经济上的差异，例如高值组与低值组每月相差多少个百分点。
- **定位选股范围**：判断收益差异遍布整个排序，还是主要集中在最高或最低的一组，为确定选股范围提供依据。

逐期重新分组并绘制净值，还可以观察组间差异形成的时间及持续性。

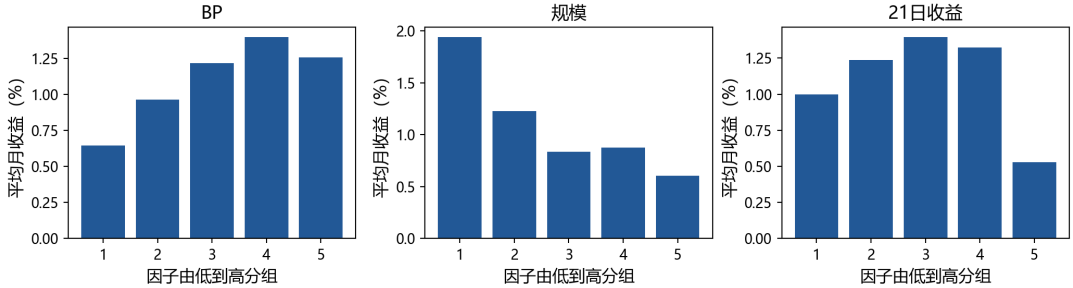
分组检验：观察排序对应的收益结构



1. 每个形成日按因子值从低到高排序，分为近似等数量的五组。
2. 计算每组下一期的等权平均收益，逐期重新分组。
3. 汇总组均收益并绘制各组净值，观察单调、反向或非单调结构。

G1 为低值组，G5 为高值组。

分组平均收益：整个排序还是局部差异？



比较三个特征的五组平均月收益。逐组上升或下降表示较清楚的单调结构；若差异集中在两端，整体 IC 未必能完整体现。

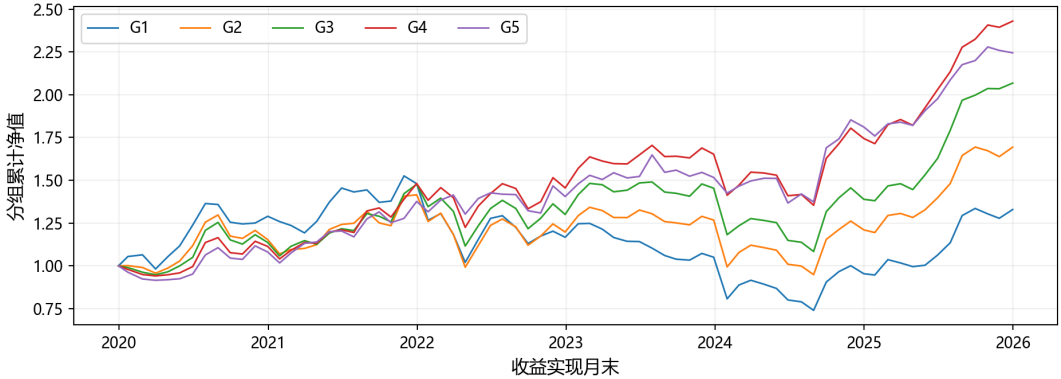
分组净值：收益差异何时形成?

组 q 的单期等权收益及累计净值为

$$R_{q,t+1} = \frac{1}{N_{q,t}} \sum_{i \in G_{q,t}} r_{i,t+1}, \qquad V_{q,T} = \prod_{t=0}^{T-1} (1 + R_{q,t+1}).$$

- 平均收益比较长期水平；净值曲线显示差异形成的时间和回撤过程。
- 检查组间差异是否持续，是否集中在某段行情。

BP 五组累计净值



G1 为低 BP，G5 为高 BP。逐月重新分组、恢复组内等权；初始净值为 1。

多空检验：相对表现

单组收益包含股票共同涨跌的影响。比较排序两端的收益差，可以考察**因子能否区分相对表现较好与较差的股票**。

多头组收益	空头组收益	多空收益
5%	3%	2%
−3%	−5%	2%

- **比较相对表现**：两组共同的涨跌可在相减时部分抵消，突出排序两端的收益差异。
- **观察跨期表现**：将多空收益连成时间序列，考察平均收益、波动与净值回撤。

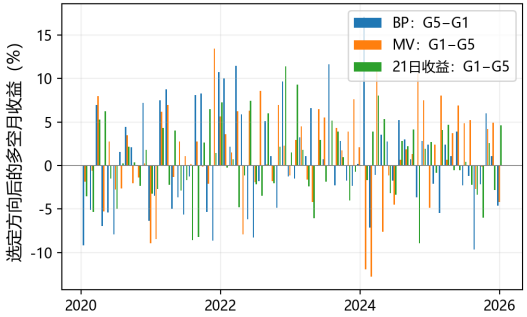
多空组合：先确定多头与空头

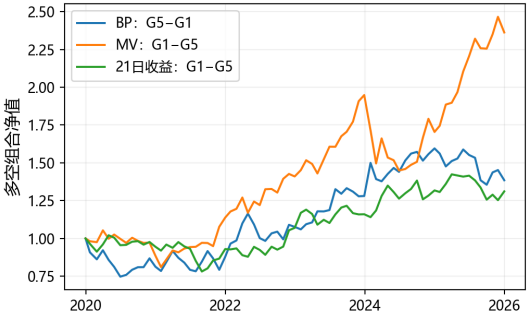
比较高值组与低值组的平均收益，做多较高的一组，做空较低的一组：

$$R_{t+1}^{LS} = \begin{cases} R_{G5,t+1} - R_{G1,t+1}, & \bar{R}_{G5} \geq \bar{R}_{G1}, \\ R_{G1,t+1} - R_{G5,t+1}, & \bar{R}_{G1} > \bar{R}_{G5}. \end{cases}$$

- 确定多空方向后，各期保持一致，按 $V_{t+1} = V_t(1 + R_{t+1}^{LS})$ 计算净值。
- 本例多、空名义金额各为期初净资产的 1 倍，现金收益与费用设为 0。
- 样本外检验时，在估计期确定多空方向，检验期固定使用。

三个特征的多空收益与净值





BP 做多 G5、做空 G1；规模和 21 日收益做多 G1、做空 G5。左图为逐月多空收益，右图为累计净值。

单因子检验的证据

IC、Rank IC	特征与未来收益的整体关联
逐期及累计 IC	关联出现在哪些阶段，是否稳定
分组平均收益	排序对应的收益结构，是否单调
分组净值	组间差异的积累过程与回撤
多空收益	选定方向后两端组的收益差及其波动

结合这些结果判断方向、稳定性和收益幅度，再看因子在模型中的增量作用。

BP 行业中性化：IC 与稳定性

逐月对缩尾后的 BP 作申万一级行业内去均值，比较 2020–2025 年的 72 个月。两组使用各月行业分类可得的相同股票样本。

指标	BP	均值	标准差	ICIR	p_+
Pearson IC	中性化前	0.0223	0.1632	0.1367	50.0%
Pearson IC	行业去均值	0.0242	0.0913	0.2650	56.9%
Rank IC	中性化前	0.0603	0.1879	0.3211	59.7%
Rank IC	行业去均值	0.0540	0.1045	0.5162	65.3%

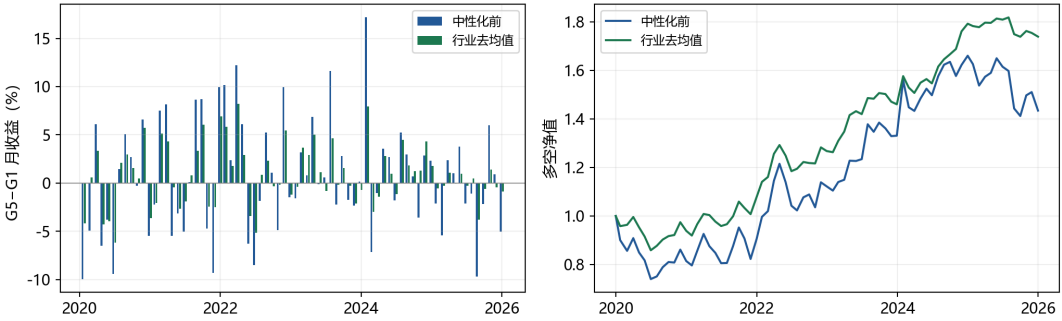
- Pearson IC 均值略升，Rank IC 均值略降。
- 两类 IC 的波动均明显减小，ICIR 和正值月份占比上升。

BP 行业中性化：五组收益与净值



上图为五组平均月收益，下图为逐月重分组的净值。行业去均值后，平均收益从 G1 到 G5 逐组上升。

BP 行业中性化：多空收益与净值



两组均做多 G5、做空 G1。行业去均值后，平均月收益由 0.66% 升至 0.82%，月收益标准差由 5.78% 降至 3.15%，期末净值由 1.43 升至 1.74。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

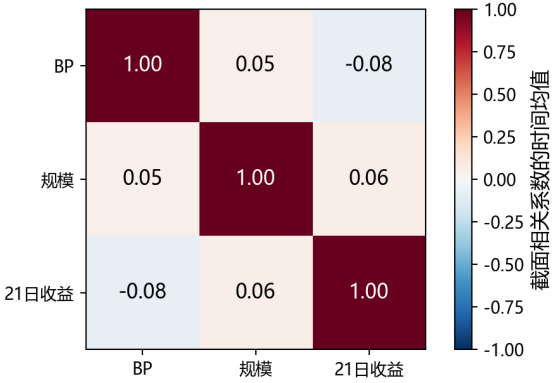
单因子有效与新增信息

BP、EP 都可能具有较好的单因子表现，但可能重复表达估值信息。

- 单因子检验观察该特征自身与收益的关联。
- 增量检验考察已有因子之外，它还保留多少与收益有关的信息。
- 先检查因子间相关，再检验候选因子对剩余收益差异的解释。

参考：招商证券（2017），第 7、11–12 页。

因子相关性：初步观察信息重复



图中为逐月截面相关系数的时间均值。相关性低表示特征不同；这些差异是否与收益有关，仍需进一步检验。

两个残差：剩余收益与新增特征

固定一个截面，将常数列并入已有特征矩阵 X：

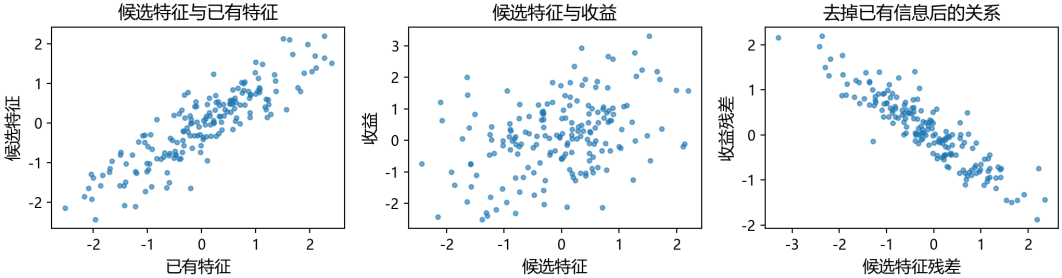
$$r = X\widehat{\beta} + u, \qquad x_{new} = X\widehat{\gamma} + v.$$

$$u = bv + \varepsilon.$$

- u：已有模型未解释的收益差异。
- v：候选特征未被已有特征线性解释的部分。
- 用 v 解释 u，检验新增信息与剩余收益差异之间的关系。

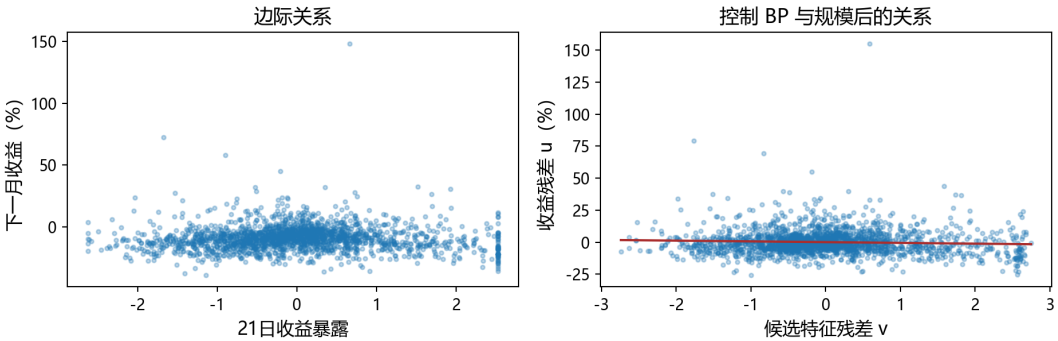
同一样本、含截距 OLS 下，该斜率等于直接将候选特征加入多元回归后的系数。

增量关系的模拟示例



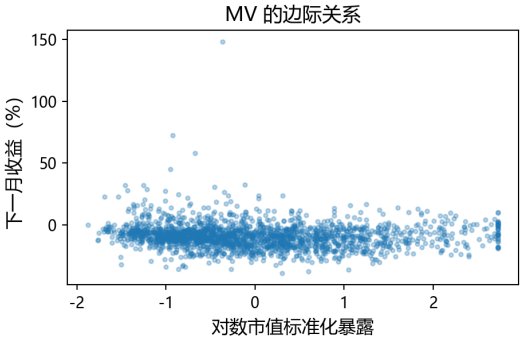
模拟数据：候选特征与已有特征相关，边际收益关系混合了两部分影响。分别去掉已有信息后，可观察新增特征与剩余收益的关系。

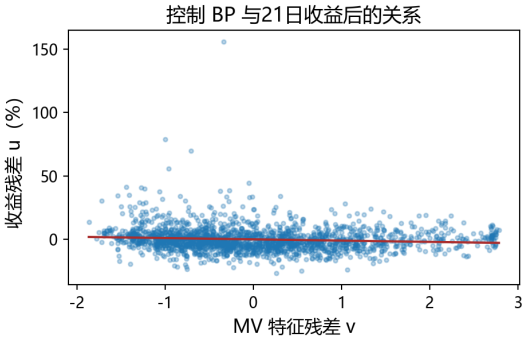
实际截面中的残差关系：21 日收益



2021 年 12 月末特征与 2022 年 1 月收益。以 BP、规模为控制变量，分别对 21 日收益特征和下一月收益残差化。右图斜率对应多元模型中的候选特征系数。

实际截面中的残差关系：MV



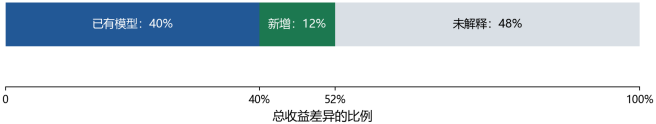


2021 年 12 月末特征与 2022 年 1 月收益。以 BP、21 日收益为控制变量，分别对 MV 暴露和下一月收益残差化。右图斜率对应多元回归中的规模系数。

新增解释度的计算

若已有模型解释了总收益差异的 40%，新增特征解释了剩余部分的 20%，则

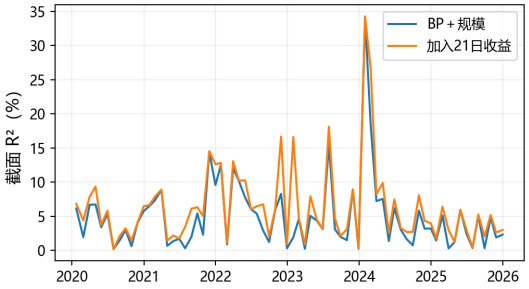
$$\Delta R^2 = (1 - 0.40) \times 0.20 = 0.12, \qquad R^2_{new} = 0.52.$$

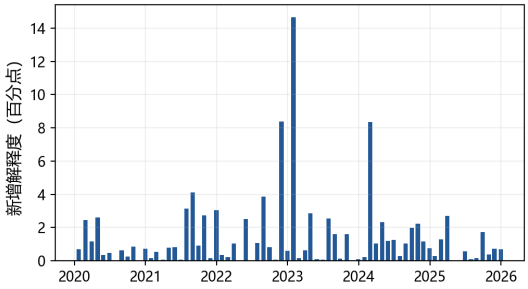


$$R^2_{new} = R^2_{old} + (1 - R^2_{old}) R^2_{increment}.$$

增量占比以剩余差异为分母。两个 OLS 模型使用相同股票样本与收益变量。

加入 21 日收益后的解释度变化





同一截面样本上的二因子与三因子模型。普通样本内 R^2 随变量增加不会下降，仍需检查调整后 R^2、系数稳定性与后续样本表现。

因子进入顺序与贡献归属

进入顺序	首先解释	随后检验
规模 $\rightarrow$ BP	规模对应的收益差异	BP 在规模之外的贡献
BP $\rightarrow$ 规模	BP 对应的收益差异	规模在 BP 之外的贡献

- 增量贡献取决于已有变量。
- 同一样本、相同最终变量的线性 OLS，进入顺序不改变最终拟合，但改变逐步归因。
- 每步若再筛选或进行非线性赋值，最终模型也可能不同。

逐层增量解释思路参考：招商证券（2017），第 12 页。

收益解释与收益预测

已实现收益的解释模型为

$$r_{i,t+1} = a_{t+1} + \sum_k z_{i,k,t} f_{k,t+1} + u_{i,t+1}.$$

形成预测还需要在 t 时点给出系数预测：

$$\widehat{r}_{i,t+1|t} = \widehat{a}_{t+1|t} + \sum_k z_{i,k,t} \widehat{f}_{k,t+1|t}.$$

- 用后续样本评价模型的预测效果。
- 合成后的预测或评分也应重新做 IC、分组与多空检验。
- 本实验以估计期平均回归系数形成检验期预测，系数正负由数据估计。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

实验内容与数据

$$BP_{i,t} = 1/PB_{i,t}, \quad Size_{i,t} = \log MV_{i,t}, \quad Ret21_{i,t} = P^{adj}_{i,t}/P^{adj}_{i,t-21} - 1.$$

1. 构建 BP、规模、21 日收益，比较缩尾、标准化及赋值方法。
2. 计算 IC、累计 IC、五组收益与高减低收益。
3. 比较 BP + 规模与加入 21 日收益后的模型，解释系数和新增解释度。
4. 用 2020–2022 估计系数，在 2023–2025 检验预测。

使用 lab05 实践二的全部股票宽表，逐月筛选有效样本。

实验文件与输出

`lab06_framework.py`	学生模板，完成 L06-01 至 L06-06
`lab06_answer.py`	参考实现
`lab06_core.py`	数据、月份对齐、回归循环与导出
`lab06_figures.py`	分组统计与结果绘图

文件位于 `code/lab06/`；输出位于 `code/output/lab06/` 的 `student/` 或 `reference/`。

提交暴露表、IC 表、分组与多空收益表、回归结果，以及相应图形和简短分析。

L06-01 至 L06-03：构建与处理特征

```
def make_factors(panel):
    return pd.DataFrame({"bp": 1 / panel.pb,
                         "size": np.log(panel.total_mv),
                         "ret21": panel.ret21}, index=panel.index)

panel["bp_mad"] = panel.groupby("date")["bp"].transform(winsor_mad)
panel["bp_mad_z"] = panel.groupby("date")["bp_mad"].transform(zscore)
```

在模板中补全缩尾、Z-score 和秩赋值函数；计算标准化前后的均值、标准差，并查看分布图。

L06-04：IC 与分组收益

```
pair = cross[["bp_mad_z", "next_ret"]].dropna()
ic = pair.bp_mad_z.corr(pair.next_ret)
rank_ic = pair.bp_mad_z.rank().corr(pair.next_ret.rank())

rank = pair.bp_mad_z.rank(method="first")
group = pd.qcut(rank, 5, labels=[1, 2, 3, 4, 5])
group_ret = pair.next_ret.groupby(group, observed=True).mean()
high_low = group_ret.loc[5] - group_ret.loc[1]
```

先按股票代码排序，以代码顺序处理并列边界。将每期统计连成时间序列，分别计算累计 IC 与收益净值。

单因子结果：保留关联的正负

样本段	特征	平均 IC	平均 Rank IC	正值比例
估计期	BP	0.017	0.055	55.6%
估计期	规模	-0.024	-0.028	44.4%
估计期	21 日收益	-0.017	-0.038	47.2%
检验期	BP	0.025	0.065	61.1%
检验期	规模	-0.040	-0.058	38.9%
检验期	21 日收益	-0.036	-0.051	38.9%

结合 IC 的均值、正值比例、分组与高减低结果，解释三个特征的收益关联。

L06-05：候选特征的残差

```
controls = cross[["bp_mad_z", "size_mad_z"]]
v = residualize(cross.ret21_mad_z, controls)
u = residualize(cross.next_ret, controls)

slope = (v @ u) / (v @ v)
```

分别残差化特征和收益。比较该斜率与三因子回归中 21 日收益的系数，验证二者一致。

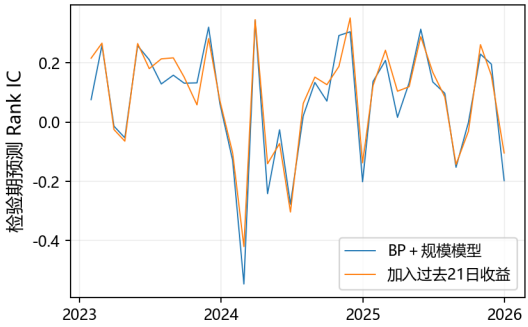
L06-06：回归系数与检验期预测

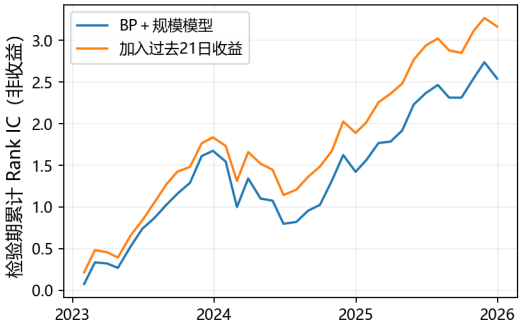
```
params, r2 = fit_model(cross.next_ret,
    cross[["bp_mad_z", "size_mad_z", "ret21_mad_z"]])

# Estimate each training month, then average the coefficients.
weights = training_coefficients.mean()
prediction = weights["const"] + test_exposures @ weights[test_exposures.columns]
```

使用相同股票样本比较两个模型；以估计期的平均系数作为检验期预测权重。

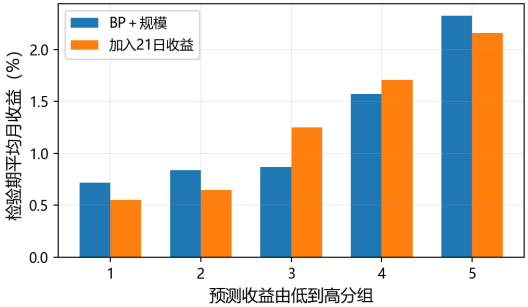
检验期预测：两个模型的比较

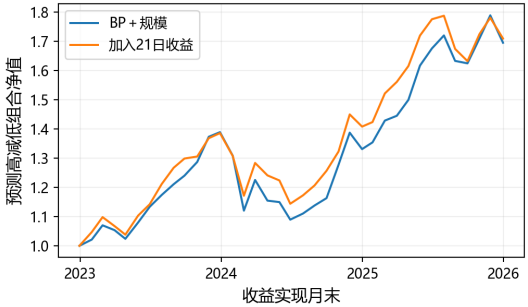




预测采用 2020–2022 的平均月度回归系数；2023–2025 固定使用这些系数。观察新增特征是否改善后续收益排序。

多因子预测的分组与多空检验





按检验期预测收益从低到高分组，比较组均收益和 G5—G1 净值。

实验讨论

- 处理前后的哪些变化来自数值尺度，哪些来自排序或样本变化？
- IC、分组收益与高减低组合是否给出一致的关联方向？差异集中在哪些阶段？
- 新增特征与已有特征是否重复？它解释了多少剩余收益差异？
- 样本内解释度的增加，是否对应检验期预测的改善？还需要哪些交易与成本检验？