多因子选股：因子处理与有效性检验

肖亮海

信息科学技术学院

课程 GitHub：`github.com/styluck/quant`

从 BP、规模模型到因子检验

第五讲用月末 BP 和规模暴露解释下一月股票收益：

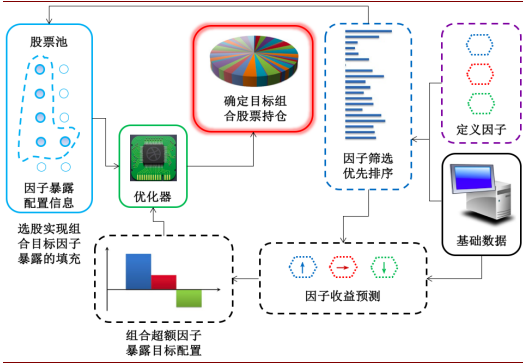
$$r_{i,t+1} = a_{t+1} + z(BP_{i,t}) f_{BP,t+1} + z(\log MV_{i,t}) f_{Size,t+1} + u_{i,t+1}.$$

- 股票特征来自当期数据；因子收益由横截面回归估计。
- 本讲讨论特征如何处理，以及如何评价它与未来收益的关系。
- 以 BP、规模和过去 21 日收益为例，进一步考察新增特征的解释贡献。

实践二代码：`code/lab05/lab05_practice2_example.py`。

多因子选股的研究流程

图 6 因子模型搭建与优化过程示意图



资料来源：招商证券

图：招商证券（2017），第 9 页，图 6。

数据与因子：确定股票样本和信息时点，构建股票特征，处理极端值与尺度差异。

因子检验：观察单因子的相关、分组收益和跨期表现，再检验新增因子的解释贡献。

组合构建：根据模型与投资目标确定暴露和持仓，评价收益、成本及风险。

本讲集中讨论因子处理与检验。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

因子数据与时间口径

数据	沿用实践二 example 读取的全部股票宽表，逐月形成有效样本
股票状态	月末非 ST，价格、成交量、成交额和换手率有效
原始字段	PB、总市值、收盘价与复权因子
特征时点	每月最后一个交易日收盘后
收益区间	从本月末到下一月末

特征计算与预处理使用当期可得数据；下一期收益在完成特征处理后合并。

三个股票特征

$$BP_{i,t} = \frac{1}{PB_{i,t}}, \qquad Size_{i,t} = \log MV_{i,t},$$

$$Ret21_{i,t} = \frac{P^{adj}_{i,t}}{P^{adj}_{i,t-21}} - 1.$$

- BP 描述账面权益相对市值的水平；规模越大，表示公司市值越大。
- 21 日收益描述近期价格变化，正值表示上涨，负值表示下跌。
- 保留各特征的原始含义，收益关联的正负由后续检验给出。

BP 与规模的示例使用正 PB、正市值记录。

缺失值与极端观测

- 先检查字段、单位、重复记录及缺失来源，修复可确认的数据错误。
- 缺少计算所需的原始字段时，记录缺失并按当期样本规则处理。
- 有效的极端观测可能影响均值、标准差和回归结果，可比较缩尾前后的分布。
- 保留原始特征与处理后特征；下一期收益缺失不填为零。

MAD 缩尾

在每个月末的股票截面内，计算中位数与绝对偏差的中位数：

$$m_t = \text{median}_i(x_{i,t}), \qquad MAD_t = \text{median}_i\,|x_{i,t} - m_t|.$$

取边界 $L_t = m_t - 3 \times 1.4826 MAD_t$、$U_t = m_t + 3 \times 1.4826 MAD_t$，令

$$x_{i,t}^{win} = \min\{\max(x_{i,t}, L_t), U_t\}.$$

- 缩尾保留记录，将阈值外数值替换成边界；截尾则删除记录。
- 中位数与 MAD 对少量极端值较稳健；阈值需固定并记录。
- 本实验在 $MAD = 0$ 时保留原值。

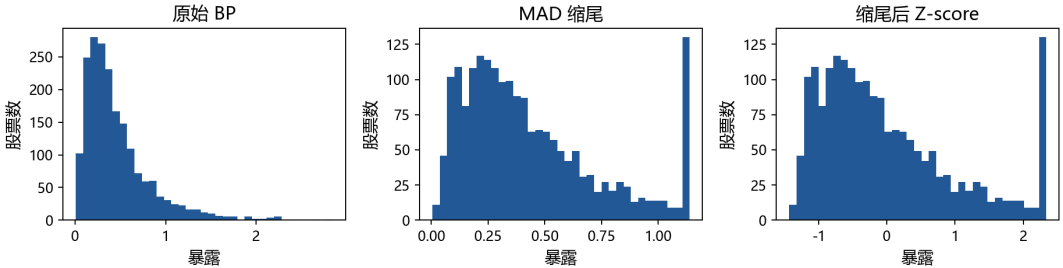
横截面标准化

对同一月末的有效股票计算：

$$z_{i,t} = \frac{x_{i,t} - \bar{x}_t}{s_t}, \qquad s_t^2 = \frac{1}{N_t - 1} \sum_i (x_{i,t} - \bar{x}_t)^2.$$

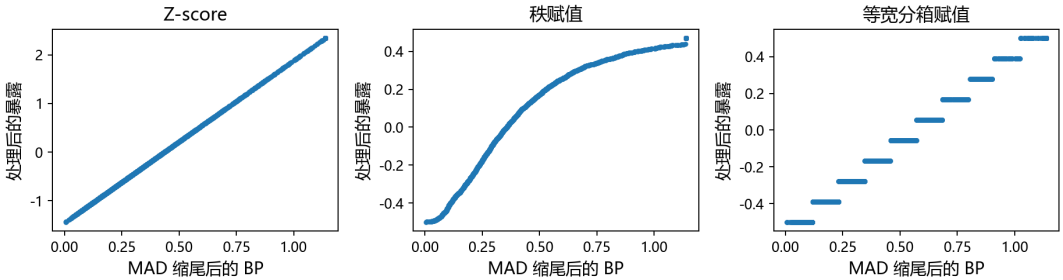
- 去均值后除以标准差，统一位置和尺度。
- $z = 1$ 表示高于当期截面均值一个标准差。
- 标准化保留排序和距离比例，不会消除偏态或行业、市值暴露。
- 标准差为零时无可用尺度，结果记为缺失。

BP：缩尾与标准化前后



2021 年 12 月末的有效股票截面。缩尾压缩尾部数值；Z-score 进一步改变位置和尺度。

暴露赋值：数值、名次与区间



Z-score 保留距离比例；秩赋值保留次序；等宽分箱将区间内数值赋为同一水平。本图分箱数为 10，等宽分箱与等数量分组不同。

赋值方法参考：招商证券（2017），第 11 页。

中性化：控制其他特征

若希望控制规模和行业的线性影响，可逐期估计：

$$x_{i,t} = a_t + b_t \log MV_{i,t} + \sum_{g=1}^{G-1} c_{g,t} D_{ig,t} + e_{i,t}.$$

- 残差表示控制变量未能线性解释的特征部分。
- 标准化只调整位置与尺度；回归中性化改变了特征所包含的信息。
- 同一 OLS 样本内，残差与各列控制变量正交。
- 控制变量取决于研究目的；本实验以 BP 和规模为已有特征，不加入缺少历史分类数据的行业变量。

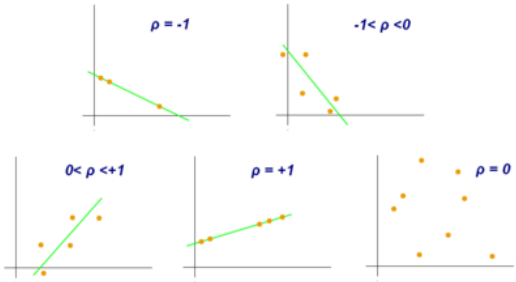
本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

Pearson 相关系数

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2}\sqrt{\sum_i (y_i - \bar{y})^2}}.$$

- 协方差衡量共同变化，再用两列各自的标准差消除单位。
- 正值表示同向线性关联，负值表示反向线性关联。
- $-1 \leq r \leq 1$；任一列恒定时未定义。
- 零相关不等于独立。



图：统计分析第四章“数据的分类分析方法”，第 16 页。

Spearman 秩相关系数

分别将两列有效配对观测转换成名次，再计算 Pearson：

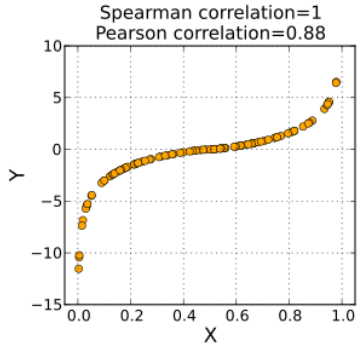
$$r_s = \mathrm{Corr}\big(\mathrm{rank}(x), \mathrm{rank}(y)\big).$$

- 秩相关衡量排序的一致性，不保留数值之间的距离。
- 严格递增变换不改变排序，因此不改变 Spearman 系数。
- 无并列值时，令 $d_i = R_i - S_i$，有

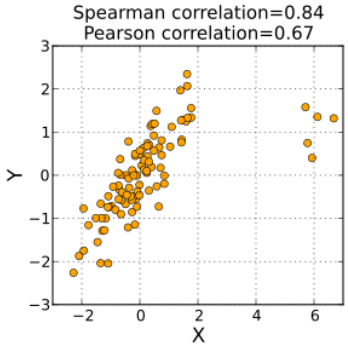
$$r_s = 1 - \frac{6\sum_i d_i^2}{N(N^2-1)}.$$

- 有并列值时采用平均秩；如 $(1, 2, 2, 4)$ 的秩为 $(1, 2.5, 2.5, 4)$。

为什么使用秩相关?



单调非线性关系：次序完全一致，Pearson 小于 1。



少数偏离点改变数值距离，秩相关受到的影响相对较小。

图：统计分析第四章“数据的分类分析方法”，第 17–18 页。

IC：当期特征与下一期收益的相关

$$IC_{k,t} = \mathrm{Corr}_i(x_{i,k,t}, r_{i,t+1}), \qquad RankIC_{k,t} = \mathrm{Corr}_i\big(rank(x_{i,k,t}), rank(r_{i,t+1})\big).$$

- 固定形成日 t，每个观测是一只股票；每期得到一个相关系数。
- 当期特征对应下一持有期收益，不能用收益发生后的信息构造特征。
- 正 IC 表示高特征值与高收益同向，负 IC 表示反向。
- IC 是相关程度，不是收益率或预测正确率。

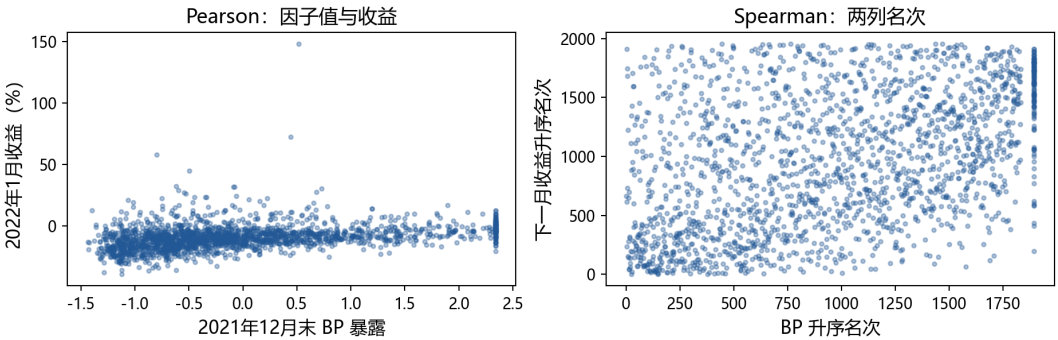
手算一次 Rank IC

股票	BP	下一月收益	BP 名次	收益名次	d_i^2
A	0.2	1%	1	1	0
B	0.5	3%	2	3	1
C	1.0	2%	3	2	1
D	2.0	4%	4	4	0

$$RankIC = 1 - \frac{6 \times 2}{4(4^2 - 1)} = 0.8.$$

排序整体同向，B、C 的次序相反。计算中两列都采用升序名次。

同一截面：因子值与名次



2021 年 12 月末 BP 与 2022 年 1 月收益。左图比较数值，右图比较相同配对股票的名次。

预处理对 IC 的影响

同一样本上的变换	Pearson IC	Rank IC
Z-score	不变	不变
严格递增非线性变换	通常改变	不变
缩尾、分箱	可能改变	并列名次可能改变
回归中性化	可能改变	可能改变

比较不同处理方法时，保持股票样本和收益区间一致。Z-score 后 IC 若发生变化，应先检查缺失值与样本变化。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

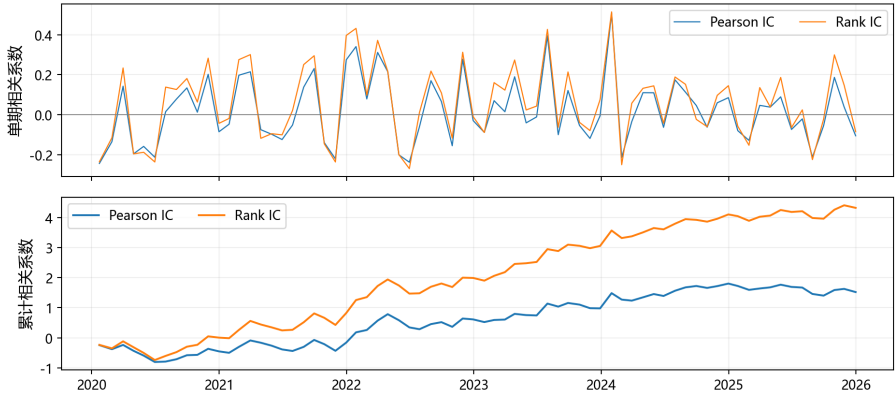
IC 时间序列与累计 IC

把各期 IC_t 按时间排列，累计 IC 定义为

$$C_T = \sum_{t=1}^{T} IC_t.$$

- 逐期 IC 显示方向与波动，便于识别异常月份。
- 累计曲线上升、横盘、下降，分别反映阶段内正、负 IC 的累积关系。
- 累计 IC 用于观察关联何时增强或减弱，不作复利计算，也不代表净值。

BP 的逐月 IC 与累计 IC



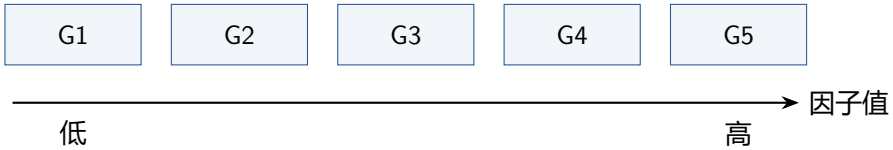
上图显示单期相关的波动，下图显示相关的累积。结合两幅图判断长期均值是否由少数月份主导。

跨期汇总指标

$$\overline{IC} = \frac{1}{T}\sum_{t} IC_t, \qquad ICIR = \frac{\overline{IC}}{s(IC)}, \qquad p_+ = \frac{\#\{t : IC_t > 0\}}{T}.$$

- 均值描述平均关联方向与强度；标准差描述跨期波动。
- 正值比例描述 IC 为正的有效期数占比，负均值也可能对应稳定的反向关系。
- ICIR 是均值与标准差之比，本讲不年化；零标准差时不定义。
- 同时报告期数、股票数和覆盖率；均值检验还需考虑序列相关。

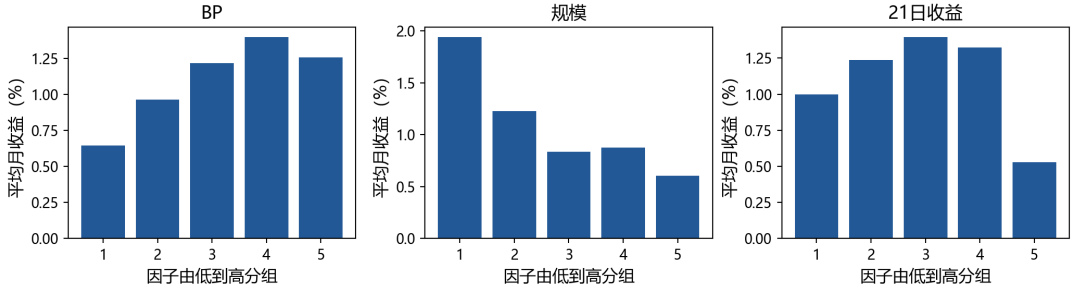
分组检验：观察排序对应的收益结构



1. 每个形成日按因子值从低到高排序，分为近似等数量的五组。
2. 计算每组下一期的等权平均收益，逐期重新分组。
3. 汇总组均收益并绘制各组净值，观察单调、反向或非单调结构。

G1、G5 只表示低值组和高值组；不预设哪组收益更高。

分组平均收益：整个排序还是局部差异？



比较三个特征的五组平均月收益。逐组上升或下降表示较清楚的单调结构；若差异集中在两端，整体 IC 未必能完整体现。

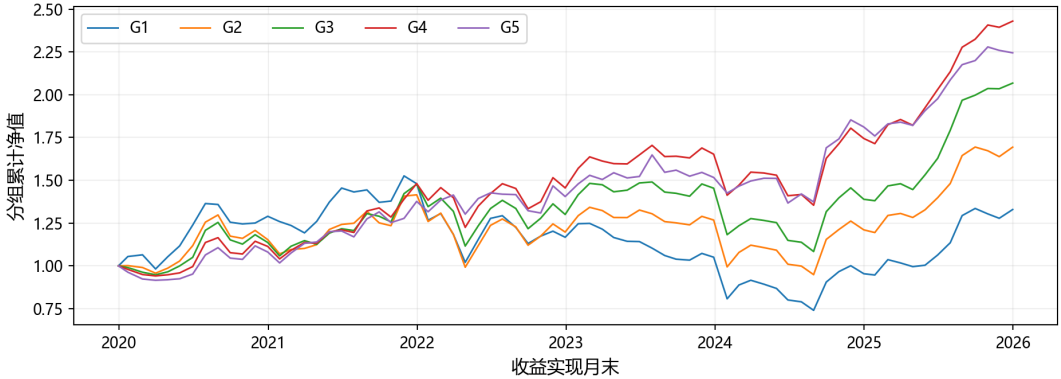
分组净值：收益差异何时形成?

组 q 的单期等权收益及累计净值为

$$R_{q,t+1} = \frac{1}{N_{q,t}} \sum_{i \in G_{q,t}} r_{i,t+1}, \qquad V_{q,T} = \prod_{t=0}^{T-1} (1 + R_{q,t+1}).$$

- 平均收益比较长期水平；净值曲线显示差异形成的时间和回撤过程。
- 检查组间差异是否持续，是否集中在某段行情。
- 本例为共同有效配对样本的分组统计，暂不模拟成交与交易成本。

BP 五组累计净值



G1 为低 BP，G5 为高 BP。逐月重新分组、恢复组内等权；初始净值为 1。样本缺失与覆盖率随统计表一并报告。

多空组合：排序两端的收益差

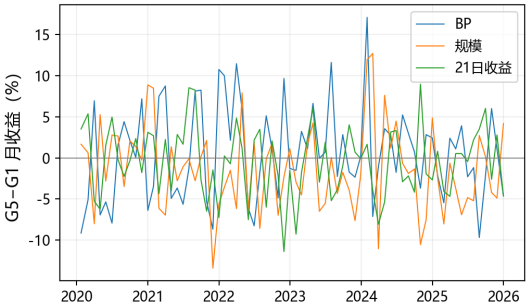
做多高因子值组 G5，做空低因子值组 G1，形成等金额多空组合：

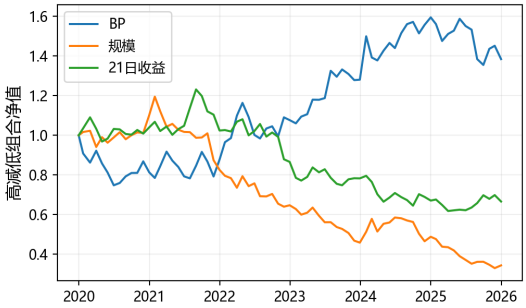
$$R_{t+1}^{H-L} = R_{G5,t+1} - R_{G1,t+1}.$$

- 正值表示高因子值组跑赢低值组；负值表示低值组跑赢高值组。
- IC 衡量整体关联，高减低收益衡量两端差异的经济幅度。
- 本例每期多、空名义金额各为期初净资产的 1 倍，现金收益与费用设为 0。
- 对应净值按 $V_{t+1} = V_t(1 + R_{t+1}^{H-L})$ 计算；同时报告收益波动和回撤。

等金额多空仍可能带有行业、规模和市场 Beta 暴露。

三个特征的多空收益与净值





统一使用 G5−G1，保留特征原始方向。负收益本身也是排序关系的证据。此图未计做空约束、融资与交易费用。

单因子检验的证据

IC、Rank IC	特征与未来收益的整体关联
逐期及累计 IC	关联出现在哪些阶段，是否稳定
分组平均收益	排序对应的收益结构，是否单调
分组净值	组间差异的积累过程与回撤
高减低收益	排序两端的收益差及其波动

结合这些结果判断方向、稳定性和收益幅度，再考察因子在模型中的增量作用。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

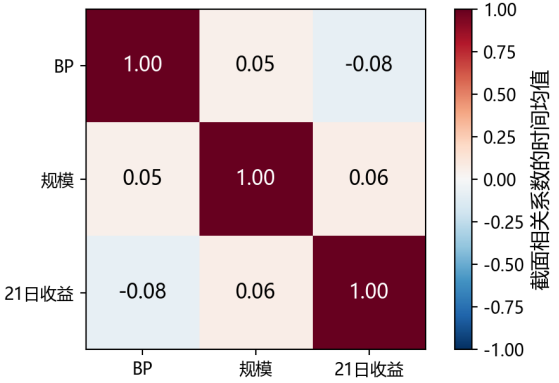
单因子有效与新增信息

BP、EP 都可能具有较好的单因子表现，但可能重复表达估值信息。

- 单因子检验观察该特征自身与收益的关联。
- 增量检验考察已有因子之外，它还保留多少与收益有关的信息。
- 先检查因子间相关，再检验候选因子对剩余收益差异的解释。

参考：招商证券（2017），第 7、11–12 页。

因子相关性：初步观察信息重复



图中为逐月截面相关系数的时间均值。相关性低表示特征不同；这些差异是否与收益有关，仍需进一步检验。

两个残差：剩余收益与新增特征

固定一个截面，将常数列并入已有特征矩阵 X：

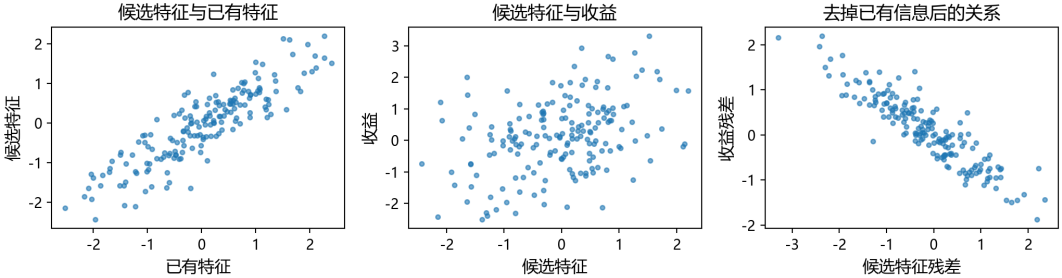
$$r = X\widehat{\beta} + u, \qquad x_{new} = X\widehat{\gamma} + v.$$

$$u = bv + \varepsilon.$$

- u：已有模型未解释的收益差异。
- v：候选特征未被已有特征线性解释的部分。
- 用 v 解释 u，检验新增信息与剩余收益差异之间的关系。

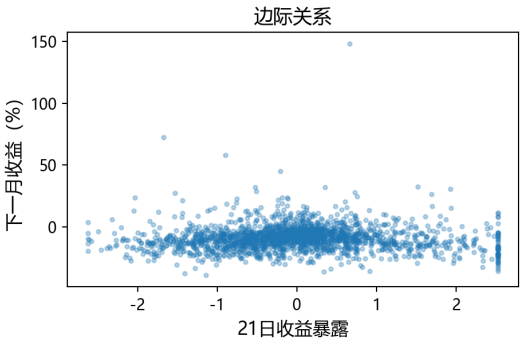
同一样本、含截距 OLS 下，该斜率等于直接将候选特征加入多元回归后的系数。

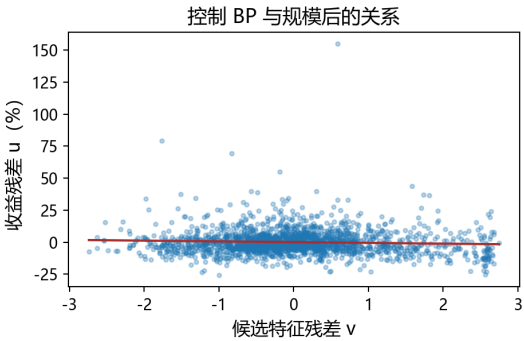
增量关系的模拟示例



模拟数据：候选特征与已有特征相关，边际收益关系混合了两部分影响。分别去掉已有信息后，可观察新增特征与剩余收益的关系。

实际截面中的残差关系



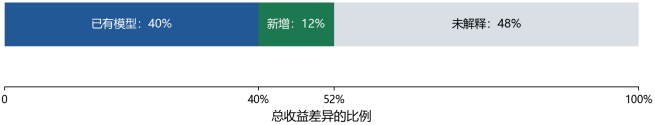


2021 年 12 月末特征与 2022 年 1 月收益。以 BP、规模为控制变量，分别对 21 日收益特征和下一月收益残差化。右图斜率对应多元模型中的候选特征系数。

新增解释度的计算

若已有模型解释了总收益差异的 40%，新增特征解释了剩余部分的 20%，则

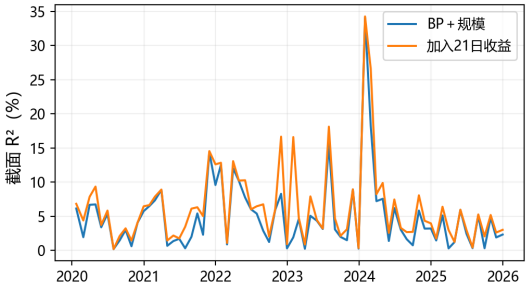
$$\Delta R^2 = (1 - 0.40) \times 0.20 = 0.12, \qquad R^2_{new} = 0.52.$$

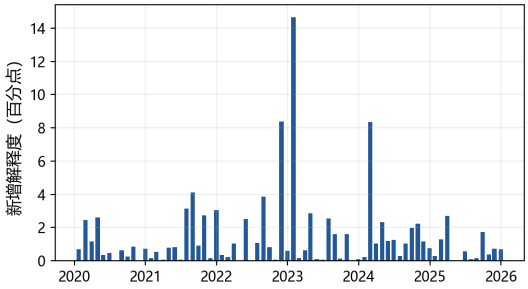


$$R^2_{new} = R^2_{old} + (1 - R^2_{old}) R^2_{increment}.$$

增量占比以剩余差异为分母，不能直接当作总解释度的增加。上述关系针对同一样本、同一收益变量的线性 OLS 比较。

加入 21 日收益后的解释度变化





同一截面样本上的二因子与三因子模型。普通样本内 R^2 随变量增加不会下降，仍需检查调整后 R^2、系数稳定性与后续样本表现。

因子进入顺序与贡献归属

进入顺序	首先解释	随后检验
规模 $\rightarrow$ BP	规模对应的收益差异	BP 在规模之外的贡献
BP $\rightarrow$ 规模	BP 对应的收益差异	规模在 BP 之外的贡献

- 增量贡献取决于已有变量，不能视为因子的固定属性。
- 同一样本、相同最终变量的线性 OLS，进入顺序不改变最终拟合，但改变逐步归因。
- 每步若再筛选或进行非线性赋值，最终模型也可能不同。

逐层增量解释思路参考：招商证券（2017），第 12 页。

收益解释与收益预测

已实现收益的解释模型为

$$r_{i,t+1} = a_{t+1} + \sum_k z_{i,k,t} f_{k,t+1} + u_{i,t+1}.$$

形成预测还需要在 t 时点给出系数预测：

$$\widehat{r}_{i,t+1|t} = \widehat{a}_{t+1|t} + \sum_k z_{i,k,t} \widehat{f}_{k,t+1|t}.$$

- 事后截面拟合良好，不保证未来预测有效。
- 合成后的预测或评分也应重新做 IC、分组与多空检验。
- 本实验以估计期平均回归系数形成检验期预测，系数正负由数据估计。

本讲位置

1. 原始特征与因子预处理
2. 相关系数与 IC
3. 累计 IC、分组与多空检验
4. 多因子模型的增量信息
5. 实验：从因子处理到增量检验

实验内容与数据

1. 构建 BP、规模、21 日收益，比较缩尾、标准化及赋值方法。
2. 计算 IC、累计 IC、五组收益与高减低收益。
3. 比较 BP + 规模与加入 21 日收益后的模型，解释系数和新增解释度。
4. 用 2020–2022 估计系数，在 2023–2025 检验预测。

使用 lab05 实践二的全部股票宽表，逐月筛选有效样本。历史分段用于教学对照，尚未模拟完整交易过程。

实验文件与输出

`lab06_framework.py`	学生模板，完成 L06-01 至 L06-06
`lab06_answer.py`	参考实现
`lab06_core.py`	数据、月份对齐、回归循环与导出
`lab06_figures.py`	分组统计与结果绘图

文件位于 `code/lab06/`；输出位于 `code/output/lab06/` 的 `student/` 或 `reference/`。

提交暴露表、IC 表、分组与多空收益表、回归结果，以及相应图形和简短分析。

L06-01 至 L06-03：构建与处理特征

```
def make_factors(panel):
    return pd.DataFrame({"bp": 1 / panel.pb,
                         "size": np.log(panel.total_mv),
                         "ret21": panel.ret21}, index=panel.index)

panel["bp_mad"] = panel.groupby("date")["bp"].transform(winsor_mad)
panel["bp_mad_z"] = panel.groupby("date")["bp_mad"].transform(zscore)
```

在模板中补全缩尾、Z-score 和秩赋值函数；计算标准化前后的均值、标准差，并查看分布图。

L06-04：IC 与分组收益

```
pair = cross[["bp_mad_z", "next_ret"]].dropna()
ic = pair.bp_mad_z.corr(pair.next_ret)
rank_ic = pair.bp_mad_z.rank().corr(pair.next_ret.rank())

rank = pair.bp_mad_z.rank(method="first")
group = pd.qcut(rank, 5, labels=[1, 2, 3, 4, 5])
group_ret = pair.next_ret.groupby(group, observed=True).mean()
high_low = group_ret.loc[5] - group_ret.loc[1]
```

先按股票代码排序，以代码顺序处理并列边界。将每期统计连成时间序列，分别计算累计 IC 与收益净值。

单因子结果：保留关联的正负

样本段	特征	平均 IC	平均 Rank IC	正值比例
估计期	BP	0.017	0.055	55.6%
估计期	规模	-0.024	-0.028	44.4%
估计期	21 日收益	-0.017	-0.038	47.2%
检验期	BP	0.025	0.065	61.1%
检验期	规模	-0.040	-0.058	38.9%
检验期	21 日收益	-0.036	-0.051	38.9%

根据 IC、分组与高减低结果解释三个特征的收益关联；不能仅以正值比例判断有效性。

L06-05：候选特征的残差

```
controls = cross[["bp_mad_z", "size_mad_z"]]
v = residualize(cross.ret21_mad_z, controls)
u = residualize(cross.next_ret, controls)

slope = (v @ u) / (v @ v)
```

分别残差化特征和收益。比较该斜率与三因子回归中 21 日收益的系数，验证二者一致。

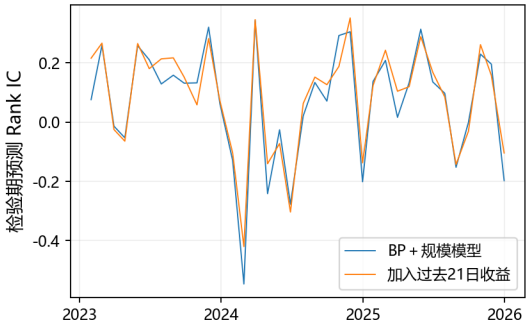
L06-06：回归系数与检验期预测

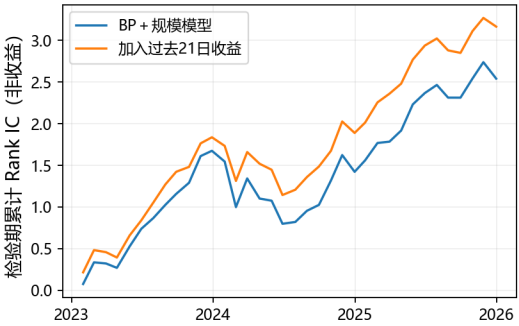
```
params, r2 = fit_model(cross.next_ret,
    cross[["bp_mad_z", "size_mad_z", "ret21_mad_z"]])

# Estimate each training month, then average the coefficients.
weights = training_coefficients.mean()
prediction = weights["const"] + test_exposures @ weights[test_exposures.columns]
```

使用相同股票样本比较两个模型。预测系数只由估计期得到，检验期不重新使用同期收益拟合预测权重。

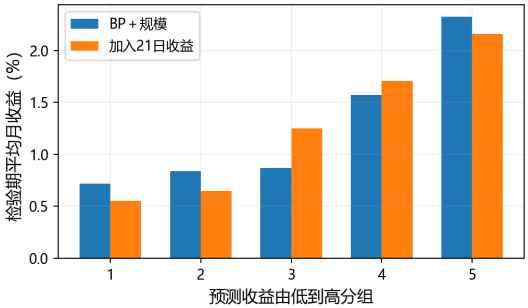
检验期预测：两个模型的比较

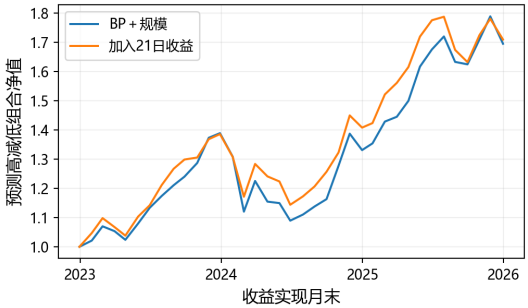




预测采用 2020–2022 的平均月度回归系数；2023–2025 固定使用这些系数。观察新增特征是否改善后续收益排序。

多因子预测的分组与多空检验





按检验期预测收益从低到高分组，比较组均收益和 G5−G1 净值。分组统计及多空资金口径与单因子部分相同；未计交易成本。

实验讨论

- 处理前后的哪些变化来自数值尺度，哪些来自排序或样本变化？
- IC、分组收益与高减低组合是否给出一致的关联方向？差异集中在哪些阶段？
- 新增特征与已有特征是否重复？它解释了多少剩余收益差异？
- 样本内解释度的增加，是否对应检验期预测的改善？还需要哪些交易与成本检验？